



Metode Explainable Artificial Intelligence (XAI) Berbasis Feature Importance Untuk Deteksi Dini Penyakit Jantung

Medycha Emhandyksa^{a*}, Izza Nur Afifah^b

^{a,b}Teknik Robotika dan Kecerdasan Buatan, Universitas Sunan Gresik, Indonesia

*Korespondensi Penulis: medycha.e@lecturer.usg.ac.id

INFO ARTIKEL

Riwayat Artikel

Diterima, Januari 13, 2026

Direvisi, Maret 1, 2026

Disetujui, Maret 15, 2026

Tersedia, Maret 31, 2026

Kata Kunci

Explainable Artificial

Intelligence

Deep Learning Neural Network

LIME

SHAP

Hidden Layer

ABSTRAK

Explainable Artificial Intelligence (XAI) merupakan pendekatan baru yang mampu mengatasi sifat *black box* pada algoritma *deep learning neural network*. Penelitian ini bertujuan untuk memperluas aspek penelitian XAI melalui analisa pengaruh jumlah *hidden layer* dan *neurons* pada algoritma *Deep Learning Neural Network* (DLNN) terhadap keterpilihan *feature importance* yang dihasilkan oleh dua mode XAI yaitu *Local Interpretable Model-Agnostic Explanation* (LIME) dan *Shapley Additive Explanations* (SHAP). Objek penelitian yang digunakan adalah data sekunder parameter medis untuk deteksi dini penyakit jantung. Hasil penelitian menunjukkan kelima model DLNN yang dirancang memiliki tingkat *accuracy* dan *f1-score* yang fluktuatif pada rentang 70% hingga 80%. Model DLNN ke-3 dengan 15 *hidden layer* dan 16 *neurons* menghasilkan *feature importance* fbs menggunakan model LIME. Model DLNN lainnya menghasilkan *feature importance* cp menggunakan model LIME. Metode *hyperparameter tuning* dengan teknik *Grid Search CV* menghasilkan tingkat *accuracy* sebesar 84% dengan *feature importance* cp menggunakan model LIME. Penelitian pada model SHAP tidak dapat dilanjutkan akibat terjadi *error* pada struktur data. Jumlah *hidden layer* dan *neurons* pada algoritma DLNN mempengaruhi keterpilihan *feature importance* yang dihasilkan model LIME.

This is an open-access article under the CC-BY-SA license.



1. Pendahuluan

World Health Organization (WHO) menyatakan *coronary heart disease* atau penyakit jantung menjadi penyebab kematian terbesar di Dunia dengan jumlah kematian mencapai 9,1 juta pada tahun 2021 (WHO, 2021). Beberapa faktor resiko penyebab penyakit jantung yaitu kekurangan gizi, kebiasaan merokok, penggunaan alkohol, perokok pasif, dan kekurangan aktivitas fisik (American Heart Association, 2021). Terdapat beberapa faktor resiko pendukung lainnya seperti usia, genetik, jenis kelamin, hipertensi, *diabetes mellitus*, obesitas, gaya hidup, dan *hyperlipidemia* [1], [2].

Machine learning merupakan kecerdasan buatan (*artificial intelligence*) dengan kemampuan mempelajari pola data secara otomatis dan mengeluarkan prediksi yang akurat berdasarkan pola tersebut [3]. Penggunaan *machine learning* di bidang kesehatan khususnya pada kasus deteksi penyakit jantung menunjukkan potensi untuk membantu dokter melakukan upaya deteksi dini [4], [5], [6]. Model *XGBoost* dan *K-Nearest Neighbors* mampu mencapai akurasi sebesar 98,50% dan 91,80% [7]. Model *deep learning* yang dipadukan dengan metode *Genetic Algorithm* dan *Recursive Feature Elimination* (RFEM) sebagai *feature selection* dan metode *Adaptive Elephant Herd Optimization* (AEHOM)

sebagai metode optimasi menunjukkan tingkat akurasi sebesar 89,1%, presisi sebesar 88,3%, dan *F1-Score* sebesar 89,6% [8]. Chayakrit K. et al. menunjukkan *custom-built algorithm* menjadi model terbaik dengan nilai parameter AUC sebesar 0,93 pada 103 *cohort study* [9]. Studi *literature review* pada 59 penelitian terdahulu menunjukkan model CNN dan *Residual Network* (ResNet) merupakan dua model yang paling banyak digunakan dengan tingkat akurasi mencapai 97% [10]. Hasil penelitian menggunakan *multimodal machine learning* menunjukkan beberapa *framework multimodal machine learning* memiliki rata-rata tingkat akurasi sebesar 90,8% dan AUC sebesar 0,89 [11]. Hasil penelitian lainnya menunjukkan model *machine learning* yang dipadukan dengan metode SMOTE dan *Extra Trees* yang telah dioptimasi menggunakan *Hyperband* memiliki performa tertinggi sebesar 99% pada parameter akurasi, *recall*, dan *F1-Score* [12].

Meskipun model *Deep Learning Neural Network* (DLNN) memiliki performa yang tinggi, model tersebut tidak mampu memberikan penjelasan mengenai hasil prediksi yang dikeluarkan (*unexplainable*) akibat sifat *black box* yang dimilikinya. Adanya sifat *black box* menghambat penerapan algoritma *deep learning* secara praktis [13], [14]. *Explainable artificial intelligence* (XAI) merupakan bidang pendekatan baru dengan tujuan memberikan penjelasan yang dipahami manusia terkait mekanisme pengambilan keputusan atau hasil prediksi dari algoritma *machine learning* yang bersifat *black box* [13], [15], [16]. Penggunaan XAI di bidang kesehatan membantu klinisi untuk *decision support* dalam mendeteksi berbagai macam penyakit [17], [18].

Penelitian terdahulu menunjukkan adanya keterbatasan yang secara spesifik mengkaji pengaruh jumlah lapisan dan *neurons* pada *hidden layer* algoritma *deep learning neural network* (DLNN) terhadap keterpilihan *feature relevance* yang dihasilkan oleh model LIME dan SHAP. Jumlah lapisan dan *neurons* pada *hidden layer* merupakan dua elemen utama pada algoritma DLNN untuk menghasilkan performa yang tinggi [3], [19], [20]. Namun demikian kedua elemen tersebut juga merupakan salah satu faktor penyebab algoritma DLNN memiliki sifat *black box* khususnya pada lapisan *hidden layer*. Oleh sebab itu penelitian ini bertujuan untuk memperluas aspek penelitian XAI melalui analisa pengaruh jumlah *hidden layer* dan *neurons* pada algoritma *Deep Learning Neural Network* (DLNN) terhadap keterpilihan *feature importance* yang dihasilkan oleh dua mode XAI yaitu *Local Interpretable Model-Agnostic Explanation* (LIME) dan *Shapley Additive Explanations* (SHAP).

2. Metode Penelitian

Metode penelitian yang digunakan bersifat simulasi eksperimental. Pada penelitian ini dilakukan perancangan dan pengembangan algoritma yang merupakan integrasi dari algoritma *Deep learning neural network* (DLNN) dan dua algoritma *Explainable artificial intelligence* (XAI) yaitu *Local Interpretable Model-Agnostic Explanations* (LIME) [21] dan *Shapley Additive Explanations* (SHAP) [22]. Data yang digunakan merupakan data sekunder yaitu *Cleveland Cardiovascular Disease Dataset* yang bersumber dari *Kaggle.com*. Penelitian ini menggunakan sumber daya komputasi dengan beberapa spesifikasi yaitu laptop HP ProBook 440 G11, *processor Intel(R) Core (TM) Ultra 5 125U (1.30 GHz)*, *64-bit operating system*, *SSD 477GB*, dan RAM 16GB. Penelitian yang dilakukan memiliki beberapa tahapan sebagai berikut.

2.1. Pengumpulan Data


Tahap pengumpulan data dilakukan dengan melakukan analisis pada beberapa *website* seperti *Kaggle.com* dan *UCI.com* untuk mendapatkan *dataset* yang relevan dan valid. Hasil analisis menunjukkan *Cleveland Cardiovascular Disease dataset* merupakan *dataset* penyakit jantung yang cukup relevan dan valid. *Dataset* tersebut banyak

digunakan sebagai bahan penelitian di berbagai Negara dan telah terpublikasi diberbagai jurnal terindeks *scopus* [23].

Cleveland Cardiovascular Disease dataset terdiri dari dua kategori atau kelas data pasien yaitu kelas 0 (tidak berpotensi penyakit jantung) sebanyak 164 data dan kelas 1 (berpotensi penyakit jantung) sebanyak 139 data. *Dataset* tersebut memiliki 14 fitur yaitu *age*, *sex*, *cp*, *trestbps*, *chol*, *fbs*, *restecg*, *thalach*, *exang*, *oldpeak*, *slope*, *ca*, *thal*, dan *target*. Fitur *target* terdiri dari dua kelas yaitu 0 dan 1 yang membedakan kategori atau kelas data pasien (tidak berpotensi atau berpotensi penyakit jantung).

2.2. Pengolahan Data

Tahap penelitian berikutnya dilakukan proses analisa dan pengolahan terhadap data yang telah didapatkan. Kedua proses tersebut bertujuan untuk menyiapkan data dalam format yang dapat digunakan oleh algoritma *machine learning*. Gambar 1 menunjukkan alur pengolahan *dataset* yang dilakukan pada penelitian ini.



Gambar 1 Alur Pengolahan Data.

Alur pengolahan data dimulai dengan merubah format *dataset* menjadi *dataframe* menggunakan *library* Pandas. Kemudian dilakukan analisa apakah terdapat nilai data yang kosong (*checking missing values*). Setelah dipastikan bahwa tidak terdapat nilai

data yang kosong, kemudian dilakukan analisa apakah jumlah data kelompok atau kelas target sudah seimbang (*checking imbalanced dataset*). Pada penelitian ini ditemukan bahwa terjadi ketidakseimbangan jumlah data pada kelas target 0 (164 data) dan kelas target 1 (139). Teknik *Synthetic Minority Over-Sampling Technique* (SMOTE) [24] untuk menyeimbangkan jumlah data pada kedua kelas tersebut menjadi 328 data. Langkah berikutnya adalah membagi data menjadi data latih dan data uji. Pada penelitian ini dilakukan pembagian data latih sebesar 80% dan data uji sebesar 20%. Langkah terakhir pada alur pengolahan data adalah *data scaling* yang berarti merubah skala data ke dalam rentang 0 hingga 1. Proses *data scaling* dilakukan supaya data dapat digunakan lebih lanjut pada model *deep learning neural network*.

2.3. Perancangan Algoritma

Pada penelitian ini dilakukan perancangan dan pengembangan lima algoritma atau model *Deep learning neural network* (DLNN) yang diintegrasikan dengan dua algoritma *Explainable Artificial Intelligence* (XAI) yaitu *Local Interpretable Model-Agnostic Explanation* (LIME) dan *Shapley Additive Explanations* (SHAP) untuk deteksi dini penyakit jantung. Penelitian ini dilakukan sebagai salah satu upaya menciptakan teknologi *Artificial Intelligence* (AI) yang transparan dan dapat dipercaya.

Perancangan algoritma pada penelitian ini menggunakan *software* VSCode dengan bahasa pemrograman *Python*. Dalam perancangan dan pengembangan algoritma terdapat empat tahapan yang terdiri dari persiapan *framework*, perancangan dan pengembangan algoritma DLNN, perancangan algoritma LIME dan SHAP, dan integrasi antara algoritma DLNN dengan algoritma LIME serta SHAP.

2.3.1. Persiapan Framework

Framework yang digunakan pada penelitian ini adalah *Tensorflow*, *LIME*, dan *SHAP*. *Framework Tensorflow* digunakan untuk membuat model *Deep learning neural network* (DLNN) sedangkan *Framework LIME* dan *Framework SHAP* masing-masing digunakan untuk membuat model LIME dan SHAP. *Framework LIME* dan *SHAP* merupakan *library* independen yang dikhususkan untuk membuat model *Explainable Artificial Intelligence*. Kedua *framework* tersebut dapat diintegrasikan dengan *framework Tensorflow* untuk memberikan penafsiran hasil prediksi dari model *deep learning*.

2.3.2. Perancangan Deep Learning Neural Network (DLNN)

Pada penelitian ini dilakukan perancangan lima model *Deep learning neural network* (DLNN) dengan variasi pada jumlah *hidden layer* dan jumlah *neurons* yang ada di dalam *hidden layer* tersebut. Perancangan model DLNN dilakukan melalui percobaan *trials and errors* yang berlandaskan prinsip *Occam's Razor*, yaitu mencari model paling sederhana yang dapat menghasilkan performa terbaik. Penelitian ini juga menggunakan teknik *hyperparameter tuning* yaitu *Grid Search CV* untuk mendapatkan satu model dengan *hyperparameter* terbaik diantara lima model DLNN yang dirancang. Tabel 1 menunjukkan rekayasa berupa kombinasi antara jumlah *hidden layer* yang meningkat dengan jumlah *neurons* yang meningkat dan menurun yang terdapat di dalam *hidden layer* tersebut.

Tabel 1 Rekayasa Model DLNN.

Model ke-	<i>Hidden Layers</i> (meningkat)	<i>Neurons</i>	
		Meningkat	Menurun
1	5	4	64
2	10	8	32
3	15	16	16
4	20	32	8
5	25	64	4

Perancangan model DLNN menggunakan bahasa pemrograman *Python* memerlukan beberapa *library* sebagai berikut.

Library Python untuk perancangan model DLNN:

```
import tensorflow as tf
from tensorflow.keras.layers import Dense, Conv1D,
MaxPooling1D, Flatten, Dropout
```

Terdapat *hyperparameter* pada model DLNN yang menjadi variabel terkontrol sebagai berikut.

```
Activation function : ReLu
Learning_rate_init : 0.001
Random_state       : 5
Verbose            : True
Learning_rate       : 'invscaling'
Momentum           : 0.9
```

2.3.3. Perancangan Model Local Interpretable Model-Agnostic Explanation (LIME)

Local Interpretable Model-Agnostic Explanation (LIME) merupakan salah satu metode *Explainable Artificial Intelligence* (XAI) yang dapat digunakan disemua jenis model *machine learning* (*model-agnostic*) dan bersifat memberikan penjelasan hasil prediksi setelah tahap pelatihan dan pengujian model (*post-hoc explanation*) [21]. Penjelasan yang dihasilkan oleh model LIME bersifat individu (*local explanation*), yang berarti model LIME memberikan penjelasan pada setiap hasil prediksi, bukan memberikan penjelasan untuk perilaku model *machine learning* secara keseluruhan.

Tujuan utama dari model LIME adalah memastikan kehandalan interpretabilitas dan keakuratan penjelasan secara lokal. Dalam rangka mencapai kedua tujuan tersebut, model LIME harus memastikan kedua parameter berikut ini tetap rendah (minimal) untuk bisa dipahami oleh manusia.

$$\mathcal{L}(f, g, \pi_x); \Omega(g) \quad (1)$$

Keterangan:

$\mathcal{L}(f, g, \pi_x)$: menunjukkan seberapa tidak akuratnya fungsi g dalam mendekati fungsi f secara lokal

$\Omega(g)$: mengukur tingkat kompleksitas penjelasan yang dihasilkan fungsi g

Secara detail berikut merupakan rumus matematis dari penjelasan yang dihasilkan oleh model LIME.

$$\xi(x) = \operatorname{argmin}_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g) \quad (2)$$

2.3.4. Perancangan Model Shapley Additive Explanation (SHAP)

Shapley Additive Explanations (SHAP) merupakan salah satu metode XAI yang memberikan pembobotan (*weighting*) pada setiap fitur (*feature importance*) terhadap hasil prediksi kelas tertentu [22]. Terdapat tiga hal utama pada model SHAP yaitu penjelasan dari model yang menjadi model itu sendiri (*explanation model*) yang kemudian disebut dengan *the class of additive features attribution methods* yang menggabungkan enam model XAI, penggunaan *game theory* berbasis *SHAP values* sebagai pengukuran terpadu, dan metode *SHAP value* terbaru yang lebih sesuai dengan intuisi manusia. *The class of additive features attribution methods* memiliki model matematis sebagai berikut:

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i \quad (3)$$

syarat: $z' \in \{0,1\}^M$ dan $\phi_i \in \mathbb{R}$

Keterangan:

M: jumlah dari fitur masukkan yang disederhanakan

Explanation model memanfaatkan data *input* x' yang dipetakan terhadap data *input* yang asli melalui fungsi $x = h_x(x')$. *The class of additive featurer attribution methods* menghasilkan satu solusi unik (*explanation models*) yang memiliki tiga kriteria yaitu *local accuracy*, *missingness*, dan *consistency*. Berikut model matematis dari satu solusi unik tersebut.

$$\phi_i(f, x) = \sum_{z' \subseteq x'} \frac{|z'|!(M-|z'|-1)!}{M!} [f_x(z') - f_x(z' \setminus i)] \quad (4)$$

Keterangan:


ϕ_i : *Shapley values*

Berdasarkan model matematis dari satu solusi unik tersebut dapat diketahui bahwa metode yang tidak berbasis pada *shapley values* akan menurunkan nilai *local accuracy* dan *consistency*. Hal inilah yang mendasari perancangan model SHAP sebagai metode pengukuran terpadu dari *feature importance*. Berikut merupakan model matematis dari model SHAP.

$$f(h_x(z')) = E[f(z) | z_s] \quad (5)$$

2.3.5. Integrasi Algoritma DLNN dengan Algoritma LIME dan SHAP

Integrasi antara model DLNN dengan model LIME dan SHAP merupakan fokus utama dari penelitian untuk mengetahui pengaruh jumlah *hidden layer* dan *neurons* yang ada di dalamnya pada algoritma DLNN terhadap keterpilihan *feature relevance* yang dihasilkan oleh metode LIME dan SHAP. Kelima model DLNN yang telah dilakukan tahap perancangan, pelatihan, pengujian, dan evaluasi, secara berurutan dilakukan tahap perancangan penjelasan hasil prediksi menggunakan model LIME dan SHAP. Kedua model tersebut akan memberikan penjelasan hasil prediksi berupa *feature importance* yang menunjukkan fitur yang paling mempengaruhi model dalam pengambilan keputusan. Pada penelitian ini digunakan data uji ke-15 sebagai sampel hasil prediksi yang akan diberikan penjelasan. Gambar 2 merupakan *flowchart* integrasi antara model DLNN dengan model LIME dan SHAP.



Gambar 2 Flowchart Integrasi Model DLNN dengan LIME dan SHAP.

Tahap pemberian penjelasan hasil prediksi dilakukan dengan memilih sample hasil prediksi terlebih dahulu dimana pada penelitian ini digunakan sampel hasil prediksi ke-15. Kemudian dilakukan proses *explain instance* yang dilakukan oleh model LIME dan SHAP dengan parameter yang diolah adalah sampel data hasil prediksi, model DLNN, dan jumlah *feature importance* yang akan ditampilkan. Tahap terakhir adalah menampilkan *feature importance* hasil analisa model LIME dan SHAP yang menunjukkan fitur data yang paling mempengaruhi model DLNN dalam mengambil keputusan kelas tertentu menggunakan sampel data hasil prediksi ke-15.

2.4. Pelatihan dan Pengujian Algoritma

Algoritma yang telah dirancang kemudian dilakukan tahap pelatihan dan pengujian. Tahap pelatihan bertujuan untuk mengenalkan algoritma terhadap pola-pola yang terdapat di dalam *dataset*. Setelah mengenali pola-pola tersebut algoritma akan diuji menggunakan data baru untuk mengetahui kemampuan generalisasi algoritma. Pada tahap pelatihan digunakan beberapa *hyperparameter* sebagai berikut.

Epoch : 500
Cross Validation : 10
matrix evaluation : *accuracy, f1-score*

2.5. Evaluasi Algoritma

Tahap evaluasi algoritma dilakukan untuk mengetahui tingkat deviasi performa model terhadap nilai yang sebenarnya *groundtruth*. Pada penelitian ini terdapat dua parameter evaluasi yang digunakan yaitu *accuracy* dan *f1-score*. Pemilihan parameter *accuracy* didasarkan pada efektivitas parameter tersebut yang dapat menunjukkan kemampuan model dalam memprediksi kelas yang sebenarnya (*true positive and true negative*) di dalam populasi seluruh jenis prediksi kelas (*true positive, true negative, false positive, false negative*). Parameter *f1-score* juga dipilih pada penelitian ini sebagai metode evaluasi karena memiliki kemampuan untuk menunjukkan keseimbangan antara parameter *recall* dan *precision*. Berikut merupakan model matematis dari parameter *accuracy* dan *f1-score*.

$$accuracy = \frac{TP+TN}{P+N} \quad (6)$$

$$F1 - Score = \frac{2 \times precision \times recall}{precision + recall} \quad (7)$$

Keterangan:

TP : *True Positive*
 TN : *True Negative*
 FN : *False Negative*
 FP : *False Positive*
 P : TP + FN
 N : FP + TN

3. Hasil dan Pembahasan


3.1. Hasil Penelitian

Tabel 2 menunjukkan hasil penelitian mengenai pengaruh jumlah *hidden layers* dan *neurons* yang ada di dalamnya terhadap nilai *accuracy* dan *f1-score* serta keterpilihan *feature importance* yang dihasilkan model LIME dan SHAP. Kolom berwarna abu-abu menunjukkan model ke-2 yang memiliki *hyperparameter* yang sama dengan *hyperparameter* terbaik yang dihasilkan oleh teknik *Grid Search CV* (kolom berwarna kuning). Kolom berwarna merah menunjukkan hasil penelitian pada model SHAP yang mengalami *error structure data*. Gambar 3 menunjukkan tingkat *accuracy* yang


dihasilkan oleh kelima model DLNN. Gambar 4 menunjukkan tingkat *f1-score* yang dihasilkan oleh kelima model DLNN. Gambar 5 menunjukkan tingkat keterpilihan *feature importance* pada model LIME yang merupakan penjelasan hasil prediksi dari kelima model DLNN.

Tabel 2 Hasil Penelitian Pengaruh Rekayasa Jumlah *Hidden Layers* dan *Neurons* Terhadap Parameter Evaluasi dan *Feature Importance*.


Model	Jumlah <i>Hidden Layers</i>	Jumlah <i>Neurons</i>	<i>Accuracy</i> (%)	<i>F1-Score</i> (%)	<i>Feature Importance</i>	
					LIME	SHAP
1	5	4	74	74	cp	<i>Error code</i>
		64	75	75	cp	
2	10	8	74	73	cp	
		32	71	70	cp	
3	15	16	75	75	fbs	
		16	75	75	fbs	
4	20	32	72	72	cp	
		8	80	80	cp	
5	25	64	77	77	cp	
		4	45	31	fbs	
<i>Grid Search CV</i>	10	8	84		cp	



Gambar 3 Perbandingan Nilai *Accuracy* Antar Model DLNN.



Gambar 4 Perbandingan Nilai *F1-Score* Antar Model DLNN.



Gambar 5. Proporsi Keterpilihan *Feature Importance* Model LIME.

3.2. Pembahasan

Hasil penelitian menunjukkan tidak terjadi perubahan yang signifikan pada tingkat *accuracy* (Gambar 3) dan tingkat *f1-score* (Gambar 4) yaitu pada rentang 70-80% ketika terjadi peningkatan atau penurunan jumlah *hidden layers* dan *neurons* yang ada di dalamnya. Tidak adanya perubahan yang signifikan tersebut dapat disebabkan model mengalami *underfitting* akibat kurangnya kompleksitas model yang dirancang [25]. Jumlah *neurons* yang digunakan pada satu model bersifat homogen dan tidak ada kombinasi. Sebagai contoh pada model 1 digunakan lima *hidden layers* dengan empat *neurons* pada setiap lapisan *hidden layer*nya. Jumlah *neurons* yang sama pada setiap *hidden layer* tersebut dapat menghambat model untuk merekonstruksi pola yang terdapat di dalam data latih sehingga model tidak mampu mempelajari pola tersebut secara sempurna. Hasil penelitian menggunakan metode *hyperparameter tuning* dengan teknik *Grid Search CV* menunjukkan bahwa model ke-2 dengan 10 *hidden layer* dan 8 *neurons* memiliki *hyperparameter* yang sama dengan *hyperparameter* terbaik yang dihasilkan oleh teknik tersebut. Teknik *Grid Search CV* menunjukkan nilai *accuracy* tertinggi yaitu 84%.

Berdasarkan hasil penelitian model *Deep Learning Neural Network* (DLNN) yang dirancang *from scratch* dengan jumlah *hidden layer* dan *neurons* yang ada di dalamnya yang relatif tinggi atau rendah menghasilkan keterpilihan *feature importance* yang sama (fitur cp) pada model LIME. Sebaliknya model DLNN *from scratch* dengan jumlah *hidden layer* dan *neurons* yang ada di dalamnya yang tidak relatif tinggi atau rendah menghasilkan keterpilihan *feature importance* yang berbeda (fitur fbs) pada model LIME. Hasil ini ditunjukkan dengan data pada Tabel 2 dan Gambar 5. Berdasarkan data pada Tabel 2 dapat diketahui bahwa model DLNN ke-3 yang memiliki jumlah *hidden layers* dan *neurons* yang tidak terlalu tinggi dan tidak terlalu rendah (15 *hidden layers* dan 16 *neurons*), model LIME menghasilkan fbs sebagai fitur yang paling mempengaruhi model dalam menghasilkan keputusan tertentu (*feature importance*). Pada model DLNN 1, 2, 4, dan 5 *feature importance* yang dianggap paling mempengaruhi model dalam menghasilkan keputusan adalah fitur cp. Penelitian menggunakan metode *hyperparameter tuning* dengan teknik *Grid Search CV* menghasilkan fitur cp sebagai *feature importance* yang dihasilkan oleh model LIME. Fitur cp merupakan jenis nyeri dada yang dialami pasien yang terdiri dari empat tingkatan yaitu angina tipikal (kelas 0), angina atipikal (kelas 1), nyeri non-anginal (kelas 2), tanpa gejala (kelas 3). Fitur fbs

berarti tingkat gula darah puasa pasien. Pada Gambar 5 dapat diketahui bahwa *feature importance* dengan proporsi tertinggi (7 data) yang dihasilkan model LIME adalah cp yang terdapat pada model DLNN 1, 2, 4, 5 sedangkan fbs menjadi *feature importance* tertinggi kedua (3 data) yang dihasilkan oleh model 3.

Pada tahap pemberian penjelasan hasil prediksi menggunakan model SHAP, terjadi kesalahan *error* pada struktur data seperti yang ditunjukkan pada Gambar 6. Kesalahan atau *error* yang terjadi disebabkan model SHAP tidak dapat mengolah data yang memiliki skala 0 hingga 1, sedangkan model DLNN yang termasuk *multilayer neural network* hanya dapat mengolah data yang memiliki skala 0 hingga 1 supaya mendapatkan hasil yang optimal. Oleh sebab itu penelitian untuk memberikan penjelasan hasil prediksi menggunakan model SHAP tidak dapat dilanjutkan.

SHAP Explainer

```
idx=9
explainer = shap.KernelExplainer(gol_naik.predict, X_test_scaled)
sv = explainer.shap_values(X_test_scaled.loc[[5]])
exp = shap.Explanation(sv, explainer.expected_value, data=X_test_scaled.loc[[idx]].values, feature_names=X_test_scaled.columns)
shap.plots.waterfall(exp[0])
```

AttributeError Traceback (most recent call last)

Cell In[20], line 3

```
1 idx=9
2 explainer = shap.KernelExplainer(gol_naik.predict, X_test_scaled)
----> 3 sv = explainer.shap_values(X_test_scaled.loc[[5]])
4 exp = shap.Explanation(sv, explainer.expected_value, data=X_test_scaled.loc[[idx]].values, feature_names=X_test_scaled.columns)
5 shap.plots.waterfall(exp[0])
```

AttributeError: 'numpy.ndarray' object has no attribute 'loc'

Gambar 6 Kesalahan atau *Error* Pada Model SHAP.

4. Kesimpulan

Explainable Artificial Intelligence (XAI) merupakan pendekatan baru yang berupaya menciptakan teknologi kecerdasan buatan khususnya algoritma *Deep Learning Neural Network* (DLNN) yang lebih transparan dan dapat dipercaya sehingga meningkatkan penerapan teknologi secara praktis. Penelitian mengenai rekayasa *hidden layer* pada perancangan algoritma DLNN yang dikombinasikan dengan metode XAI dapat menjadi langkah awal yang strategis untuk mewujudkan upaya tersebut. Berdasarkan hasil penelitian dapat disimpulkan bahwa jumlah *hidden layer* dan *neurons* yang ada di dalamnya pada model *Deep Learning Neural Network* (DLNN) yang dirancang *from scratch* mempengaruhi tingkat keterpilihan *feature importance* yang dihasilkan oleh model LIME. Model SHAP tidak dapat menjelaskan hasil prediksi yang dikeluarkan oleh algoritma DLNN yang dirancang *from scratch*. Metode *hyperparameter tuning* dengan teknik *Grid Search CV* memiliki potensi yang cukup menjanjikan untuk dikombinasikan dengan model LIME.

Hasil penelitian dapat dilakukan pengembangan lebih lanjut dengan beberapa poin sebagai berikut.

- Eksplorasi pada tahapan *preprocessing data* untuk menyesuaikan format data antara algoritma *deep learning neural network* dengan algoritma SHAP.
- Eksplorasi model DLNN yang digunakan dan metode pelatihan model.
- Penggunaan metode *Explainable Artificial Intelligence* berbasis *attribution maps*.

Daftar Pustaka

- [1] R. J. Koene, A. E. Prizment, A. Blaes, and S. H. Konety, "Shared risk factors in cardiovascular disease and cancer," *Circulation*, vol. 133, no. 11, pp. 1104-1114, 2016, <https://doi.org/10.1161/CIRCULATIONAHA.115.020406>.
- [2] W. C. Meijers and R. A. de Boer, "Common risk factors for heart failure and cancer," *Cardiovascular Research*, vol. 115, no. 5, pp. 844-853, 2019, <https://doi.org/10.1093/cvr/cvz035>.
- [3] I. Goodfellow, Y. Bengio, A. Courville, and Y. Bengio, *Deep learning* (no. 2). MIT press Cambridge, 2016.
- [4] B. Li *et al.*, "Machine learning in vascular surgery: A systematic review and critical appraisal," *npj Digital Medicine*, vol. 5, no. 1, p. 7, 2022/01/19 2022, <https://doi.org/10.1038/s41746-021-00552-y>.
- [5] C. Boyd *et al.*, "Machine learning quantitation of cardiovascular and cerebrovascular disease: A systematic review of clinical applications," *Diagnostics*, vol. 11, no. 3, p. 551, 2021, <https://doi.org/10.3390/diagnostics11030551>.
- [6] A. Triantafyllidis *et al.*, "Deep learning in mhealth for cardiovascular disease, diabetes, and cancer: Systematic review," (in English), *JMIR Mhealth Uhealth*, Review vol. 10, no. 4, p. e32344, 2022, <https://doi.org/10.2196/32344>.
- [7] A. Ogunpola, F. Saeed, S. Basurra, A. M. Albarrak, and S. N. Qasem, "Machine learning-based predictive models for detection of cardiovascular diseases," *Diagnostics*, vol. 14, no. 2, p. 144, 2024, <https://doi.org/10.3390/diagnostics14020144>.
- [8] H. A. Al-Shaikh *et al.*, "Comprehensive evaluation and performance analysis of machine learning in heart disease prediction," *Scientific Reports*, vol. 14, no. 1, p. 7819, 2024/04/03 2024, <https://doi.org/10.1038/s41598-024-58489-7>.
- [9] C. Krittanawong *et al.*, "Machine learning prediction in cardiovascular diseases: A meta-analysis," *Scientific Reports*, vol. 10, no. 1, p. 16057, 2020/09/29 2020, <https://doi.org/10.1038/s41598-020-72685-1>.
- [10] P. Xiong, S. M.-Y. Lee, and G. Chan, "Deep learning for detecting and locating myocardial infarction by electrocardiogram: A literature review," (in English), *Frontiers in Cardiovascular Medicine*, Review vol. Volume 9 - 2022, 2022-March-25 2022, <https://doi.org/10.3389/fcvm.2022.860032>.
- [11] M. Moshawrab, M. Adda, A. Bouzouane, H. Ibrahim, and A. Raad, "Reviewing multimodal machine learning and its use in cardiovascular diseases detection," *Electronics*, vol. 12, no. 7, p. 1558, 2023, <https://doi.org/10.3390/electronics12071558>.
- [12] A. Abdellatif, H. Abdellatif, J. Kanesan, C. O. Chow, J. H. Chuah, and H. M. Ghenni, "An effective heart disease detection and severity level classification model using machine learning and hyperparameter optimization methods," *IEEE Access*, vol. 10, pp. 79974-79985, 2022, <https://doi.org/10.1109/ACCESS.2022.3191669>.
- [13] D. Gunning and D. Aha, "Darpa's explainable artificial intelligence (xai) program," *AI Magazine*, vol. 40, no. 2, pp. 44-58, 06/24 2019, <https://doi.org/10.1609/aimag.v40i2.2850>.
- [14] S. N. Payrovnaziri *et al.*, "Explainable artificial intelligence models using real-world electronic health record data: A systematic scoping review," *Journal of the American Medical Informatics Association*, vol. 27, no. 7, pp. 1173-1185, 2020, <https://doi.org/10.1093/jamia/ocaa053>.
- [15] A. Barredo Arrieta *et al.*, "Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai," *Information Fusion*, vol. 58, pp. 82-115, 2020/06/01/ 2020, <https://doi.org/10.1016/j.inffus.2019.12.012>.

- [16] T. Miller, "Explanation in artificial intelligence: Insights from the social sciences," *Artificial Intelligence*, vol. 267, pp. 1-38, 2019/02/01/ 2019, <https://doi.org/10.1016/j.artint.2018.07.007>.
- [17] M. R. Islam, M. U. Ahmed, S. Barua, and S. Begum, "A systematic review of explainable artificial intelligence in terms of different application domains and tasks," *Applied Sciences*, vol. 12, no. 3, p. 1353, 2022, <https://doi.org/10.3390/app12031353>.
- [18] S. Ali, F. Akhlaq, A. S. Imran, Z. Kastrati, S. M. Daudpota, and M. Moosa, "The enlightening role of explainable artificial intelligence in medical & healthcare domains: A systematic literature review," *Computers in Biology and Medicine*, vol. 166, p. 107555, 2023/11/01/ 2023, <https://doi.org/10.1016/j.compbiomed.2023.107555>.
- [19] J. D. Kelleher, *Deep learning*. MIT press, 2019.
- [20] J. Krohn, G. Beyleveld, and A. Bassens, *Deep learning illustrated: A visual, interactive guide to artificial intelligence*. Addison-Wesley Professional, 2019.
- [21] M. T. Ribeiro, S. Singh, and C. Guestrin, ""Why should i trust you?": Explaining the predictions of any classifier," presented at the Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, San Francisco, California, USA, 2016. [Online]. Available: <https://doi.org/10.1145/2939672.2939778>.
- [22] S. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," 2017, <https://doi.org/10.48550/arXiv.1705.07874>.
- [23] A. Janosi, W. Steinbrunn, M. Pfisterer, and R. Detrano. *Heart disease*, doi: <https://doi.org/10.24432/C52P4X>.
- [24] N. Chawla, K. Bowyer, L. Hall, and W. Kegelmeyer, "Smote: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321-357, 06/01 2002, <https://doi.org/10.1613/jair.953>.
- [25] J. Heaton, I. Goodfellow, Y. Bengio, and A. Courville, "Deep learning," *Genetic Programming and Evolvable Machines*, vol. 19, no. 1, pp. 305-307, 2018/06/01 2018, <https://doi.org/10.1007/s10710-017-9314-z>.