

Penerapan Metode XAI-SHAP pada Algoritma CatBoost
untuk Identifikasi Faktor Risiko Gangguan Tidur
Berdasarkan Metrik Gaya Hidup

JUDUL	Penerapan Metode XAI-SHAP pada Algoritma CatBoost untuk Identifikasi Faktor Risiko Gangguan Tidur Berdasarkan Metrik Gaya Hidup
Rumusan Masalah	Bagaimana penerapan <i>Shapley Additive exPlanations</i> (SHAP) yang merupakan bagian dari <i>Explainable AI</i> (XAI) pada algoritma CatBoost dapat menghasilkan model klasifikasi risiko gangguan tidur yang transparan, sekaligus mampu mengidentifikasi faktor-faktor gaya hidup digital yang paling berkontribusi terhadap munculnya gangguan tersebut secara akurat dan dapat diinterpretasikan?
Latar Belakang	Gangguan tidur telah berkembang menjadi salah satu tantangan kesehatan global yang paling relevan di era modern. Kondisi ini dikaitkan dengan peningkatan risiko penyakit kronis. Mulai dari gangguan kardiovaskular, diabetes tipe 2, hingga depresi klinis yang pada akhirnya menekan produktivitas individu dan membebani sistem layanan kesehatan secara luas. Yang menarik, sebagian besar pemicunya bersifat perilaku dan terukur, antara lain durasi paparan layar sebelum tidur, pola konsumsi kafein, intensitas tekanan kerja, hingga ritme aktivitas fisik harian. Studi yang melibatkan 20.645 mahasiswa di Provinsi Fujian membuktikan bahwa variabel-variabel gaya hidup ini adalah prediktor nyata yang dapat dipetakan secara kuantitatif menggunakan <i>machine learning</i> (Lin et al., 2025). Temuan tersebut membuka peluang konkret untuk membangun sistem deteksi dini berbasis data gaya hidup yang mampu mengklasifikasikan risiko gangguan tidur secara personal dan proaktif. Membangun sistem semacam itu menuntut algoritma yang tidak sekadar akurat, tetapi juga mampu menangani karakteristik data gaya hidup yang kaya akan dimensi heterogen, yaitu perpaduan antara variabel numerik seperti detak jantung dan BMI, dengan variabel kategorikal seperti jenis pekerjaan, kronotipen, dan kondisi kesehatan mental. Kehadiran fitur kategorikal dalam jumlah besar justru menjadi titik lemah banyak algoritma konvensional yang memerlukan <i>encoding</i> manual, prosedur yang rentan menimbulkan bias. CatBoost (<i>Categorical Boosting</i>) dirancang untuk mengatasi masalah ini dengan memproses fitur kategorikal secara langsung melalui mekanisme <i>ordered target statistics</i>. Keunggulan ini terbukti nyata; Taher & Ayon (2024) melaporkan akurasi 93,80% pada pendekatan <i>gradient boosting</i> untuk klasifikasi gangguan tidur, melampaui Random Forest dan AdaBoost. CatBoost dipilih bukan semata karena performanya, melainkan karena kesesuaiannya yang organik dengan struktur data gaya hidup yang kompleks. Namun, akurasi prediksi yang tinggi saja tidak cukup untuk menjadikan sebuah model layak digunakan dalam pengambilan keputusan medis. Inilah paradoks terbesar <i>machine learning</i> modern; semakin kompleks model, semakin sulit prediksinya untuk dipahami manusia. CatBoost, seperti algoritma <i>ensemble</i> berbasis pohon lainnya, beroperasi sebagai <i>black box</i> yang menghasilkan keputusan dari ratusan pohon yang bekerja paralel tanpa menjelaskan mengapa seseorang dikategorikan berisiko tinggi. Kondisi ini bukan sekadar masalah teknis; ia menyentuh dimensi etika dan regulasi yang fundamental dalam penerapan AI di dunia kesehatan. Sadeghi et al. (2024) menegaskan bahwa ketidakmampuan model menjelaskan prediksinya menjadi penghalang utama adopsi AI di klinik, karena dokter dan pasien membutuhkan justifikasi logis sebelum mengambil tindakan medis. Atas dasar itulah, <i>Explainable AI</i> (XAI) diposisikan sebagai komponen inti dalam penelitian ini.

	Perkembangan XAI dalam satu dekade terakhir telah melahirkan metode-metode yang mampu membuka selubung <i>black box</i> dan mengubah output model menjadi penjelasan yang bermakna bagi tenaga kesehatan. Alih-alih sekadar memberikan hasil prediksi, XAI memetakan kontribusi nyata setiap variabel input terhadap keputusan yang dihasilkan memungkinkan tenaga kesehatan memahami bukan hanya <i>apa</i> yang diprediksi, tetapi <i>mengapa</i> prediksi itu terbentuk. Keberhasilan pendekatan ini telah dibuktikan secara konkret oleh Emhandyksa & Afifah (2026), yang menggunakan XAI berbasis <i>feature importance</i> untuk membangun peta risiko penyakit jantung yang dapat dibaca langsung oleh tenaga kesehatan tanpa latar belakang teknis dalam <i>machine learning</i>. Preseden dari domain kardiovaskular ini secara logis menunjuk peluang yang setara di domain gangguan tidur, mengingat variabilitas dan kompleksitas faktor gaya hidup yang jauh lebih kaya dan multidimensional di dalamnya. Di antara berbagai metode XAI yang tersedia, <i>Shapley Additive exPlanations</i> (SHAP) dipandang paling relevan dan memiliki fondasi matematis paling kokoh untuk model berbasis pohon seperti CatBoost. Berlandaskan teori nilai Shapley dari permainan koalisi, SHAP menghitung kontribusi marginal setiap fitur secara adil dengan mempertimbangkan seluruh kombinasi fitur yang mungkin. Keunikannya adalah kemampuan bekerja di dua level sekaligus: secara <i>global</i> merangkum pola risiko di seluruh populasi, secara <i>lokal</i> menjelaskan prediksi spesifik per individu. Srinivasu et al. (2024) telah memvalidasi bahwa integrasi CatBoost–SHAP menghasilkan interpretabilitas superior dalam diagnosis medis. Berpijak pada validasi tersebut, penelitian ini menerapkan kombinasi ini untuk membedah dan meranking faktor gaya hidup digital yang paling berkontribusi terhadap risiko gangguan tidur yang menghasilkan bukan sekadar model prediktif, melainkan instrumen pemahaman yang dapat digunakan untuk intervensi berbasis bukti.
Tinjauan Pustaka	1. Taher & Ayon (2024) menganalisis klasifikasi gangguan tidur menggunakan Random Forest, AdaBoost, dan Gradient Boosting dengan akurasi 93,80%. Penelitian ini sangat relevan, namun menyisakan celah utama: tidak menerapkan metode XAI, sehingga model tersebut masih berupa <i>black-box</i> yang sulit diinterpretasikan. 2. Lin et al. (2025) memetakan kualitas tidur mahasiswa menggunakan algoritma ANN dan Gradient Boosting Trees. Celah pada penelitian ini adalah kurangnya transparansi model (interpretabilitas) yang sebenarnya dapat diselesaikan dengan pendekatan Explainable AI (XAI). 3. Sadeghi et al. (2024) mengkaji urgensi penggunaan Explainable AI di sektor kesehatan. Penelitian ini menegaskan pentingnya XAI untuk membangun kepercayaan praktisi medis terhadap algoritma cerdas, namun belum ada implementasi spesifik XAI SHAP untuk prediksi gangguan tidur berbasis gaya hidup. 4. Emhandyksa & Afifah (2026) menerapkan XAI berbasis Feature Importance untuk deteksi dini penyakit jantung. Penelitian ini membuktikan efektivitas XAI di dunia medis, namun fokus domainnya adalah kardiovaskular, bukan analisis pola tidur dan gaya hidup digital. 5. Srinivasu et al. (2024) mengimplementasikan CatBoost yang dikombinasikan dengan metode SHAP untuk analisis kanker payudara. Penelitian ini memvalidasi kehebatan kombinasi CatBoost dan SHAP untuk data rekam medis, namun penerapannya belum mencakup analisis di domain spesifik deteksi dini gangguan tidur.
Referensi/ Daftar Pustaka	Taher, A., & Ayon, W. I. Z. (2024). Exploring Sleep Disorders: A Comparative Analysis of Machine Learning Algorithms on Sleep Health and Lifestyle Data. 2024 IEEE PEEIACON.

	Lin, Y., et al. (2025). Evaluation of sleep quality and influencing factors among medical and non-medical students using machine learning techniques. <i>Frontiers in Psychiatry</i>, 16, 1533875. Sadeghi, Z., et al. (2024). A review of Explainable Artificial Intelligence in healthcare. <i>Computers and Electrical Engineering</i>, 118, 109370. Emhandyksa, M., & Afifah, I. N. (2026). Metode Explainable Artificial Intelligence (XAI) Berbasis Feature Importance Untuk Deteksi Dini Penyakit Jantung. <i>Journal of Sustainable Supply Chain and Technology</i>, 1(1), 68-79. Srinivasu, P. N., et al. (2024). XAI-driven CatBoost multi-layer perceptron neural network for analyzing breast cancer. <i>Scientific Reports</i>.
--	--