

**OPTIMASI PREDIKSI RISIKO SERANGAN JANTUNG
MENGUNAKAN K-MEANS CLUSTERING DAN XGBOOST UNTUK
IDENTIFIKASI POLA PASIEN BERISIKO TINGGI**



SKRIPSI

Diajukan Sebagai Salah Satu Syarat untuk Memperoleh
Gelar Sarjana Strata 1 (S.1) Program Studi Teknik Informatika
Fakultas Sains dan Teknologi
Universitas Islam Nahdlatul Ulama Jepara

Oleh:

**DIMAS MAULANA FIRMANSYAH
NIM: 211240001121**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NAHDLATUL ULAMA JEPARA
2025**

ABSTRAK

Dimas Maulana Firmansyah, 211240001121, Optimasi Prediksi Risiko Serangan Jantung Menggunakan K-Means Clustering dan XGBoost untuk Identifikasi Pola Pasien Berisiko Tinggi, 2025.

Penelitian ini bertujuan untuk mengoptimalkan prediksi risiko serangan jantung pada pasien berisiko tinggi dengan menggabungkan algoritma K-Means Clustering dan XGBoost. Dataset yang digunakan berasal dari platform Kaggle dengan total 158.355 data pasien dan 28 atribut kesehatan. Algoritma K-Means digunakan untuk mengelompokkan pasien ke dalam tiga klaster utama berdasarkan kemiripan atribut medis, sedangkan algoritma XGBoost diterapkan secara khusus pada klaster risiko tinggi untuk melakukan klasifikasi lebih lanjut terhadap kemungkinan terjadinya serangan jantung. Tahapan preprocessing data meliputi label encoding dan normalisasi, dilanjutkan dengan tuning hyperparameter untuk meningkatkan performa model.

Hasil evaluasi menunjukkan bahwa model XGBoost mampu memprediksi risiko serangan jantung dengan akurasi sebesar 72.45% pada kelompok pasien risiko tinggi. Pendekatan integratif ini memberikan gambaran yang lebih terarah mengenai pola risiko pada populasi pasien, serta mendukung pemanfaatan metode machine learning dalam sistem deteksi dini berbasis data. Dengan demikian, kombinasi K-Means dan XGBoost dapat berfungsi sebagai fondasi awal dalam pengembangan sistem prediksi kesehatan yang efisien dan data-driven.

Kata kunci: serangan jantung, K-Means, Clustering, XGBoost, prediksi risiko, klasifikasi medis.

ABSTRACT

Dimas Maulana Firmansyah, 211240001121, Optimization of Heart Attack Risk Prediction Using K-Means Clustering and XGBoost to Identify High-Risk Patient Patterns, 2025.

This study aims to optimize the prediction of heart attack risk in high-risk patients by combining the K-Means Clustering and XGBoost algorithms. The dataset used comes from the Kaggle platform with a total of 158,355 patient data and 28 health attributes. The K-Means algorithm is used to group patients into three main clusters based on the similarity of medical attributes, while the XGBoost algorithm is applied specifically to the high-risk cluster to further classify the possibility of a heart attack. The data preprocessing stages include label encoding and normalization, followed by hyperparameter tuning to improve model performance. The evaluation results show that the XGBoost model is able to predict the risk of heart attack with an accuracy of 72.45% in high-risk patient groups. This integrative approach provides a more focused picture of the risk patterns in the patient population, and supports the use of machine learning methods in data-based early detection systems. Thus, the combination of K-Means and XGBoost can serve as an initial foundation in the development of an efficient and data-driven health prediction system.

Keywords: *heart attack, K-Means, Clustering, XGBoost, risk prediction, medical classification.*

PERNYATAAN KEASLIAN

Yang bertanda tangan dibawah ini :

Nama : Dimas Maulana Firmansyah
NIM : 211240001121
Program Studi : Teknik Informatika

Saya menyatakan dengan penuh kejujuran dan tanggungjawab, bahwa Skripsi yang saya susun sebagai salah satu syarat untuk memperoleh gelar Sarjana Universitas Islam Nahdlatul Ulama Jepara merupakan hasil karya saya sendiri dan belum pernah diajukan sebagai pemenuhan persyaratan untuk memperoleh gelar Sarjana dari Perguruan Tinggi lain.

Adapun bagian-bagian tertentu dalam penulisan Skripsi yang saya kutip dari karya orang lain telah dituliskan sumbernya secara jelas dengan norma, kaidah, dan etika penulisan ilmiah.

Selanjutnya saya bersedia menerima sanksi dari Fakultas Sains dan Teknologi program studi Teknik Informatika UNISNU Jepara apabila di kemudian hari ditemukan ketidakbenaran dari pernyataan ini.

Jepara, 23 Juni 2025




Dimas Maulana Firmansyah

PERSETUJUAN PEMBIMBING

Yang bertanda tangan dibawah ini menyatakan telah menyetujui skripsi mahasiswa:

Nama : Dimas Maulana Firmansyah
Nim : 211240001121
Program Studi : Teknik Informatika
Judul : Optimasi Prediksi Risiko Serangan Jantung Menggunakan K-Means Clustering dan XGBoost untuk Identifikasi Pola Pasien Berisiko Tinggi

Untuk diujikan dalam sidang Skripsi program sarjana (S1).

Nama	Tanggal	Tanda Tangan
<u>Teguh Tamrin, S.Kom, M.Kom</u> NIDN. 0620127603 (Pembimbing 1)	23 Juni 2025	
<u>Akhmad Khanif Zyen, S.Kom, M.Kom.</u> NIDN. 0621048602 (Pembimbing 2)	22 Juni 2025	

PENGESAHAN

Skripsi mahasiswa di bawah ini:

Nama : DIMAS MAULANA FIRMANSYAH
NIM : 211240001121
Program Studi : Teknik Informatika
Judul : OPTIMASI PREDIKSI RISIKO SERANGAN JANTUNG
MENGUNAKAN K-MEANS CLUSTERING DAN
XGBOOST UNTUK IDENTIFIKASI POLA PASIEN
BERISIKO TINGGI

telah diujikan dan dipertahankan dalam sidang oleh Majelis penguji Fakultas Sains dan Teknologi Universitas Islam Nahdlatul Ulama (UNISNU) Jepara dan dinyatakan **LULUS** pada :


Rabu, 02 Juli 2025


Selanjutnya dapat diterima sebagai syarat guna memperoleh gelar Sarjana Program Studi Teknik Informatika pada Fakultas Sains dan Teknologi UNISNU Jepara Tahun Akademik 2024/2025

Jepara, 02 Juli 2025

Ketua Sidang


Sekretaris Sidang



Teguh Tamrin, S.Kom, M.Kom.
NIY. 4 764220 17 235


Akhmad Khanif Zyen, S.Kom.,
M.Kom.
NIY. 3 860421 13 092

Penguji I.

Penguji II.


R. Hadapiningradja Kusumodestoni,
S.Kom., M.Kom.
NIY. 3 861222 14 139


Harminto Mulyo, S.Kom. M.Kom.
NIY. 3 820204 13 096

Mengetahui

Dekan Fakultas Sains dan Teknologi


Dr. Ir. H. Mochammad Qasruddin, S.T., M.T., IPM., ASEAN Eng.
NIY. 3 820604 13 093

HALAMAN PERSEMBAHAN

Skripsi ini kupersembahkan pada:

1. Tuhan Yang Maha Esa, Sumber segala kekuatan, cahaya di setiap langkah, dan penentu segala takdir. Tanpa rahmat dan hidayah-Mu, tak mungkin semua ini dapat terwujud.
2. Ibuku tercinta, Hj. Sri Marwati , Yang doanya tak pernah putus, peluknya adalah rumah, dan kasih sayangnya adalah pelita yang menuntunku dalam gelap.
3. Almarhum Ayahku tercinta, H. Ali Hamka, Yang kerja keras dan pengorbanannya menjadi inspirasi dan semangat dalam setiap perjalanan hidupku.
4. Adikku tersayang, Ahmad Farhan Hamka dan Arfan Naufal Yahya, Yang senyum polos dan canda tawanya menjadi penguat di kala lelah mendera.
5. Kakek H. Jasmo dan Nenek Hj. Siti Aminah, Yang telah mendorong diriku untuk sekolah setinggi-tingginya serta menanamkan nilai-nilai kehidupan sejak aku kecil, dengan penuh kasih dan doa.
6. Kakek H. Nur Hadi dan Nenek Zumrotun, Yang telah menanamkan nilai-nilai kehidupan sejak aku kecil, dengan penuh kasih dan doa.
7. Seluruh keluarga besarku, Atas dukungan, doa, dan cinta yang selalu mengiringi langkahku, tanpa pamrih dan tanpa henti.
8. Dosen Pembimbing Akademik, Bapak Teguh Tamrin, S.Kom, M.Kom., Atas arahan, perhatian, dan motivasi yang diberikan sejak awal masa studi hingga kini.
9. Dosen Pembimbing Skripsi, Bapak Akhmad Khanif Zyen, S.Kom, M.Kom, Yang telah dengan sabar membimbing, mengoreksi, dan memotivasi saya dalam proses penyusunan skripsi ini.
10. Teman seperjuangan Prodi Teknik Informatika Angkatan 2021, Untuk kebersamaan, dukungan, dan semangat yang tak ternilai. Kalian adalah bagian dari cerita indah dalam hidupku.

11. Sekali lagi untuk Almarhum Ayah saya, terimakasih sudah mendidikku untuk menjadi orang yang lebih baik, Yang selalu mengingatkanku untuk membaca QS. Al Waqiah dan QS. Al Mulk, Meskipun Kehilanganmu menjadi pukulan terbesar untukku tapi kupastikan diri ini bangkit.
12. Dan terakhir, untuk diriku sendiri, Dimas Maulana Firmansyah, Terima kasih telah bertahan, meski berkali-kali ingin menyerah. Terima kasih telah percaya, meski banyak keraguan. Ini adalah bukti bahwa kamu bisa.

HALAMAN MOTTO

“Bukan soal seberapa cepat sampai, tapi seberapa konsisten melangkah.”

(Dimas Maulana Firmansyah)

" Yakin, Ikhtiar, dan Tawakal—kemenangan itu milik mereka yang bersabar."

(QS. Al-Imran: 200)

KATA PENGANTAR

Dengan memanjatkan puji dan syukur kepada Allah SWT yang telah berkenan melimpahkan rahmat, taufiq, dan hidayah-Nya, sehingga penulis dapat menyelesaikan penelitian dengan judul: **“Optimasi Prediksi Risiko Serangan Jantung Menggunakan K-Means Clustering dan XGBoost untuk Identifikasi Pola Pasien Berisiko Tinggi”** dengan baik.


Pada kesempatan ini penulis dengan rasa bangga dan bahagia menghaturkan ucapan terima kasih yang sebesar-besarnya kepada:

1. Rektor Universitas Islam Nahdlatul Ulama (UNISNU) Jepara (Prof. Dr. H. Abdul Djamil, M.A.) yang telah menyampaikan ilmu pengetahuan sehingga dapat menambah dan menjadikan penulis bersemangat dalam menempuh studi.
2. Dekan Fakultas Sains dan Teknologi Universitas Islam Nahdlatul Ulama (UNISNU) Jepara (Dr. Ir. H. Mochammad Qomaruddin, S.T., M.T., IPM., ASEAN Eng.) yang telah memberikan fasilitas dan kemudahan sehingga dapat menyelesaikan perkuliahan dan artikel ilmiah/tugas akhir dengan baik.
3. Ketua program studi Teknik Informatika Fakultas Sains dan Teknologi Universitas Islam Nahdlatul Ulama (UNISNU) Jepara (Gentur Wahyu Nyipto Wibowo, S.Kom, M.Kom.) yang telah memberikan arahan dan kemudahan sehingga dapat menyelesaikan perkuliahan dan skripsi dengan baik.
4. Pembimbing skripsi 1. Teguh Tamrin, S.Kom, M.Kom, 2. Akhmad Khanif Zyen, S.Kom, M.Kom. yang dengan segala kesabaran telah berkenan memberikan arahan kepada peneliti hingga menjadi lebih sempurna dalam menyelesaikan skripsi ini.
5. Para Dosen Program studi Teknik Informatika yang tidak bisa penulis sebutkan satu persatu yang telah banyak memberikan sentuhan ilmu pengetahuan yang tidak ternilai harganya.
6. Orang tua yang senantiasa memanjatkan doa demi keberhasilan penulis.

Peneliti menyadari, bahwa apa yang dituangkan dan disajikan ini masih banyak kekurangan dan kekhilafan. Tetapi peneliti berharap mudah-mudahan skripsi/tugas akhir ini bisa menjadikan sesuatu yang bermanfaat terutama bagi peneliti sendiri dan umumnya kepada para pembaca yang sudi melihat dan membacanya.

Jepara, 23 Juni 2025

Penulis,

A handwritten signature in black ink, consisting of a stylized 'D' followed by a series of loops and a horizontal line at the end.

Dimas Maulana Firmansyah

DAFTAR ISI

HALAMAN JUDUL	i
ABSTRAK	ii
<i>ABSTRACT</i>	iii
PERNYATAAN KEASLIAN	iv
PERSETUJUAN PEMBIMBING.....	v
PENGESAHAN	vi
HALAMAN PERSEMBAHAN	vii
HALAMAN MOTTO.....	ix
KATA PENGANTAR	x
DAFTAR ISI.....	xii
DAFTAR GAMBAR	xvi
DAFTAR TABEL	xvii
BAB I PENDAHULUAN	1
1.1. Latar Belakang.....	1
1.2. Rumusan Masalah	7
1.3. Tujuan Penelitian	7
1.4. Manfaat Penelitian.....	8
1.4.1. Manfaat Akademik	8
1.4.2. Manfaat Praktis.....	8
BAB II LANDASAN TEORI	10
2.1. Kajian Teori.....	10
2.1.1. Penyakit Jantung	10
2.1.2. Data Mining	10

2.1.3.	Clustering.....	11
2.1.4.	K-Means.....	12
2.1.4.1.	Mekanisme Kerja Algoritma K-Means.....	13
2.1.5.	Extreme Gradient Boosting (XGBoost)	15
2.1.5.1.	Mekanisme Kerja Algoritma XGBoost.....	16
2.1.6.	Python.....	22
2.1.7.	Google Colab.....	22
2.1.8.	Overfitting.....	23
2.1.9.	Knowledge Discovery in Databases (KDD).....	24
2.1.10.	Confusion Matrix	24
2.1.11.	Accuracy.....	25
2.1.12.	Precision	25
2.1.13.	Recall	26
2.1.14.	F1-Score	26
2.1.15.	Hyperparameter Tuning	26
2.2.	Hasil Penelitian Yang Relevan	27
2.3.	Kerangka Berpikir	31
2.4.	Hipotesis Penelitian	31
BAB III METODE PENELITIAN.....		33
3.1.	Jenis dan Pendekatan Penelitian.....	33
3.1.1.	Jenis Penelitian	33
3.1.2.	Pendekatan Penelitian	33
3.2.	Waktu dan Tempat Penelitian.....	34
3.2.1.	Waktu Penelitian.....	34
3.2.2.	Tempat Penelitian	34

3.3.	Populasi dan Sampel Penelitian	36
3.3.1.	Populasi Penelitian	36
3.3.2.	Sampel Penelitian	37
3.4.	Instrumen Penelitian	38
3.4.1.	Studi Literatur.....	38
3.4.2.	Analisis Data	39
3.4.3.	Visualisasi Model.....	39
3.5.	Teknik Pengumpulan Data	41
3.6.	Teknik Analisis Data	43
3.6.1.	Pre Prosesing Data	43
3.6.2.	Training Data dan Testing Data	45
3.6.3.	Modelling	46
3.6.4.	Evaluasi Model	46
3.6.5.	Analisis Feature Importance.....	47
BAB IV	HASIL DAN ANALISIS.....	48
4.1.	Hasil Penelitian	48
4.1.1.	Penyesuaian Bahasa Atribut dan Nilai Kategorikal Dataset 49	
4.1.2.	Import Library dan Dataset.....	50
4.1.3.	Menampilkan Informasi Umum Dataset	53
4.1.4.	Menghapus Kolom Tidak Relevan	55
4.1.5.	Encoding dan Normalisasi Data	56
4.1.6.	Clustering dengan Algoritma K-Means	58
4.1.7.	Seleksi Data Cluster Risiko Tinggi.....	61
4.1.8.	Klasifikasi dengan Algoritma XGBoost.....	62
4.1.9.	Analisis Tambahan	64

4.2.	Analisis Hasil Penelitian.....	73
4.2.1.	Evaluasi Model	74
4.2.2.	Interpretasi Temuan	75
4.2.3.	Kaitan dengan Hipotesis dan Penelitian Sebelumnya	77
BAB V	PENUTUP	79
5.1.	Simpulan.....	79
5.2.	Saran	80
DAFTAR PUSTAKA		81
DAFTAR LAMPIRAN.....		86
	Lampiran 1 Dataset Heart Attack Prediction In Indonesia.....	86
	Lampiran 2 Hasil Clustering K-Means Risiko Tinggi.....	86
	Lampiran 3 Hasil Klasifikasi Menggunakan Xgboost	86

DAFTAR GAMBAR

Gambar 1. Arsitektur Algoritma XGBoost	20
Gambar 2. Kerangka Berpikir.....	31
Gambar 3. Dataset Heart Attack Prediction In Indonesia.....	35
Gambar 4. Penyesuaian Bahasa Atribut dan Nilai Kategori.....	49
Gambar 5. Import Library dan Dataset	50
Gambar 6. Informasi Umum Dataset.....	53
Gambar 7. Hapus Kolom Atribut Yang Tidak Digunakan	55
Gambar 8. Proses Encoding dan Normalisasi Data	56
Gambar 9. Clustering Dengan Algoritma K-Means.....	58
Gambar 10. Grafik Bar Clustering dengan K-Means	60
Gambar 11. Data Pasien dari Cluster Risiko Tinggi	61
Gambar 12. Hasil Klasifikasi dengan XGBoost	62
Gambar 13. Distribusi Usia pada Cluster Risiko Tinggi.....	66
Gambar 14. Rata-rata Risiko Serangan Jantung per Kelompok Usia	67
Gambar 15. Heatmap Indikator Risiko Serangan Jantung Berdasarkan Kelompok Usia (Cluster Risiko Tinggi)	69
Gambar 16. Pentingnya Fitur dalam Prediksi Serangan Jantung (Feature Importance XGBoost).....	71

DAFTAR TABEL

Tabel 1. Rumus K-Means	15
Tabel 2. Atribut dataset Heart Attack Prediction In Indonesia	42
Tabel 3. Atribut Yang Digunakan	44

BAB I

PENDAHULUAN

1.1. Latar Belakang

Henti jantung, atau cardiac arrest, merupakan kondisi medis darurat yang terjadi ketika jantung tiba-tiba berhenti memompa darah. Ketika hal ini terjadi, aliran darah ke otak dan organ-organ vital lainnya terhenti, yang dapat menyebabkan kematian mendadak bila tidak segera ditangani (Patel et al., 2021). Tanpa intervensi medis yang cepat, kematian bisa terjadi hanya dalam hitungan menit. Pada umumnya, henti jantung disebabkan oleh gangguan pada sistem kelistrikan jantung, yang mengakibatkan irama jantung abnormal seperti ventricular tachycardia atau ventricular fibrillation. Selain itu, beberapa kasus juga dipicu oleh detak jantung yang sangat lambat atau bradikardia. Menurut data, sekitar 50% kasus henti jantung menimpa individu yang sebelumnya tidak mengetahui bahwa mereka memiliki gangguan jantung. (Siregar et al., 2023)

Waktu kemunculan serangan jantung dan kecepatan dalam memberikan penanganan yang tepat sangat berpengaruh terhadap tingkat morbiditas dan mortalitas. Pada pasien yang mengalami serangan jantung, keterlambatan dalam mendapatkan perawatan darurat di rumah sakit dapat memperburuk kondisi dan menurunkan peluang kesembuhan. Setiap tahunnya, banyak orang kehilangan nyawa atau mengalami dampak jangka panjang karena tidak segera diberikan penanganan yang sesuai terhadap gejala serangan jantung. Serangan jantung biasanya muncul sebagai nyeri dada atau rasa tidak nyaman yang dapat menyebar ke lengan, leher, rahang, dan punggung serta disertai dengan kesulitan bernapas dan berkeringat. Selain itu, pada beberapa pasien diabetes atau lanjut usia, serangan jantung terkadang dapat terjadi secara diam-diam dan dengan gejala yang tidak khas, seperti nyeri perut. Keterlambatan ini dapat terjadi karena kurangnya kesadaran akan gejala serangan jantung, yang kemudian meningkatkan angka kematian. Pasien lain menunda mungkin karena penyangkalan terhadap

kondisi, ketakutan, dan kepercayaan yang tidak beralasan, dan beberapa pasien mungkin takut mendapat malu jika mereka berobat ke rumah sakit dengan tanpa ada keperluan yang pasti. (Pengabdian Magister Pendidikan IPA et al., 2023)

Selain pentingnya mengenali tanda-tanda serangan jantung, masyarakat juga perlu memahami berbagai faktor pemicunya. Dengan mengetahui faktor-faktor tersebut, individu dapat mengambil langkah pencegahan untuk mengurangi risiko terkena serangan jantung. Beberapa faktor yang meningkatkan risiko antara lain adalah pertambahan usia, tekanan darah tinggi (hipertensi), kebiasaan merokok, kadar kolesterol yang tinggi, obesitas, penyakit diabetes, kurangnya aktivitas fisik, paparan polusi udara, stres, dan lainnya. (Rahayu et al., 2020)

Dengan meningkatnya kompleksitas data dalam bidang kesehatan, penggunaan teknik data mining menjadi semakin krusial dalam upaya pencegahan dan penanganan penyakit jantung. Salah satu metode yang dapat dimanfaatkan adalah K-Means Clustering, yang mampu mengelompokkan pasien berdasarkan karakteristik kesehatan seperti tekanan darah, kadar kolesterol, dan kebiasaan merokok. Melalui pengelompokan ini, tenaga medis dapat menyusun strategi intervensi yang lebih terfokus terhadap pasien yang masuk dalam kategori risiko tinggi. Sebagai ilustrasi, studi yang dilakukan oleh (Wala et al., 2024) membuktikan bahwa algoritma K-Means efektif dalam mengelompokkan data pasien untuk keperluan analisis risiko penyakit, termasuk dalam konteks penyakit jantung.

Di era digital saat ini, transformasi teknologi dalam bidang kesehatan mengalami percepatan yang signifikan, terutama dalam konteks pengolahan data besar (big data) dan pemanfaatan kecerdasan buatan (Artificial Intelligence/AI). Data pasien yang dulunya hanya bersifat administratif kini dapat dimanfaatkan sebagai sumber informasi prediktif untuk mendeteksi potensi risiko kesehatan. Penerapan machine learning tidak hanya terbatas pada bidang komputasi, tetapi juga telah menjelma menjadi alat bantu penting dalam pengambilan keputusan medis, khususnya dalam diagnosis dan

prediksi penyakit kronis seperti jantung. Keunggulan utama dari metode ini adalah kemampuannya untuk mempelajari pola tersembunyi dalam data yang tidak dapat dikenali secara langsung oleh tenaga medis melalui observasi manual. Dengan kata lain, algoritma seperti K-Means dan XGBoost dapat menjembatani keterbatasan analisis konvensional melalui pendekatan otomatis dan berbasis data, yang pada akhirnya mampu mendukung layanan kesehatan yang lebih personal dan preventif.

Lebih lanjut, integrasi antara algoritma unsupervised learning dan supervised learning dalam satu model hybrid mencerminkan pendekatan inovatif yang responsif terhadap kompleksitas data klinis. Hal ini penting karena data kesehatan sering kali bersifat heterogen dan memiliki tingkat ketidakpastian yang tinggi. Dengan memanfaatkan clustering di tahap awal, model dapat menyaring dan memetakan populasi pasien ke dalam kelompok-kelompok homogen, sehingga proses klasifikasi selanjutnya menjadi lebih terfokus dan akurat. Strategi semacam ini tidak hanya relevan untuk deteksi dini serangan jantung, tetapi juga berpotensi untuk dikembangkan lebih luas dalam konteks penyakit lain seperti kanker, stroke, dan gangguan metabolik. Oleh karena itu, penelitian ini menempatkan dirinya pada posisi yang strategis dalam mengisi kesenjangan antara data yang melimpah dan kebutuhan pengambilan keputusan klinis yang cepat dan tepat sasaran.

Meningkatnya jumlah kasus penyakit jantung di berbagai belahan dunia, termasuk Indonesia, menjadi tantangan besar dalam sistem pelayanan kesehatan. Organisasi Kesehatan Dunia (WHO) mencatat bahwa penyakit kardiovaskular merupakan penyebab kematian nomor satu secara global. Di Indonesia, beban ekonomi akibat penyakit jantung juga sangat signifikan, baik dari sisi biaya pengobatan maupun dampak kehilangan produktivitas kerja masyarakat. Oleh karena itu, pendekatan kuratif semata tidak lagi memadai. Diperlukan strategi berbasis pencegahan dan deteksi dini yang efektif, serta dapat menjangkau populasi luas secara cepat dan akurat. Teknologi machine learning menjadi alternatif yang menjanjikan karena mampu memproses data dalam jumlah besar dan memberikan hasil prediksi

dalam waktu yang jauh lebih singkat dibanding metode tradisional.

Selain itu, penerapan data mining dan machine learning dalam sistem informasi kesehatan juga sejalan dengan upaya global dalam membangun ekosistem *smart healthcare*. Konsep ini mendorong digitalisasi layanan medis dengan mengandalkan kecerdasan buatan untuk mendukung diagnosis berbasis data (data-driven diagnosis), prediksi risiko pasien, dan optimalisasi alokasi sumber daya rumah sakit. Dengan mengombinasikan K-Means dan XGBoost, penelitian ini turut berkontribusi dalam pengembangan sistem yang tidak hanya bersifat reaktif tetapi juga proaktif dalam menghadapi ancaman penyakit jantung. Hasil dari penelitian ini diharapkan dapat membuka peluang untuk diintegrasikan ke dalam sistem pendukung keputusan klinis (Clinical Decision Support System/CDSS), sehingga dapat memberikan rekomendasi medis secara real-time kepada tenaga kesehatan.

Clustering adalah teknik yang populer digunakan pada data mining. Teknik ini merupakan proses pengelompokan data menjadi beberapa cluster data berdasarkan kemiripan atribut-atribut yang dimiliki data (Haris Kurniawan et al., 2020). Pada penelitian ini, digunakan algoritma K-Means clustering. K-Means adalah Teknik pengelompokan data di mana atribut data dikelompokkan ke dalam partisi set data, kemudian ditetapkan ke dalam kelompok yang berbeda. (Wala & Umar, 2024)

K-Means Clustering adalah salah satu algoritma unsupervised learning yang digunakan untuk mengelompokkan data ke dalam beberapa cluster berdasarkan kesamaan karakteristiknya. Algoritma ini berfungsi untuk mengelompokkan objek dengan karakteristik serupa ke dalam satu kelompok (cluster) yang sama, sementara objek dengan karakteristik berbeda akan ditempatkan dalam kelompok yang berbeda. ("K-Means Clustering Algorithm: A Brief Review," 2021a)

Algoritma K-Means Clustering merupakan salah satu metode unsupervised learning yang paling banyak digunakan dalam berbagai bidang, termasuk medis dan diagnosis penyakit. Dalam konteks penelitian ini, K-Means berperan dalam mengelompokkan pasien berdasarkan tingkat risiko

serangan jantung, sehingga membantu tenaga medis dalam mengidentifikasi pola kesehatan pasien dan menerapkan intervensi lebih cepat.(Purba et al., 2022a)

Extreme Gradient Boosting atau XGBoost ialah salah satu metode supervised learning yang digunakan untuk klasifikasi maupun regresi. Algoritma ini merupakan sistem machine learning pada tree boosting yang dapat dioptimalkan untuk membangun pohon dengan skala lebih besar. Sebagai pengembangan dari Gradient Boosting, XGBoost adalah metode ensemble berbasis decision tree yang dirancang untuk mempercepat waktu proses, bahkan pada data berukuran besar. XGBoost bekerja dengan menggabungkan berbagai pengklasifikasi lemah menjadi model yang lebih kuat, melalui pelatihan berurutan menggunakan hasil klasifikasi sebelumnya, yang disebut residuals atau error.(Mayang Pratiwi & Mufidah, 2024)

XGBoost adalah algoritma berbasis gradient boosting decision tree (GBDT) yang telah terbukti sangat efektif dalam berbagai bidang, terutama dalam diagnosis dan prediksi penyakit medis. Dalam penelitian ini, XGBoost digunakan untuk meningkatkan akurasi prediksi pasien berisiko tinggi terkena serangan jantung dengan memanfaatkan hasil clustering dari K-Means. Dengan kombinasi ini, sistem deteksi dini dapat menjadi lebih akurat, efisien, dan dapat diandalkan, sehingga membantu tenaga medis dalam mengambil keputusan yang lebih cepat dan tepat.(Yang, 2024)

Dalam penelitian ini, perhatian difokuskan pada pemanfaatan algoritma K-Means Clustering untuk melakukan pengelompokan pasien berdasarkan sejumlah faktor risiko yang telah terbukti berhubungan dengan kejadian serangan jantung. Faktor-faktor tersebut meliputi usia, tekanan darah tinggi (hipertensi), kadar kolesterol, riwayat diabetes, pola konsumsi makanan, tingkat stres yang dialami, hingga kualitas tidur pasien. Untuk menjaga agar cakupan penelitian tetap spesifik dan terarah, data yang digunakan berasal dari dataset sekunder yang telah tersedia di platform Kaggle, sehingga penelitian ini tidak melibatkan proses pengumpulan data primer secara

langsung di lapangan. Dengan menggunakan dataset yang sudah tersedia, analisis data dapat difokuskan sepenuhnya pada proses pengolahan dan penerapan metode machine learning, yang diharapkan mampu menghasilkan model klasifikasi yang efektif dan akurat.

Beberapa penelitian sebelumnya telah mencoba menerapkan algoritma machine learning dalam konteks penyakit jantung. Salah satunya adalah studi oleh Wala et al. (2024) yang memanfaatkan metode K-Means Clustering untuk mengelompokkan pasien penyakit jantung ke dalam beberapa cluster berdasarkan atribut seperti tekanan darah dan jenis nyeri dada. Hasil penelitian tersebut menunjukkan bahwa K-Means efektif dalam mengidentifikasi pola-pola pasien berdasarkan tingkat risiko. Namun, penelitian tersebut belum dilanjutkan ke tahap klasifikasi risiko yang lebih dalam pada masing-masing cluster, khususnya terhadap kelompok risiko tinggi. Hal ini menunjukkan adanya celah penelitian, yaitu belum optimalnya pendekatan prediktif terhadap pasien dalam cluster risiko tinggi, yang padahal justru memerlukan penanganan lebih cepat dan akurat. Oleh karena itu, penelitian ini tidak hanya melakukan pengelompokan awal dengan K-Means, tetapi juga mengintegrasikannya dengan algoritma XGBoost untuk membangun model klasifikasi yang lebih tajam dan akurat, khususnya pada pasien yang telah teridentifikasi dalam cluster risiko tinggi. Pendekatan kombinasi ini diharapkan mampu menjawab kebutuhan identifikasi dini serta mendukung proses pengambilan keputusan medis berbasis data secara lebih efisien.

Meskipun penelitian ini merujuk pada studi Wala et al. (2024) dalam pemanfaatan metode K-Means Clustering, penting untuk dicatat bahwa dataset yang digunakan dalam penelitian ini berbeda. Penelitian ini menggunakan dataset sekunder yang berskala besar, yaitu sebanyak 158.355 data pasien dengan 28 atribut yang diambil dari sumber publik di platform Kaggle. Kompleksitas dan volume data yang lebih tinggi ini memberikan tantangan tersendiri dalam proses pengolahan dan analisis, sehingga pendekatan yang digunakan dalam penelitian ini difokuskan pada optimasi

prediksi risiko tinggi secara lebih efisien dan terarah. Dengan demikian, penelitian ini bukan hanya mengadopsi metode terdahulu, tetapi juga mengembangkan penerapannya dalam konteks data yang lebih besar dan representatif.

Setelah proses segmentasi pasien berdasarkan risiko dilakukan menggunakan K-Means, algoritma XGBoost diterapkan untuk mengklasifikasikan lebih lanjut pasien yang tergolong ke dalam kelompok berisiko tinggi. Langkah ini dilakukan untuk meningkatkan akurasi prediksi dan mendalami karakteristik pasien dalam klaster risiko tersebut. Kombinasi dari kedua pendekatan ini diharapkan dapat mempercepat proses identifikasi pasien rentan serangan jantung, sehingga informasi yang diperoleh bisa dimanfaatkan untuk mendukung pengambilan keputusan medis yang lebih cepat dan berbasis data. Selain itu, penerapan teknik analisis ini juga bertujuan untuk mendorong pemanfaatan data mining dan machine learning dalam bidang kesehatan, khususnya dalam upaya mengoptimalkan prediksi pada kelompok pasien berisiko tinggi dan mempercepat pendeteksian risiko, sehingga hasilnya dapat digunakan untuk mendukung proses pengambilan keputusan medis yang lebih cepat, tepat, dan berbasis analisis data.

1.2. Rumusan Masalah

Berdasarkan latar belakang masalah diatas, maka dapat diambil identifikasi masalah sebagai pokok permasalahan yaitu “Bagaimana penerapan K-Means Clustering dan XGBoost dapat meningkatkan akurasi dalam identifikasi pola pasien berisiko tinggi terkena serangan jantung”.

1.3. Tujuan Penelitian

Tujuan dari penelitian ini adalah mengoptimalkan prediksi risiko serangan jantung dengan mengelompokkan pasien berdasarkan faktor risiko menggunakan K-Means Clustering dan meningkatkan akurasi prediksi pasien berisiko tinggi menggunakan XGBoost.

1.4. Manfaat Penelitian

Melalui hasil penelitian ini, diharapkan dapat memberikan manfaat sebagai berikut:

1.4.1. Manfaat Akademik

1. Pengembangan Ilmu Data Mining dan Machine Learning

Penelitian ini berkontribusi dalam penerapan kombinasi metode unsupervised learning (K-Means Clustering) dan supervised learning (XGBoost) dalam bidang kesehatan, khususnya prediksi risiko serangan jantung.

2. Menjadi Referensi untuk Penelitian Selanjutnya

Hasil penelitian ini dapat menjadi dasar bagi penelitian lain yang ingin mengembangkan model prediksi penyakit kardiovaskular dengan algoritma machine learning yang lebih kompleks, seperti Hybrid Clustering atau Deep Learning.

3. Validasi Model dalam Konteks Data Medis

Metode yang digunakan dalam penelitian ini dapat diuji dan dibandingkan dengan metode lain, sehingga dapat memperkaya literatur mengenai penggunaan K-Means dan XGBoost dalam analisis kesehatan.

1.4.2. Manfaat Praktis

1. Membantu Deteksi Dini Serangan Jantung

Model yang dikembangkan dalam penelitian ini dapat membantu tenaga medis dan rumah sakit dalam mengidentifikasi pasien dengan risiko tinggi sehingga tindakan pencegahan dapat dilakukan lebih cepat.

2. Efisiensi dalam Pengolahan Data Pasien

Dengan menggunakan K-Means Clustering, pasien dapat dikategorikan ke dalam kelompok risiko rendah, sedang, atau tinggi, yang mempermudah analisis tanpa harus melakukan diagnosis manual untuk setiap pasien.

3. Peningkatan Akurasi Prediksi Risiko Serangan Jantung

Dengan menerapkan XGBoost, model prediksi dapat memiliki akurasi yang lebih tinggi dibandingkan metode tradisional, seperti Decision Tree atau Logistic Regression, sehingga mengurangi kesalahan dalam identifikasi pasien berisiko tinggi.

4. Dapat Digunakan dalam Sistem Pendukung Keputusan Medis

Penelitian ini dapat diintegrasikan ke dalam Decision Support System (DSS) yang digunakan di rumah sakit atau klinik untuk membantu dokter dalam mengambil keputusan berdasarkan data pasien yang tersedia.

5. Mendukung Pencegahan dan Edukasi Pasien

Hasil penelitian ini dapat digunakan untuk mengedukasi masyarakat tentang faktor risiko serangan jantung, sehingga pasien dapat melakukan perubahan gaya hidup untuk mengurangi risiko terkena penyakit jantung.

BAB II

LANDASAN TEORI

2.1. Kajian Teori

2.1.1. Penyakit Jantung

Serangan jantung, atau infark miokard, adalah kondisi medis serius yang terjadi ketika aliran darah ke otot jantung mengalami penyumbatan total atau sebagian, menyebabkan jaringan jantung mengalami kekurangan oksigen dan akhirnya rusak. Penyumbatan ini umumnya disebabkan oleh aterosklerosis, yaitu kondisi di mana plak lemak, kolesterol, kalsium, dan zat lain menumpuk di dinding arteri koroner. Jika plak ini pecah, tubuh merespons dengan membentuk gumpalan darah yang dapat menyumbat arteri, menghambat pasokan oksigen ke jantung, dan menyebabkan kematian sel otot jantung secara cepat. (Taylor et al., 2024)

Gejala serangan jantung bisa bervariasi, tetapi tanda-tanda yang paling umum adalah nyeri dada yang menekan, sesak napas, pusing, mual, keringat dingin, dan kelelahan ekstrem. Nyeri dada sering digambarkan sebagai rasa terhimpit atau tertindih yang bisa menjalar ke lengan kiri, leher, punggung, atau rahang. Pada beberapa kasus, terutama pada wanita, gejala bisa lebih ringan atau tidak khas, seperti mual yang berkepanjangan, nyeri di punggung bagian atas, atau kelelahan yang tidak biasa. Oleh karena itu, banyak serangan jantung yang tidak langsung dikenali, yang menyebabkan keterlambatan dalam penanganan dan meningkatkan risiko komplikasi serius. (Hogan et al., 2024)

2.1.2. Data Mining

Data Mining adalah teknik yang digunakan untuk menganalisis pola dan karakteristik yang dapat diprediksi di masa depan, serta mengidentifikasi informasi tersembunyi yang sebelumnya tidak terlihat dalam kumpulan data yang besar. Metode ini memungkinkan eksplorasi pengetahuan dan pola

dalam data dengan memanfaatkan pendekatan statistik, matematika, dan machine learning.(Sekar Setyaningtyas et al., 2022)

Perkembangan sistem informasi yang terdistribusi berkontribusi terhadap pertumbuhan volume data yang sangat besar. Seiring waktu, jumlah data akan terus meningkat dengan menggabungkan informasi saat ini dengan data di masa mendatang, sehingga menciptakan aliran data dalam jumlah besar. Dalam konteks ini, algoritma Data Mining berperan penting dalam menganalisis data secara efisien dan efektif, memungkinkan pengguna untuk mengelola dan mengekstrak wawasan dari dataset yang terus berkembang.(Sekar Setyaningtyas et al., 2022)

2.1.3. Clustering

Clustering adalah proses pengelompokan objek yang memiliki kesamaan karakteristik ke dalam kelompok yang berbeda, atau lebih spesifiknya, membagi sebuah dataset menjadi beberapa subset sehingga setiap subset memiliki makna yang lebih bermakna. Dalam setiap cluster, terdapat sekumpulan objek yang memiliki kemiripan satu sama lain, tetapi berbeda dengan objek dalam cluster lainnya.(Indraputra & Fitriana, n.d.)

Algoritma clustering terbagi menjadi dua jenis utama, yaitu clustering hierarkis dan clustering partisional. Algoritma hierarkis membentuk cluster secara bertahap berdasarkan struktur yang telah ditentukan sebelumnya, sementara algoritma partisional menentukan semua kelompok dalam satu tahap tertentu. Clustering juga dapat diartikan sebagai proses pengelompokan data berdasarkan pola tertentu, di mana objek dengan karakteristik serupa akan dikelompokkan dalam satu cluster, sedangkan objek yang memiliki karakteristik berbeda akan dimasukkan ke dalam cluster lain.(Indraputra & Fitriana, n.d.)

Dalam kajiannya, Madhulatha mengidentifikasi berbagai teknik clustering yang umum digunakan, termasuk pengertian, algoritma, manfaat, penerapannya, serta kekurangannya. Sementara itu, Bataineh et al. membandingkan beberapa metode clustering, seperti Fuzzy C-Means (FCM)

dan Subtractive Clustering, dengan menilai validitas hasil dari masing-masing metode.(Indraputra & Fitriana, n.d.)

Clustering memiliki peranan penting dalam kehidupan sehari-hari karena erat kaitannya dengan pengelolaan data untuk menghasilkan informasi yang bermanfaat. Salah satu aspek penting dalam pengolahan data adalah mengklasifikasikan dan mengelompokkan data ke dalam kategori atau cluster tertentu. Metode clustering telah diterapkan dalam berbagai bidang, seperti analisis statistik, pembelajaran mesin, data mining, pengenalan pola, analisis citra, dan bioinformatika.(Indraputra & Fitriana, n.d.)

Sebagai contoh, dalam penelitian yang dilakukan oleh Varghese et al., teknik clustering digunakan untuk menganalisis data akademik siswa, sehingga dapat mengidentifikasi pola performa mereka berdasarkan berbagai parameter yang ditentukan.(Indraputra & Fitriana, n.d.)

2.1.4.K-Means

K-Means adalah metode clustering yang termasuk dalam pendekatan partitioning, di mana algoritma ini menggunakan model centroid sebagai pusat dalam pembentukan cluster. Model centroid bekerja dengan menentukan titik tengah (centroid) dari setiap cluster, yang berupa nilai numerik dan berfungsi sebagai acuan dalam menghitung jarak suatu objek data. Sebuah objek akan dikelompokkan ke dalam cluster tertentu jika memiliki jarak terdekat dengan centroid cluster tersebut. K-Means dikenal sebagai algoritma pembelajaran tanpa pengawasan (unsupervised learning) yang sederhana dan efektif untuk menyelesaikan masalah pengelompokan dengan tujuan meminimalkan kesalahan klasifikasi dalam pemrosesan data.(Hajar et al., n.d.)

Algoritma K-Means Clustering merupakan salah satu metode unsupervised learning yang paling sering digunakan dalam pengelompokan data. Algoritma ini bekerja dengan membagi data ke dalam sejumlah cluster (K clusters) berdasarkan kesamaan karakteristiknya. Dalam prosesnya, algoritma K-Means membagi dataset menjadi K kelompok yang berbeda,

dengan meminimalkan variasi dalam satu cluster (intra-cluster) dan memaksimalkan perbedaan antara cluster yang berbeda (inter-cluster). Karena kecepatannya, kesederhanaannya, dan efisiensinya dalam menangani dataset yang besar, K-Means sering digunakan dalam berbagai bidang seperti analisis data medis, segmentasi pelanggan, deteksi anomali, dan pengolahan citra digital. ("K-Means Clustering Algorithm: A Brief Review," 2021b)

Salah satu keunggulan utama K-Means adalah kemampuannya untuk menyusun struktur data yang tidak memiliki label. Dalam banyak kasus, data yang dikumpulkan dari dunia nyata tidak selalu memiliki kategori atau klasifikasi yang sudah diketahui sebelumnya. Dengan menggunakan K-Means, data dapat dikelompokkan berdasarkan pola tersembunyi yang muncul dari analisis distribusi titik data dalam ruang multidimensi. Oleh karena itu, algoritma ini sering digunakan dalam dunia kesehatan untuk mengidentifikasi kelompok pasien dengan pola penyakit yang serupa, membantu dalam diagnosis dini, dan meningkatkan efektivitas pengobatan berdasarkan karakteristik pasien. (Purba et al., 2022b)

2.1.4.1. Mekanisme Kerja Algoritma K-Means

Algoritma K-Means Clustering merupakan salah satu metode paling populer dalam data mining yang digunakan untuk mengelompokkan data ke dalam beberapa klaster berdasarkan kemiripan karakteristik. Pada prinsipnya, algoritma ini berfungsi untuk mengelompokkan data ke dalam k buah klaster, di mana data yang memiliki kemiripan fitur akan dikumpulkan ke dalam klaster yang sama, sedangkan data yang berbeda fitur akan masuk ke klaster lain. Tahapan kerja algoritma ini dijelaskan secara sistematis oleh (Kepadatan et al., 2021) dalam penelitian mereka.

Tahapan pertama dari algoritma ini adalah menentukan jumlah klaster yang diinginkan, misalnya $k = 3$. Nilai k harus lebih kecil dari jumlah total data ($k < n$) agar setiap klaster memiliki anggota yang bermakna. Setelah itu, dilakukan pemilihan pusat klaster (centroid) awal secara acak dari data yang ada. Pemilihan ini sangat penting karena centroid awal akan mempengaruhi

hasil akhir dari proses clustering.

Setelah menentukan centroid awal, langkah selanjutnya adalah menghitung jarak antara masing-masing data terhadap setiap centroid menggunakan rumus Euclidean Distance multivariat sebagai berikut:

$$D(i, j) = \sqrt{(X_{1i} - X_{1j})^2 + (X_{2i} - X_{2j})^2 + \dots + (X_{ki} - X_{kj})^2} \quad (1)$$

Keterangan:

$D(i, j)$: Jarak data ke i kepusat cluster j

X_{ki} : Data ke i pada atribut data ke k

X_{kj} : Titik pusat ke j pada atribut data ke k

Perhitungan ini dilakukan untuk semua data terhadap semua centroid, dan data kemudian diklasifikasikan ke klaster dengan jarak terkecil.

Setelah semua data teralokasikan ke klaster tertentu, dilakukan pembaruan posisi centroid untuk setiap klaster. Centroid baru dihitung menggunakan rata-rata seluruh anggota klaster pada setiap atribut menggunakan rumus:

$$V_{ij} = \frac{1}{N_i} \sum_{k=0}^{N_i} X_{kj} \quad (2)$$

Dimana:

V_{ij} : Centroid baru untuk klaster i pada atribut j

N_i : Jumlah data dalam klaster ke- i

X_{kj} : Nilai data ke- k pada atribut ke- j dalam klaster tersebut

Proses ini (menghitung jarak, mengalokasikan data, memperbarui centroid) diulang secara iteratif hingga nilai centroid tidak berubah lagi secara signifikan, menandakan bahwa algoritma telah mencapai konvergensi.

Mengacu pada penelitian (Kepadatan et al., 2021), perhitungan jarak menggunakan rumus Euclidean Distance dilakukan untuk data pelanggan e-wallet. Sebagai contoh sederhana, misalkan terdapat tiga data transaksi:

Tabel 1. Rumus K-Means

Data	Atribut 1 (X1)	Atribut 2 (X2)
D1	2000	30
D2	1500	45
D3	2200	35

Dan centroid awal:

$$C1 = (2100, 32)$$

$$C2 = (1600, 40)$$

$$\text{Menghitung jarak D1 ke C1: } D(D1, C1) = \sqrt{(2000 - 2100)^2 + (30 - 32)^2} \\ = \sqrt{(-100)^2 + (-2)^2} = \sqrt{10000 + 4} = \sqrt{10004} \approx 100.02$$

$$\text{Menghitung jarak D1 ke C2: } D(D1, C2) = \sqrt{(2000 - 1600)^2 + (30 - 40)^2} \\ = \sqrt{(400)^2 + (-10)^2} = \sqrt{160000 + 100} = \sqrt{160100} \approx 400.12$$

Karena jarak D1 ke C1 lebih kecil daripada ke C2, maka D1 dialokasikan ke kluster C1.

Proses serupa dilakukan untuk data D2 dan D3. Setelah semua data dialokasikan, centroid baru dihitung sebagai rata-rata dari semua anggota kluster. Proses ini diulangi hingga perubahan centroid antar iterasi sangat kecil atau tidak ada, menandai bahwa proses clustering telah konvergen.

Dengan menggunakan langkah-langkah tersebut, pengelompokan data menjadi lebih terstruktur dan pola dalam data menjadi lebih mudah dianalisis.

2.1.5. Extreme Gradient Boosting (XGBoost)

XGBoost adalah metode yang dikembangkan sebagai penyempurnaan dari gradient boosting oleh Dr. Tianqi Chen dari University of Washington pada tahun 2014. Gradient boosting sendiri merupakan algoritma yang digunakan untuk menemukan solusi optimal dalam berbagai permasalahan, terutama dalam regresi, klasifikasi, dan ranking. Prinsip utama dari algoritma

ini adalah melakukan penyesuaian parameter secara bertahap untuk meminimalkan loss function, yang berfungsi sebagai mekanisme evaluasi model.(Yulianti et al., 2022)

XGBoost dirancang dengan struktur pohon regresi yang lebih teratur, sehingga dapat meningkatkan kinerja model dan mengurangi kompleksitasnya, yang pada akhirnya membantu mencegah terjadinya overfitting. Hasil akhir dari prediksi yang dihasilkan oleh XGBoost diperoleh melalui proses penjumlahan hasil prediksi dari setiap pohon regresi yang telah dibangun.(Yulianti et al., 2022)

2.1.5.1. Mekanisme Kerja Algoritma XGBoost

XGBoost adalah sebuah implementasi dari metode Gradient Boosting dengan mengadopsi formulasi model yang lebih terstruktur untuk mengatasi masalah overfitting. Pengembangan XGBoost dilakukan oleh T. Chen dan C. Guestrin pada tahun 2016, yang merupakan library gradient boosting terdistribusi yang telah dioptimalkan untuk desain yang lebih efisien, fleksibel dan partable. XGBoost bekerja untuk melakukan klasifikasi, sehingga menghasilkan akurasi yang tinggi dan kinerja model yang unggul.(Aloysia Putri Prasetya & Prima Rosa, n.d.)

Langkah-langkah algoritma Extreme Gradient Boosting:

1. Membuat prediksi awal

$$f_0(x) = \left(\sum_{i=1}^n y_i / n \right) \quad (1)$$

Keterangan:

$f_0(x)$: Prediksi awal (bias awal model sebelum pohon dibentuk)

y_i : Nilai target aktual dari data ke-i

n : Jumlah total data

$\sum$: Penjumlahan seluruh nilai target

Fungsi:

Menghasilkan prediksi awal (bias) sebagai dasar untuk membangun model boosting selanjutnya.

2. Perhitungan eror atau residual

$$Y = y - f_0(X) \quad (2)$$

Keterangan:

Y : Nilai residual (error/peluang kesalahan)

y : Nilai aktual

$f_0(X)$: Prediksi awal dari model

Fungsi:

Mengukur selisih antara prediksi dan nilai aktual, digunakan untuk melatih pohon berikutnya.

3. Pelatihan model

(1) Membuat struktur pohon dengan memisahkan data ke dalam dua partisi melalui berbagai kemungkinan split.

(2) Menghitung nilai similarity dan gain pada setiap pohon yang terbentuk melalui nilai split optimal.

$$\text{Similarity} = \frac{(\sum \hat{y}_1)^2}{\sum [Previous f_1 \cdot (1 - Previous f_1(x)) + \lambda]} \quad (3)$$

Keterangan:

y_i : Nilai residual dari data ke-i

$f_i(x)$: Prediksi dari model sebelumnya pada data ke-x

λ : Parameter regularisasi untuk mencegah overfitting

Fungsi:

Mengukur seberapa “seragam” nilai-nilai residual dalam satu node

pohon. Semakin tinggi, semakin baik node tersebut untuk membuat keputusan.

$$Gain = (LeftSimilarity + RightSimilarity) - rootsimilarity \quad (4)$$

Keterangan:

Left/Right Similarity : Similarity node kiri dan kanan hasil split

Root Similarity : Similarity sebelum dilakukan split

Fungsi:

Menentukan apakah pembelahan data (split) efektif. Split terbaik adalah yang memiliki gain terbesar.

(3) Melakukan pemisahan ulang pada pohon yang memiliki nilai gain maksimal hingga mencapai batas `max_depth` untuk membentuk pohon secara menyeluruh.

(4) Setelah pembentukan pohon, lakukan pruning (pemangkasan) untuk mengurangi ukuran pohon keputusan dengan menghapus atau memotong bagian-bagian yang kurang efektif untuk klasifikasi.

(5) Menghitung output value

$$Output\ Value = (\sum \hat{y}_i) / \sum [F_{i-1} \times (1 - F_{i-1})] - \lambda \quad (5)$$

Keterangan:

y_i : Nilai residual dari data ke- i

F_{i-1} : Prediksi model sebelumnya

λ : Regularisasi

Fungsi:

Menentukan nilai prediksi pada setiap daun (leaf) di pohon yang sedang dilatih.

(6) Menghitung prediksi dari model, dimana setiap titik data melewati pohon keputusan terakhir untuk menghasilkan $h_1(x)$. selanjutnya, menghitung prediksi $f_1(x)$ dan nilai residu.

$$F_n(x) = \frac{1}{1 + \exp(-x)} \left(\frac{h_0(x)}{1 - h_0(x)} + \sum_{i=1}^n \eta \cdot h_i(x) \right) \quad (6)$$

Keterangan:

$F_n(x)$: Prediksi akhir model pada input x

$h_0(x)$: Prediksi awal (bias)

$h_i(x)$: Output dari pohon ke- i

η : Learning rate (mengatur kontribusi tiap pohon)

$\exp$: Fungsi eksponensial (digunakan dalam sigmoid)


Fungsi:

Menggabungkan hasil dari semua pohon dengan sigmoid untuk menghasilkan probabilitas prediksi antara 0–1 (untuk klasifikasi).

(7) Melakukan Langkah-langkah yang sama kembali (Langkah ke-3 Pelatihan Model) untuk membangun pohon lain

(8) Membuat prediksi akhir

Berikut contoh arsitektur dari algoritma XGBoost ditunjukkan pada Gambar :



Gambar 1. Arsitektur Algoritma XGBoost

Sumber: :

<https://eprints.unpak.ac.id/8882/1/Laporan%20Skripsi%20Lengkap-Nabila%20Rasman%20Sutandi.pdf>

Berikut adalah contoh penerapan Rumus XGBoost menurut(Sutandi, 2024):

Lakukan prediksi awal dan hitung nilai residuals ($\mathcal{Y}$) pada semua titik data dalam dataset menggunakan Persamaan 5 dan 6, yaitu :

$$f_0(x) = (2+3+0+1+0+3+1+3)8 = 1.62$$

Lakukan pelatihan model dimulai dengan menentukan batasan dengan mengambil nilai rata-rata x antara dua titik cabang (splits) sampai pada masing-masing simpul pohon menggunakan Persamaan 7 dan 8. Berikut contoh perhitungan splits pada data ke-1 dan data ke-2, yaitu :

$$\begin{aligned}\bar{x}_{d1} &= \frac{0.14+0.09+0.27+0.26+0.44+0.19+0.39+0.25+0.55+0.44+0.44+ \dots +0}{63} = 0.047 \\ \bar{x}_{d2} &= \frac{0+0.09+0+0+0+0+0+0+0.05+0+0+0.23+0.16+0.39+0.24+0.44+ \dots +0}{63} = 0.045 \\ splits &= \frac{(0.047)+(0.045)}{2} = 0.046\end{aligned}$$

Berikut perhitungan pohon cabang ke-2 ($x < 0.034$) yang memiliki nilai gain max (internal root), yaitu :

Similarity daun kanan

$$\frac{((-0.62)+1.38)^2}{2 [1.62 \times (1-1.62)]+0} = -0.288$$

Similarity daun kiri

$$\frac{(1.62+1.38)^2}{2 [1.62 \times (1-1.62)]+0} = -0.029$$

$$Gain = ((-0.029) + (-0.288)) - (-0.440) = 0.124$$

Berikut perhitungan output pada seluruh daun, yaitu :

$$\text{Daun ke-1} = \frac{(0.38+1.38+(-1.62))}{3 [1.62 \times (1-1.62)]+0} = -0.05$$

$$\text{Daun ke-2} = \frac{(-1.62)}{1 [1.62 \times (1-1.62)]+0} = 0.62$$

$$\text{Daun ke-3} = \frac{((-1.62)+1.38)}{2 [1.62 \times (1-1.62)]+0} = 0.12$$

$$\text{Daun ke-4} = \frac{((-0.62)+1.38)}{2 [1.62 \times (1-1.62)]+0} = -0.38$$

Prediksi dari model M_i dengan mencari nilai $f_i(x)$ untuk klasifikasi

Berikut perhitungan nilai $f_i(x)$ dengan learning_rate = 0.1, yaitu :

Data ke-1, data ke-2, dan data ke-3

$$f_i(x) = \sigma \left[\left[\frac{1.62}{1-1.62} \right] + (0.1 \times (-0.05)) \right] = \sigma [-2.6] + (0.1 \times (-0.05)) = \sigma [-2.62]$$

$$\sigma(-2.62) = \frac{1}{1 + \exp(-(-2.62))} = \frac{1}{1 + 13.70} = \frac{1}{14.70} = 0.068$$

Data ke-4

$$f_i(x) = \sigma \left[\left[\frac{1.62}{1-1.62} \right] + (0.1 \times 0.62) \right] = \sigma [-2.6] + (0.1 \times 0.62) = \sigma [-2.55]$$

$$\sigma(-2.55) = \frac{1}{1 + \exp(-(-2.55))} = \frac{1}{1 + 12.82} = \frac{1}{13.82} = 0.072$$

Data ke-5 dan data ke-6

$$f_i(x) = \sigma \left[\left[\frac{1.62}{1-1.62} \right] + (0.1 \times 0.12) \right] = \sigma [-2.6] + (0.1 \times 0.12) = \sigma [-2.60]$$

$$\sigma(-2.60) = \frac{1}{1 + \exp(-(-2.60))} = \frac{1}{1 + 13.48} = \frac{1}{14.48} = 0.069$$

Data ke-7 dan data ke-8

$$f_i(x) = \sigma \left[\left[\frac{1.62}{1-1.62} \right] + (0.1 \times (-0.38)) \right] = \sigma [-2.6] + (0.1 \times (-0.38)) = \sigma [-2.65]$$

$$\sigma(-2.65) = \frac{1}{1 + \exp(-(-2.65))} = \frac{1}{1 + 14.16} = \frac{1}{15.16} = 0.066$$

2.1.6. Python

Sejak diperkenalkan pada tahun 1991, Python telah menjadi salah satu bahasa pemrograman yang populer dan fleksibel untuk berbagai jenis permasalahan. Perkembangannya yang pesat kini telah memperluas cakupan penggunaannya ke bidang ekonometrik, statistik, dan analisis numerik secara umum. Dalam hal analisis data, komputasi eksploratif, serta visualisasi interaktif, Python memiliki kemampuan yang setara dengan bahasa pemrograman lain seperti R, MATLAB, SAS, dan Stata. (Kaestria & Himmah, n.d.)

Survei terbaru menunjukkan bahwa Python termasuk dalam daftar bahasa pemrograman paling populer yang digunakan dalam data science serta pengembangan berbagai jenis perangkat lunak. Keunggulan utamanya terletak pada sintaks yang sederhana, mudah dibaca, serta portabilitas kode yang tinggi, sehingga membuatnya menjadi pilihan utama bagi banyak pengembang dan peneliti. (Kaestria & Himmah, n.d.)

Python dikategorikan sebagai bahasa interpreted, yang berarti tidak perlu dikompilasi sebelum dijalankan. Hal ini mempermudah pengembangan aplikasi dan memungkinkan debugging yang lebih cepat. Selain itu, Python memiliki paradigma pemrograman multiparadigm, mendukung pemrograman prosedural, berorientasi objek (OOP), dan fungsional. Keunggulan ini menjadikan Python sangat fleksibel untuk berbagai skenario pemrograman, mulai dari pengolahan data sederhana hingga pengembangan sistem berbasis AI yang kompleks. (Diao et al., n.d.)

2.1.7. Google Colab

Google Colaboratory, atau yang lebih dikenal sebagai Colab, adalah platform berbasis komputasi awan yang memungkinkan pengguna untuk menulis, berbagi, dan menjalankan kode dalam lingkungan notebook interaktif tanpa memerlukan server sendiri. Colab menggunakan sistem notebook Jupyter dan mendukung berbagai bahasa pemrograman populer seperti Python, R, dan Julia. Platform ini menyediakan sumber daya

komputasi yang mumpuni, termasuk akses ke mesin virtual berbasis Linux dengan GPU canggih hingga 12 jam, menjadikannya ideal untuk tugas-tugas yang membutuhkan daya komputasi tinggi seperti pembelajaran mesin dan pembelajaran mendalam.(Supriyadi et al., 2023)

Colab memungkinkan peneliti untuk mengintegrasikan narasi, kode pemrograman, hasil eksekusi, dan elemen multimedia dalam satu dokumen kerja yang interaktif. Penggunaannya tersebar luas di berbagai disiplin ilmu, termasuk biologi, ilmu komputer, dan kedokteran, serta dalam lingkungan pendidikan untuk mendukung pengkodean kolaboratif dan kerja tim. Dengan aksesibilitas yang tinggi dan kemudahan penggunaan, Colab menjadi solusi yang praktis bagi mahasiswa dan peneliti dalam menyelesaikan tugas komputasi dan berbagi kode secara efisien.(Supriyadi et al., 2023)

2.1.8. Overfitting

Overfitting adalah kondisi ketika model machine learning terlalu menyesuaikan diri dengan data pelatihan, termasuk mempelajari noise atau variasi acak yang tidak relevan. Hal ini menyebabkan performa model sangat baik pada data latih tetapi menurun drastis pada data uji, karena kehilangan kemampuan generalisasi. Overfitting umum terjadi pada model kompleks atau saat jumlah fitur sangat besar dibanding jumlah data penting yang benar-benar relevan (Peters & Schuld, 2023).

Dalam penelitian ini, data memiliki 28 atribut dan 158.355 entri, sehingga risiko overfitting tetap perlu diperhatikan. Untuk mengatasinya, digunakan algoritma XGBoost yang dilengkapi dengan teknik regularisasi dan pengaturan hyperparameter seperti `max_depth` dan `learning_rate`. Studi oleh (Thomas & Kaliraj, 2024) menunjukkan bahwa tuning parameter ini dapat mengurangi overfitting dan meningkatkan akurasi prediksi pada model penyakit jantung.

2.1.9. Knowledge Discovery in Databases (KDD)

Knowledge Discovery in Databases (KDD) merupakan proses sistematis dan menyeluruh untuk mengekstraksi pengetahuan yang valid, baru, berguna, dan dapat dipahami dari kumpulan data besar. KDD terdiri dari beberapa tahapan utama, yaitu seleksi data, preprocessing, transformasi, data mining, dan evaluasi. Setiap tahap ini saling berhubungan dan berkontribusi dalam menghasilkan pola atau informasi yang relevan dari data mentah. Dalam konteks penelitian ini, proses KDD digunakan untuk mengelompokkan pasien berdasarkan risiko serangan jantung melalui algoritma K-Means dan kemudian mengklasifikasikannya menggunakan XGBoost agar hasil prediksi lebih akurat dan terstruktur (Hamidah et al., n.d.).

KDD tidak hanya sekadar aktivitas teknis, tetapi merupakan pendekatan analitis yang mengintegrasikan statistik, pembelajaran mesin, dan ilmu basis data. Penggunaannya dalam bidang kesehatan memungkinkan tenaga medis untuk mengidentifikasi pola tersembunyi yang tidak mudah dikenali secara manual. Dalam penelitian lain, penerapan metode KDD berhasil digunakan untuk menganalisis prediksi penyakit dan fenomena sosial berbasis data terbuka, dengan hasil analisis yang memberikan wawasan penting dalam pengambilan keputusan berbasis data (Hamidah et al., n.d.).

2.1.10. Confusion Matrix

Confusion matrix merupakan representasi tabular dari hasil klasifikasi model yang memuat jumlah prediksi benar dan salah terhadap dua kelas: positif dan negatif. Matriks ini berisi empat nilai utama yaitu True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN), yang digunakan sebagai dasar dalam menghitung metrik evaluasi lainnya. Dalam konteks prediksi penyakit jantung, keberadaan false negative (FN) sangat kritis karena pasien yang sebenarnya berisiko tidak terdeteksi. Oleh karena itu, penggunaan confusion matrix tidak hanya mempermudah pemahaman performa model secara keseluruhan, tetapi juga membantu mendeteksi

potensi kelemahan model dalam konteks medis yang sensitif (Alfajr & Defiyanti, 2024).

2.1.11. Accuracy

Accuracy adalah metrik evaluasi yang mengukur proporsi keseluruhan prediksi yang benar dari seluruh jumlah data. Rumusnya sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Meskipun akurasi sering dijadikan metrik utama dalam mengevaluasi model, akurasi dapat menyesatkan ketika data tidak seimbang. Misalnya, jika dataset berisi lebih banyak data pasien sehat daripada yang sakit, maka model yang hanya memprediksi “sehat” tetap bisa memiliki akurasi tinggi namun tidak bermanfaat secara klinis. Dalam penelitian prediksi penyakit jantung menggunakan C4.5, akurasi yang dicapai hanya sebesar 65,25%, yang menunjukkan bahwa penggunaan akurasi perlu dilengkapi dengan metrik lain yang lebih representatif dalam konteks medis (Muzakki et al., 2024).

2.1.12. Precision

Precision atau Positive Predictive Value adalah proporsi dari prediksi positif yang benar-benar tepat. Rumus precision adalah:

$$Precision = \frac{TP}{TP + FP}$$

Precision sangat penting dalam situasi di mana kesalahan prediksi positif (false positive) harus diminimalkan. Dalam konteks medis, false positive dapat menyebabkan pasien yang sebenarnya sehat menjalani pemeriksaan atau perawatan yang tidak perlu. Dalam penelitian (Roja Mahardika et al., 2022), precision digunakan untuk mengevaluasi model klasifikasi berbasis SVM dalam analisis sentimen. Hasil menunjukkan bahwa precision memiliki peran krusial ketika dataset bersifat imbalanced, seperti pada banyak kasus medis (Roja Mahardika et al., 2022).

2.1.13. Recall

Recall atau sensitivitas mengukur kemampuan model dalam menangkap seluruh data yang benar-benar positif. Rumusnya adalah:

$$Recall = \frac{TP}{TP + FN}$$

Recall sangat penting untuk memastikan tidak ada kasus positif yang luput dari deteksi. Dalam diagnosa penyakit, nilai recall tinggi berarti bahwa model mampu mengenali sebagian besar pasien yang benar-benar berisiko (Alfajr & Defiyanti, 2024).

2.1.14. F1-Score

F1-Score merupakan metrik yang menggabungkan precision dan recall dalam satu angka tunggal melalui rata-rata harmonis. Rumusnya adalah:

$$F1 - Score = 2 \times \frac{Precision \times Recall}{precision + Recall}$$

F1-score sangat berguna ketika distribusi data tidak seimbang dan keseimbangan antara false positive dan false negative sangat penting. Dalam penelitian yang dilakukan oleh Sitarz (2022), F1-score bahkan dikembangkan ke arah pendekatan probabilistik karena dinilai lebih representatif dibanding akurasi, terutama dalam klasifikasi berbasis medis dan NLP. Studi tersebut juga menekankan bahwa F1-score cocok untuk mengevaluasi model pada kasus ekstrem dari confusion matrix (Sitarz, 2023).

2.1.15. Hyperparameter Tuning

Hyperparameter tuning merupakan proses penting dalam pengembangan model machine learning, yang bertujuan untuk mengoptimalkan kinerja model dengan menyesuaikan parameter-parameter eksternal yang tidak dipelajari langsung dari data pelatihan. Berbeda dengan parameter model yang diperoleh selama proses pelatihan, hyperparameter harus ditentukan sebelumnya dan sangat mempengaruhi hasil akhir model. Pada algoritma seperti XGBoost, pengaturan hyperparameter yang tepat dapat meningkatkan akurasi prediksi, stabilitas model, dan kemampuan

generalisasi terhadap data baru. Beberapa metode tuning telah dikembangkan untuk memilih kombinasi parameter terbaik, seperti pendekatan berbasis pencarian acak atau pendekatan probabilistik. Penelitian oleh (Bischl et al., n.d.) menekankan bahwa pemilihan hyperparameter yang optimal dapat secara signifikan meningkatkan performa algoritma pembelajaran mesin dalam berbagai domain, termasuk bidang medis (Bischl et al., n.d.). Dengan demikian, dalam konteks prediksi risiko serangan jantung, proses hyperparameter tuning menjadi langkah krusial untuk memastikan bahwa model yang dikembangkan bekerja secara efisien dan dapat diandalkan dalam membantu proses pengambilan keputusan klinis.

2.2. Hasil Penelitian Yang Relevan

1. Penelitian berjudul “Implementasi K-Means Clustering pada Pengelompokan Pasien Penyakit Jantung” oleh Wala et al. (2024) menerapkan algoritma K-Means Clustering untuk mengelompokkan pasien penyakit jantung berdasarkan sejumlah atribut medis, seperti tekanan darah, kadar kolesterol, usia, dan jenis nyeri dada. Dengan menggunakan dataset berisi 303 pasien, penelitian ini berhasil membentuk empat cluster utama yang menggambarkan tingkat keparahan pasien berdasarkan gejala dan nilai medis. Salah satu cluster secara khusus menunjukkan kelompok risiko tinggi, yakni terdiri dari pasien berusia lanjut dengan tekanan darah sistolik dan kolesterol yang sangat tinggi. Temuan ini membuktikan bahwa K-Means efektif dalam melakukan segmentasi pasien berdasarkan profil risiko yang berbeda-beda. Namun demikian, penelitian ini tidak melanjutkan analisis lebih lanjut dalam bentuk prediksi atau klasifikasi risiko pada cluster tinggi tersebut. Oleh karena itu, penelitian ini memberikan dasar penting sekaligus membuka peluang bagi pengembangan metode lanjutan untuk memperkuat proses identifikasi pasien berisiko tinggi secara prediktif.
2. Penelitian berjudul “Clustering Penyakit DBD pada Rumah Sakit Dharma Kerti Menggunakan Algoritma K-Means” oleh (Nyoman & Adiputra, 2021) memanfaatkan algoritma K-Means Clustering untuk

mengelompokkan data rekam medis pasien DBD (Demam Berdarah Dengue) di Rumah Sakit Dharma Kerti. Penelitian ini memfokuskan pengelompokan berdasarkan atribut medis dan demografis, seperti usia, durasi rawat inap, serta jumlah trombosit. Hasil dari proses clustering menunjukkan bahwa sebagian besar pasien dengan lama rawat inap lebih dari tiga hari tergolong ke dalam cluster risiko tinggi. Walaupun penelitian ini membahas penyakit yang berbeda dari konteks skripsi ini, yaitu DBD, pendekatannya tetap relevan karena mengilustrasikan efektivitas algoritma K-Means dalam menyusun segmentasi risiko berdasarkan karakteristik pasien. Dari sini dapat dilihat bahwa algoritma ini fleksibel dan dapat diaplikasikan pada data medis yang kompleks, namun seperti penelitian Wala et al., pendekatannya belum terintegrasi dengan sistem klasifikasi untuk prediksi lanjutan.

3. Penelitian berjudul “Perbandingan Metode Decision Tree Classifier dan XGBoost Classifier dalam Memprediksi Penyakit Jantung” oleh (Mayang Pratiwi & Mufidah, 2024) Penelitian ini membandingkan dua algoritma klasifikasi populer, yaitu Decision Tree dan XGBoost, dalam konteks prediksi penyakit jantung. Menggunakan dataset dari UCI Machine Learning Repository, penelitian ini melakukan pengujian terhadap beberapa metrik evaluasi seperti akurasi, precision, recall, dan AUC. Hasilnya menunjukkan bahwa XGBoost mampu memberikan performa terbaik dengan akurasi mencapai 93%, mengungguli Decision Tree yang hanya mencapai 90%. Penelitian ini sangat relevan karena memberikan bukti empiris bahwa XGBoost lebih unggul dalam klasifikasi penyakit jantung. Namun, pendekatan penelitian ini dilakukan langsung ke seluruh dataset tanpa adanya proses segmentasi pasien berdasarkan tingkat risiko sebelumnya. Oleh karena itu, pendekatan penggabungan K-Means dan XGBoost yang diusulkan dalam skripsi ini diharapkan dapat memberikan hasil prediksi yang lebih terarah, terutama untuk kelompok pasien berisiko tinggi.
4. Penelitian berjudul “Perbandingan Metode Machine Learning untuk


Mendeteksi Penyakit Jantung” oleh (Amelia, 2023) bertujuan mengevaluasi performa beberapa algoritma klasifikasi seperti Decision Tree, Random Forest, Naïve Bayes, SVM, dan XGBoost dalam memprediksi penyakit jantung. Penelitian ini menggunakan dataset UCI dengan 13 atribut medis dan menerapkan validasi silang serta teknik Grid Search untuk tuning hyperparameter. Hasilnya menunjukkan bahwa XGBoost merupakan algoritma dengan performa terbaik, dengan akurasi mencapai 95,08%, unggul signifikan dibandingkan metode lainnya. Temuan ini memperkuat keunggulan XGBoost dalam klasifikasi data medis, terutama untuk mendeteksi penyakit jantung secara efektif. Namun demikian, penelitian ini tidak melakukan tahap segmentasi awal pada data pasien sebelum klasifikasi dilakukan, sehingga pendekatannya cenderung bersifat general dan belum mempertimbangkan diferensiasi risiko pasien. Hal ini menimbulkan peluang untuk pendekatan yang lebih terfokus melalui penggabungan teknik clustering, seperti yang ditawarkan dalam penelitian ini.

5. Penelitian berjudul “Klasifikasi Penyakit Jantung Tipe Kardiovaskular Menggunakan Adaptive Synthetic Sampling dan Algoritma Extreme Gradient Boosting” oleh (Permana et al., 2024) mengembangkan sistem klasifikasi penyakit jantung berbasis XGBoost yang diperkuat dengan teknik ADASYN untuk mengatasi ketidakseimbangan data serta metode Bayesian Optimization dalam proses tuning hyperparameter. Dengan menggunakan dataset sebanyak 4.238 data pasien dan 10 atribut, penelitian ini menghasilkan model dengan akurasi 91,6% dan nilai AUC sebesar 0,971, yang menunjukkan performa sangat tinggi. Penelitian ini membuktikan bahwa XGBoost, jika dikombinasikan dengan teknik pendukung, mampu meningkatkan akurasi klasifikasi secara signifikan. Akan tetapi, pendekatan ini tidak menyertakan tahapan segmentasi data pasien berdasarkan karakteristik risikonya sebelum klasifikasi dilakukan. Oleh karena itu, model yang

dikembangkan belum memberikan personalisasi terhadap tingkat risiko pasien secara eksplisit. Dalam konteks ini, penelitian skripsi ini mengisi celah tersebut dengan melakukan pengelompokan awal menggunakan K-Means sebelum klasifikasi lanjutan oleh XGBoost, sehingga hasil prediksi dapat lebih tajam dan terfokus pada kelompok risiko tinggi.



2.3. Kerangka Berpikir



Gambar 2. Kerangka Berpikir

2.4. Hipotesis Penelitian

Dalam Penelitian ini menggunakan 2 Jenis Hipotesis:

- Hipotesis Nol (H_0): Penerapan algoritma XGBoost setelah proses K-Means tidak memberikan peningkatan akurasi yang signifikan dalam memprediksi risiko serangan jantung pada pasien dalam cluster risiko tinggi, sehingga performa model tidak lebih baik dibanding tanpa tahap

clustering sebelumnya.

- b. Hipotesis Alternatif (H_1): Penerapan algoritma K-Means Clustering mampu mengelompokkan pasien ke dalam cluster berdasarkan tingkat risiko serangan jantung dengan pola yang jelas, serta penerapan algoritma XGBoost setelah proses clustering dapat meningkatkan akurasi prediksi terhadap pasien dalam cluster risiko tinggi secara signifikan.



BAB III

METODE PENELITIAN

3.1. Jenis dan Pendekatan Penelitian

3.1.1. Jenis Penelitian

Jenis penelitian yang digunakan dalam studi ini adalah penelitian kuantitatif, karena berfokus pada pengolahan dan analisis data numerik dalam jumlah besar untuk mengidentifikasi pola dan membuat prediksi berdasarkan hubungan antar variabel. Pendekatan kuantitatif sangat relevan dalam konteks penelitian ini karena memungkinkan penggunaan metode matematis dan statistik untuk mengukur serta membandingkan performa algoritma dalam memproses data kesehatan. Data yang digunakan adalah dataset sekunder dalam bentuk file .csv yang berisi informasi medis dan sosial-demografis dari pasien yang berisiko mengalami serangan jantung. Penelitian kuantitatif ini bertujuan untuk menghasilkan temuan yang objektif, terukur, dan dapat diandalkan, terutama dalam mendeteksi kelompok pasien yang memiliki risiko tinggi terhadap penyakit jantung. Pendekatan ini juga mendukung penggunaan algoritma machine learning yang telah banyak digunakan dalam bidang kesehatan digital dan prediksi penyakit berbasis data besar. (Zou et al., 2023)

3.1.2. Pendekatan Penelitian

Pendekatan yang digunakan dalam penelitian ini adalah pendekatan data mining yang dikombinasikan dengan metode machine learning. Teknik ini dipilih karena mampu mengolah data dalam jumlah besar untuk menemukan pola tersembunyi dan menghasilkan prediksi berbasis algoritma. Dua algoritma utama yang digunakan adalah K-Means Clustering dan XGBoost. Algoritma K-Means digunakan sebagai metode unsupervised learning yang berfungsi untuk mengelompokkan pasien ke dalam beberapa cluster berdasarkan atribut kesehatan yang mirip, seperti tekanan darah, kadar kolesterol, usia, dan gaya hidup. Cluster yang dihasilkan, khususnya cluster risiko tinggi, kemudian dianalisis lebih lanjut menggunakan algoritma

XGBoost. XGBoost, yang merupakan metode supervised learning, digunakan untuk membangun model klasifikasi prediktif guna menentukan pasien yang memiliki kemungkinan tinggi terkena serangan jantung. Pendekatan gabungan ini telah terbukti efektif dan banyak digunakan dalam penelitian berbasis data medis, karena mampu meningkatkan akurasi dan efisiensi sistem prediksi.(P & R, 2024);(Peng et al., 2024).

3.2. Waktu dan Tempat Penelitian

3.2.1. Waktu Penelitian

Penelitian ini dilaksanakan selama lima bulan, yaitu dari Februari hingga Juni 2025. Rentang waktu ini mencakup seluruh tahapan penting dalam penelitian, mulai dari perencanaan, pengumpulan data, preprocessing, pemodelan, pelatihan algoritma, evaluasi, hingga penyusunan laporan akhir. Setiap tahap dirancang agar berjalan secara sistematis dan saling terintegrasi sehingga memungkinkan analisis data yang efektif dan akurat. Proses eksplorasi data dan pelatihan model dilakukan secara bertahap untuk memastikan bahwa hasil analisis dan prediksi memiliki tingkat kepercayaan yang tinggi dan dapat dipertanggungjawabkan secara akademik.


3.2.2. Tempat Penelitian

Penelitian ini dilaksanakan secara daring (online) tanpa melibatkan lokasi fisik tertentu. Seluruh proses penelitian dilakukan secara digital menggunakan data sekunder berbentuk dataset publik yang tersedia di platform berbagi data Kaggle. Dataset yang digunakan berjudul “Heart Attack Prediction in Indonesia Dataset”, yang memuat informasi medis pasien seperti usia, tekanan darah, kolesterol, detak jantung, dan variabel lainnya yang berkontribusi terhadap risiko serangan jantung. Dataset ini diakses melalui tautan <https://www.kaggle.com/datasets/ankushpanday2/heart-attack-prediction-in-indonesia> pada tanggal 8 Maret 2025.

Data tersebut kemudian diunduh dan diolah menggunakan bahasa pemrograman Python melalui platform Google Colaboratory, yang merupakan layanan komputasi awan milik Google. Google Colab dipilih karena kemampuannya untuk menjalankan kode Python secara interaktif,

menyediakan akses gratis ke unit pemrosesan grafis (GPU), dan mendukung eksekusi notebook Jupyter yang ideal untuk eksperimen machine learning dan data mining. Dalam lingkungan ini, berbagai tahapan pengolahan data dilakukan, mulai dari pra-pemrosesan data (preprocessing), visualisasi data, hingga implementasi algoritma K-Means Clustering dan XGBoost. Library Python yang digunakan meliputi Pandas untuk manipulasi data, Scikit-learn untuk penerapan algoritma machine learning, Matplotlib dan Seaborn untuk visualisasi, serta XGBoost library untuk membangun model prediksi klasifikasi.

Dengan pendekatan daring berbasis cloud computing ini, seluruh proses penelitian menjadi lebih efisien, fleksibel, dan dapat dilakukan kapan saja tanpa batasan geografis. Penelitian juga dapat direplikasi dengan mudah oleh peneliti lain karena menggunakan alat dan dataset terbuka. Gambar 3.1 berikut menunjukkan tangkapan layar dari dataset Heart Attack yang tersedia di Kaggle sebagai dasar dari penelitian ini:



Gambar 3. Dataset Heart Attack Prediction In Indonesia

Sumber : <https://www.kaggle.com/datasets/ankushpanday2/heart-attack-prediction-in-indonesia>

3.3. Populasi dan Sampel Penelitian

3.3.1. Populasi Penelitian

Populasi dalam penelitian ini adalah seluruh individu yang tercakup dalam dataset sekunder bertajuk Heart Attack Prediction in Indonesia yang diperoleh dari platform Kaggle. Dataset ini merepresentasikan populasi pasien di Indonesia yang memiliki potensi atau risiko mengalami serangan jantung, berdasarkan kombinasi faktor medis, demografis, dan gaya hidup. Jumlah populasi dalam dataset ini mencapai 158.355 entri pasien, menjadikannya salah satu dataset berskala besar yang sangat kaya untuk kebutuhan analisis prediksi dalam ranah medis, khususnya penyakit kardiovaskular.

Setiap entri dalam populasi ini mencerminkan satu pasien dengan atribut yang lengkap, mencakup variabel demografis seperti usia dan jenis kelamin, serta indikator sosial-ekonomi dan lingkungan seperti wilayah tempat tinggal (urban/pedesaan) dan tingkat pendapatan. Selain itu, terdapat faktor gaya hidup yang berkontribusi terhadap risiko serangan jantung, antara lain: status merokok, konsumsi alkohol, aktivitas fisik, pola makan, tingkat stres, dan jumlah jam tidur. Populasi ini juga mencakup variabel riwayat kesehatan, termasuk hipertensi, diabetes, obesitas, lingkar pinggang, hasil EKG, serta riwayat penyakit jantung sebelumnya. Terdapat pula indikator biologis seperti tekanan darah sistolik dan diastolik, kadar kolesterol (HDL dan LDL), trigliserida, serta gula darah puasa, yang semuanya relevan dalam evaluasi risiko kardiovaskular.

Cakupan populasi yang sangat luas dan beragam ini memungkinkan penelitian ini untuk merefleksikan kondisi kesehatan masyarakat Indonesia secara lebih representatif. Tidak hanya menggambarkan variasi dalam status medis pasien, tetapi juga menangkap pengaruh lingkungan sosial dan perilaku hidup yang kerap menjadi pemicu utama penyakit jantung di negara berkembang.

Dalam konteks penelitian ini, populasi berfungsi sebagai dasar utama dalam pengembangan model prediksi risiko serangan jantung. Populasi ini

akan diproses melalui metode K-Means Clustering untuk mengelompokkan pasien ke dalam beberapa kategori risiko (rendah, sedang, tinggi), dan kemudian difokuskan pada kelompok risiko tinggi untuk diterapkan model klasifikasi menggunakan algoritma XGBoost. Dengan memanfaatkan populasi yang besar dan kaya informasi ini, model yang dihasilkan diharapkan tidak hanya kuat secara prediktif, tetapi juga mampu menangkap pola yang relevan secara medis dan dapat diimplementasikan secara praktis dalam sistem deteksi dini di bidang kesehatan.

3.3.2. Sampel Penelitian

Sampel dalam penelitian ini bersumber dari dataset sekunder berjudul “Heart Attack Prediction in Indonesia” yang diperoleh dari platform Kaggle. Dataset ini berisi data kesehatan pasien dengan jumlah total 158.355 entri pasien dan 28 atribut yang mencakup informasi demografis, medis, dan gaya hidup yang berkaitan erat dengan risiko serangan jantung. Dataset tersebut dipilih karena telah mencakup data dalam skala besar dan kompleks, sehingga sangat sesuai dengan tujuan penelitian untuk membangun model prediksi yang dapat mengidentifikasi pola pasien berisiko tinggi secara akurat dan terukur.

Setiap data dalam sampel memuat atribut yang sangat relevan dengan faktor risiko serangan jantung, di antaranya: usia, jenis kelamin, wilayah tempat tinggal (urban/pedesaan), tingkat pendapatan, tekanan darah sistolik dan diastolik, kadar kolesterol LDL, HDL, dan trigliserida, lingkaran pinggang, obesitas, status merokok, konsumsi alkohol, aktivitas fisik, pola makan, tingkat stres, jam tidur, hasil pemeriksaan EKG, riwayat diabetes, hipertensi, riwayat penyakit jantung sebelumnya, hingga partisipasi dalam skrining kesehatan gratis. Atribut-atribut ini telah digunakan dalam berbagai literatur medis sebagai indikator utama dalam analisis risiko penyakit kardiovaskular, sehingga kehadirannya dalam dataset memperkuat validitas analisis yang dilakukan dalam penelitian ini.

Teknik pengambilan sampel dilakukan secara purposive sampling, yaitu dengan memilih seluruh data yang memenuhi kriteria lengkap dan

relevan untuk dilakukan proses analisis lebih lanjut. Tidak dilakukan sampling acak atau reduksi data karena tujuan dari penelitian ini adalah melakukan optimasi prediksi pada skala data besar (big data). Oleh karena itu, seluruh data yang tersedia digunakan secara menyeluruh, dengan tetap memastikan kualitas data melalui proses pemeriksaan nilai kosong (missing values), encoding kategori, dan normalisasi numerik.

Dataset ini selanjutnya digunakan dalam dua tahapan utama pemodelan. Pertama, algoritma K-Means Clustering diterapkan pada seluruh dataset untuk membagi pasien ke dalam tiga klaster berdasarkan tingkat risiko serangan jantung: rendah, sedang, dan tinggi. Kedua, data dari klaster risiko tinggi yang telah teridentifikasi digunakan sebagai input untuk proses klasifikasi dengan algoritma XGBoost, dengan tujuan memprediksi apakah pasien dalam kelompok tersebut benar-benar mengalami serangan jantung. Pendekatan ini dirancang untuk memaksimalkan akurasi prediksi dan mendalami pola risiko pada pasien dengan profil kesehatan yang mengkhawatirkan, khususnya di Indonesia.

Dengan skala data yang besar dan kompleksitas atribut yang tinggi, pemilihan sampel dalam penelitian ini dianggap representatif dan dapat dijadikan landasan kuat untuk mengembangkan sistem deteksi dini serangan jantung berbasis data mining.

3.4. Instrumen Penelitian

3.4.1. Studi Literatur

Studi literatur merupakan instrumen awal yang digunakan dalam penelitian ini untuk memperoleh dasar teori dan informasi konseptual yang mendukung perumusan masalah, pemilihan metode, dan pemaknaan hasil penelitian. Dalam konteks ini, studi literatur dilakukan dengan menelaah berbagai sumber ilmiah seperti jurnal internasional, prosiding, artikel akademik, dan buku teks yang relevan dengan topik prediksi penyakit jantung dan penerapan algoritma machine learning, khususnya K-Means dan XGBoost. Tujuan dari kegiatan ini adalah untuk memahami konsep dasar mengenai penyakit jantung, teknik clustering, metode klasifikasi, serta

penerapan data mining dalam bidang kesehatan. Selain itu, studi literatur juga berguna untuk melihat bagaimana penelitian sebelumnya menggunakan metode yang serupa, sehingga dapat dijadikan pembandingan dan rujukan dalam merancang pendekatan penelitian yang tepat. Proses penelusuran literatur dilakukan melalui platform ilmiah seperti Google Scholar, ScienceDirect, dan basis data jurnal nasional yang relevan.

3.4.2. Analisis Data

Instrumen berikutnya adalah proses analisis data, yang menjadi komponen inti dalam penelitian ini. Analisis dilakukan menggunakan bahasa pemrograman Python dengan bantuan platform komputasi awan Google Colaboratory. Analisis data mencakup beberapa tahapan penting, yaitu preprocessing data, penerapan algoritma K-Means untuk clustering, serta pelatihan dan pengujian model XGBoost untuk prediksi risiko serangan jantung. Dalam tahapan preprocessing, dilakukan pembersihan data, penanganan nilai kosong, normalisasi, serta encoding data kategorikal agar data siap diolah oleh algoritma. Selanjutnya, analisis menggunakan K-Means dilakukan untuk mengelompokkan pasien ke dalam beberapa cluster berdasarkan karakteristik kesehatan yang serupa. Hasil dari clustering ini, khususnya data dalam cluster risiko tinggi, kemudian digunakan dalam pelatihan model XGBoost untuk membangun sistem klasifikasi prediktif. Proses analisis dilakukan secara terstruktur dan berulang guna memastikan hasil yang akurat, dapat diuji, dan dapat direplikasi.

3.4.3. Visualisasi Model

Visualisasi data merupakan komponen krusial dalam penelitian ini karena membantu memperjelas pola, hubungan antar variabel, serta efektivitas model yang dibangun. Dalam konteks penelitian ini, visualisasi digunakan untuk menggambarkan hasil segmentasi risiko menggunakan algoritma K-Means Clustering serta menampilkan kinerja prediksi dari model XGBoost yang diterapkan pada kelompok pasien risiko tinggi. Visualisasi juga digunakan dalam analisis tambahan, seperti distribusi usia pasien, rata-rata risiko berdasarkan kelompok umur, hingga identifikasi fitur paling

berpengaruh dalam klasifikasi serangan jantung.

Seluruh proses visualisasi dilakukan dengan memanfaatkan pustaka Python, yaitu Matplotlib, Seaborn, dan Plotly, yang dikenal luas dalam bidang data science karena fleksibilitas dan kemampuannya menyajikan grafik yang informatif serta interaktif. Salah satu visualisasi penting adalah countplot yang menampilkan jumlah pasien dalam tiap cluster (rendah, sedang, tinggi) yang dibentuk oleh K-Means. Visualisasi ini berfungsi untuk memahami proporsi distribusi risiko dalam populasi data.

Selanjutnya, pada tahap klasifikasi dengan XGBoost, confusion matrix divisualisasikan untuk menunjukkan akurasi prediksi model terhadap pasien dalam kelompok risiko tinggi, yang dibagi menjadi dua kelas: mengalami serangan jantung atau tidak. Selain itu, bar chart dari classification report seperti precision, recall, dan F1-score memberikan gambaran performa masing-masing kelas, sekaligus membantu mendeteksi potensi bias atau ketidakseimbangan klasifikasi.

Visualisasi yang sangat esensial lainnya adalah grafik feature importance, yang menunjukkan variabel-variabel yang paling berkontribusi dalam proses prediksi oleh model XGBoost. Fitur-fitur seperti hipertensi, riwayat penyakit jantung, diabetes, kadar kolesterol, dan usia ditampilkan secara hierarkis, yang mempermudah pemahaman mengenai faktor dominan dalam model prediktif.

Visualisasi yang digunakan dalam penelitian ini tidak terbatas hanya pada analisis feature importance, tetapi juga mencakup berbagai jenis grafik yang mendukung proses pemahaman dan evaluasi model secara menyeluruh. Salah satu visualisasi yang digunakan adalah countplot dari pustaka Seaborn, yang menggambarkan jumlah pasien dalam setiap klaster hasil K-Means, yaitu risiko rendah, sedang, dan tinggi. Visualisasi ini bertujuan untuk melihat proporsi distribusi pasien berdasarkan hasil clustering, serta menjadi dasar dalam menentukan fokus analisis lanjutan pada klaster risiko tinggi.

Selanjutnya, untuk memberikan gambaran mengenai karakteristik usia pasien, digunakan histogram distribusi umur yang dibedakan berdasarkan

status serangan jantung. Visualisasi ini membantu mengidentifikasi kelompok umur yang paling banyak terdapat pada klaster risiko tinggi. Selain itu, dibuat pula barplot rata-rata risiko serangan jantung berdasarkan kelompok usia, yang bertujuan untuk mengetahui kecenderungan risiko serangan jantung secara umum di tiap rentang umur tertentu.

Yang tak kalah penting, digunakan heatmap untuk menampilkan nilai rata-rata indikator risiko seperti tekanan darah, gula darah puasa, kolesterol, dan lainnya pada masing-masing kelompok usia. Heatmap ini dibuat berdasarkan hasil agregasi data dan disajikan secara visual dalam bentuk matriks berwarna untuk mempermudah perbandingan antar kelompok usia terhadap berbagai variabel kesehatan. Dengan pendekatan visualisasi yang beragam ini, proses pemodelan menjadi lebih transparan dan mudah dievaluasi, baik dari sisi segmentasi data maupun klasifikasi.

Melalui pendekatan visualisasi ini, hasil penelitian dapat dikomunikasikan secara lebih efektif dan intuitif. Grafik dan visual yang disajikan membantu menjembatani hasil numerik dan interpretasi praktis, tidak hanya untuk kalangan akademik tetapi juga bagi praktisi medis yang mungkin terlibat dalam proses implementasi sistem prediksi risiko serangan jantung. Visualisasi juga menjadi alat bantu penting dalam proses validasi model dan mendukung argumentasi terhadap temuan yang dihasilkan dari penerapan metode K-Means dan XGBoost dalam penelitian ini.

3.5. Teknik Pengumpulan Data

Teknik pengumpulan data dalam penelitian ini dilakukan melalui pengumpulan data sekunder yang diperoleh dari sumber terbuka (open source). Dataset yang digunakan merupakan data kesehatan pasien yang telah disusun dalam format file CSV (Comma Separated Values) dan mencakup informasi medis serta kebiasaan hidup yang relevan dengan risiko penyakit jantung. Data ini diunduh dari platform penyedia dataset publik yang terpercaya, dan dipilih karena mengandung atribut lengkap dan valid untuk digunakan dalam penerapan algoritma K-Means dan XGBoost. Karena seluruh data diperoleh secara daring dan telah tersedia dalam bentuk digital,

maka proses pengumpulan data tidak memerlukan prosedur survei langsung atau wawancara kepada responden. Pengumpulan data dilakukan sekali, namun pengolahan dan eksplorasi dilakukan secara berulang untuk memastikan kualitas dan kebersihan data sesuai kebutuhan algoritma.

Tabel 2. Atribut dataset Heart Attack Prediction In Indonesia

No	Nama Variabel Data	Jenis Atribut	Tipe Atribut
1	Usia	Numerik	Rasio
2	Jenis Kelamin	Kategori	Nominal
3	Wilayah	Kategori	Nominal
4	Tingkat Pendapatan	Kategori	Nominal
5	Hipertensi	Kategori	Nominal
6	Diabetes	Kategori	Nominal
7	Tingkat Kolesterol	Numerik	Rasio
8	Obesitas	Kategori	Nominal
9	Lingkar Pinggang	Numerik	Rasio
10	Riwayat Keluarga	Kategori	Nominal
11	Status Merokok	Kategori	Nominal
12	Konsumsi Alkohol	Kategori	Nominal
13	Aktivitas Fisik	kategori	Nominal
14	Kegiatan Makan	Kategori	Nominal
15	Paparan Polusi Udara	Numerik	Rasio
16	Tingkat Stres	Kategori	Nominal
17	Jam Tidur	Numerik	Rasio
18	Tekanan Darah Sistolik	Numerik	Rasio
19	Tekanan Darah Diastolik	Numerik	Rasio
20	Gula Darah Puasa	Numerik	Rasio
21	Kolesterol Hdl	Numerik	Rasio

22	Kolestrol Ldl	Numerik	Rasio
23	Trigliserida	Numerik	Rasio
24	Hasil EKG	Kategori	Nominal
25	Penyakit Jantung Sebelumnya	Kategori	Nominal
26	Penggunaan Obat	Kategori	Nominal
27	Berpartisipasi Dalam Skrinning Gratis	Kategori	Nominal
28	Serangan Jantung	Kategori	Nominal

3.6. Teknik Analisis Data

Dalam proses pengolahan data kesehatan, khususnya untuk prediksi penyakit jantung, teknik analisis data memegang peran penting dalam menghasilkan model yang akurat dan bermanfaat. Analisis data bertujuan untuk mengolah, mengevaluasi, dan menginterpretasikan data mentah menjadi informasi bermakna yang dapat digunakan untuk membangun sistem prediksi yang andal. Tahapan ini meliputi proses pembersihan data (data cleaning), seleksi fitur (feature selection), transformasi data (data transformation), serta pemilihan dan pelatihan algoritma prediktif yang tepat.

Dengan semakin banyaknya data pasien dan kompleksitas atribut medis, pemanfaatan metode data mining seperti klasifikasi dan clustering menjadi sangat efektif dalam mengidentifikasi pola tersembunyi yang berkaitan dengan risiko penyakit jantung. Penggunaan gabungan antara algoritma K-Means untuk segmentasi pasien dan XGBoost untuk klasifikasi memberikan potensi peningkatan akurasi model serta interpretasi yang lebih baik terhadap kelompok pasien berisiko tinggi (Muzakki et al., 2024)

3.6.1. Pre Processing Data

Preprocessing merupakan tahap krusial dalam pengolahan data karena secara langsung memengaruhi kualitas dan kinerja model pembelajaran mesin. Dalam konteks prediksi penyakit jantung, preprocessing diperlukan untuk menangani tantangan umum pada data medis seperti nilai kosong (missing values), variabel kategorikal yang belum dalam format numerik,

serta ketidakseimbangan skala antar fitur numerik.

Dalam penelitian ini, preprocessing diawali dengan menghapus baris data yang memiliki nilai target “HeartAttack” yang kosong guna menjaga validitas proses pelatihan model. Selanjutnya, fitur-fitur kategorikal seperti Gender, PhysicalActivity, dan SmokingHabit dikonversi ke dalam format numerik menggunakan Label Encoding, agar dapat diolah oleh algoritma K-Means dan XGBoost. Sementara itu, fitur numerik seperti Age, Cholesterol, SleepHours, dan AirQualityIndex dinormalisasi menggunakan metode StandardScaler untuk menyamakan skala dan menghindari dominasi fitur tertentu terhadap proses pembelajaran model.

Selain itu, dilakukan proses seleksi fitur dengan mengeliminasi atribut yang bersifat administratif atau kurang relevan terhadap aspek klinis. Atribut yang dipilih difokuskan pada indikator medis dan kebiasaan hidup yang terbukti memiliki keterkaitan kuat terhadap serangan jantung. Pemilihan atribut yang tepat bertujuan untuk meningkatkan akurasi dan efisiensi model. Proses ini sejalan dengan hasil penelitian(Sami et al., 2021) yang menunjukkan bahwa teknik preprocessing seperti encoding, scaling, dan balancing data dapat meningkatkan akurasi prediksi penyakit jantung secara signifikan, dengan peningkatan lebih dari 2% pada model klasifikasi medis.

Tabel 3. Atribut Yang Digunakan

No	Nama Atribut	Status Penggunaan
1	Usia	Digunakan
2	Jenis Kelamin	Digunakan
3	Wilayah	Tidak Digunakan
4	Tingkat Pendapatan	Tidak Digunakan
5	Hipertensi	Digunakan
6	Diabetes	Digunakan
7	Tingkat Kolestrol	Digunakan
8	Obesitas	Digunakan

9	Lingkar Pinggang	Tidak Digunakan
10	Riwayat Keluarga	Digunakan
11	Status Merokok	Digunakan
12	Konsumsi Alkohol	Digunakan
13	Aktivitas Fisik	Digunakan
14	Kegiatan Makan	Tidak Digunakan
15	Paparan Polusi Udara	Digunakan
16	Tingkat Stres	Digunakan
17	Jam Tidur	Digunakan
18	Tekanan Darah Sistolik	Digunakan
19	Tekanan Darah Diastolik	Digunakan
20	Gula Darah Puasa	Digunakan
21	Kolesterol Hdl	Digunakan
22	Kolesterol Ldl	Digunakan
23	Trigliserida	Digunakan
24	Hasil EKG	Digunakan
25	Penyakit Jantung Sebelumnya	Digunakan
26	Penggunaan Obat	Digunakan
27	Berpartisipasi Dalam Skrining Gratis	Tidak Digunakan
28	Serangan Jantung	Label Target

3.6.2. Training Data dan Testing Data

Setelah data siap digunakan, tahap berikutnya adalah membagi dataset menjadi dua bagian utama: data latih (training set) dan data uji (testing set), dengan perbandingan umum yaitu 80% data untuk pelatihan dan 20% untuk pengujian. Pembagian dilakukan secara acak dengan menggunakan parameter `random_state` untuk menjamin reproduktifitas eksperimen. Pendekatan ini bertujuan untuk mengevaluasi performa model secara adil terhadap data yang

belum pernah dilihat sebelumnya, dan menghindari overfitting.

Pembagian ini penting, terutama untuk model klasifikasi seperti XGBoost yang sensitif terhadap distribusi data. Untuk mengatasi ketidakseimbangan kelas (imbalance), parameter `scale_pos_weight` juga digunakan, sebagaimana diterapkan dalam penelitian oleh (Bonthu et al., 2024), yang menunjukkan peningkatan akurasi model setelah penerapan penyesuaian bobot kelas minoritas.

3.6.3. Modelling

a. K-Means Clustering untuk Segmentasi Risiko

K-Means digunakan sebagai metode unsupervised learning untuk mengelompokkan pasien ke dalam tiga klaster berdasarkan kemiripan atribut, yaitu klaster risiko rendah, sedang, dan tinggi. Jumlah cluster ($K=3$) dipilih berdasarkan pengetahuan domain medis dan kebutuhan analisis lanjutan. Proses ini memanfaatkan fitur numerik yang telah dinormalisasi dan bertujuan memberikan segmentasi awal populasi pasien berdasarkan kemiripan profil medis.

b. XGBoost untuk Klasifikasi Risiko Tinggi

Setelah segmentasi risiko dengan K-Means, data dari klaster risiko tinggi digunakan sebagai input model klasifikasi menggunakan algoritma XGBoost. Algoritma ini terkenal dalam kompetisi data science karena kemampuannya dalam menangani data besar, tidak seimbang, dan kompleks. Proses training dilakukan dengan supervised learning, di mana model dilatih menggunakan data berlabel (HeartAttack: 0 atau 1). Hyperparameter tuning dengan eksplorasi terhadap learning rate, max depth, subsample, dan jumlah estimators. (Zang et al., 2023).

3.6.4. Evaluasi Model

Evaluasi model XGBoost dilakukan menggunakan metrik: akurasi, precision, recall, F1-score, dan confusion matrix. Akurasi menunjukkan seberapa besar prediksi yang benar, precision menunjukkan proporsi prediksi positif yang tepat, recall menunjukkan kemampuan model dalam menangkap semua kasus positif, dan F1-score menyeimbangkan precision dan recall.

Selain itu, confusion matrix digunakan untuk melihat performa prediksi terhadap masing-masing kelas (positif dan negatif). Evaluasi ini bertujuan memastikan model memiliki kemampuan generalisasi yang baik, tidak hanya hafal terhadap data latih.

3.6.5. Analisis Feature Importance

Analisis feature importance digunakan untuk mengetahui fitur mana yang paling berkontribusi dalam prediksi risiko serangan jantung oleh model XGBoost. Fitur-fitur dengan kontribusi tertinggi ditampilkan dalam bentuk grafik batang (bar plot). Pengetahuan ini berguna untuk interpretasi hasil medis serta mendukung pengambilan keputusan oleh praktisi kesehatan. Berdasarkan temuan dalam studi oleh (P & R, 2024), fitur-fitur seperti kadar kolesterol, BMI, tekanan darah, dan gaya hidup merupakan variabel yang konsisten muncul sebagai indikator penting dalam model prediksi penyakit jantung.

BAB IV

HASIL DAN ANALISIS

4.1. Hasil Penelitian

Penelitian ini bertujuan untuk mengidentifikasi pola pasien dengan risiko tinggi terhadap serangan jantung melalui proses pengelompokan dan klasifikasi berbasis data. Proses tersebut dilakukan dengan menggabungkan dua pendekatan utama, yaitu K-Means Clustering untuk mengelompokkan pasien berdasarkan kesamaan karakteristik kesehatannya, serta XGBoost sebagai model klasifikasi untuk memprediksi kemungkinan serangan jantung pada kelompok risiko tinggi. Dengan menerapkan metode ini, diharapkan penelitian dapat memberikan kontribusi terhadap deteksi dini pasien yang memiliki risiko tinggi, sehingga dapat membantu dalam pengambilan keputusan medis yang lebih cepat dan tepat.


Dalam membangun sistem prediksi ini, penelitian menggunakan pendekatan OSEMN (Obtain, Scrub, Explore, Model, Interpret), yang merupakan kerangka sistematis dalam analisis data. Tahapan ini mencakup proses pengumpulan data dari dataset kesehatan yang relevan (Obtain), pembersihan data dari atribut yang tidak diperlukan serta penanganan data kategorikal (Scrub), eksplorasi dan pemahaman struktur serta pola data (Explore), penerapan algoritma K-Means Clustering untuk mengelompokkan pasien berdasarkan kemiripan kondisi (Model 1), dan dilanjutkan dengan penggunaan XGBoost pada kelompok pasien berisiko tinggi untuk meningkatkan presisi klasifikasi (Model 2), serta diakhiri dengan tahap interpretasi dan evaluasi hasil prediksi dan fitur yang berkontribusi besar terhadap risiko serangan jantung (Interpret).

Pengelompokan menggunakan K-Means menghasilkan tiga kategori risiko: rendah, sedang, dan tinggi, yang selanjutnya dianalisis berdasarkan distribusi dan proporsi pasien yang mengalami serangan jantung. Setelah itu, data dari cluster risiko tinggi digunakan sebagai input pada model XGBoost, yang dievaluasi menggunakan metrik seperti akurasi, confusion matrix, precision, recall, dan f1-score. Selain itu, fitur penting yang berkontribusi

terhadap prediksi juga dianalisis untuk mengidentifikasi faktor dominan pada kelompok berisiko tinggi.

Adapun setiap tahapan tersebut akan dijabarkan secara terstruktur dan terperinci dalam subbagian-subbagian berikut, dimulai dari proses pemuatan data hingga analisis hasil prediksi dan distribusi risiko berdasarkan kelompok usia dan indikator kesehatan.

4.1.1. Penyesuaian Bahasa Atribut dan Nilai Kategorikal Dataset



```
import pandas as pd

# Baca file CSV asli
df = pd.read_csv('heart_attack_prediction_indonesia.csv')


# Terjemahan nama kolom ke Bahasa Indonesia
column_translation = {
    'age': 'usia',
    'gender': 'jenis_kelamin',
    'region': 'wilayah',
    'income_level': 'tingkat_pendapatan',
    'hypertension': 'hipertensi',
    'diabetes': 'diabetes',
    'cholesterol_level': 'kadar_kolesterol',
    'obesity': 'obesitas',
    'waist_circumference': 'lingkar_pinggang',
    'family_history': 'riwayat_keluarga',
    'smoking_status': 'status_merokok',
    'alcohol_consumption': 'konsumsi_alkohol',
    'physical_activity': 'aktivitas_fisik',
    'dietary_habits': 'pola_makan',
    'air_pollution_exposure': 'paparan_polusi_udara',
    'stress_level': 'tingkat_stres',
    'sleep_hours': 'jam_tidur',
    'blood_pressure_systolic': 'tekanan_darah_sistolik',
    'blood_pressure_diastolic': 'tekanan_darah_diastolik',
    'fasting_blood_sugar': 'gula_darah_puasa',
    'cholesterol_hdl': 'kolesterol_hdl',
    'cholesterol_ldl': 'kolesterol_ldl',
    'triglycerides': 'trigliserida',
    'EKG_results': 'hasil_EKG',
    'previous_heart_disease': 'riwayat_penyakit_jantung',
    'medication_usage': 'penggunaan_obat',
    'participated_in_free_screening': 'ikut_skrining_gratis',
    'heart_attack': 'serangan_jantung'
}
```

Gambar 4. Penyesuaian Bahasa Atribut dan Nilai Kategori

Dalam penelitian ini, dilakukan penyesuaian bahasa pada dataset agar seluruh atribut dan nilai kategorikal yang semula berbahasa Inggris dapat dipahami secara lebih mudah dalam konteks lokal. Proses ini mencakup dua tahapan utama, yaitu translasi nama kolom (atribut) dan translasi nilai kategorikal pada kolom-kolom tertentu. Nama kolom seperti age, gender, dan cholesterol_level diubah menjadi usia, jenis_kelamin, dan kadar_kolesterol, sedangkan nilai kategorikal seperti Male, Urban, High, dan Healthy diterjemahkan menjadi Laki-laki, Perkotaan, Tinggi, dan Sehat.

Langkah ini dilakukan untuk menjaga konsistensi dan keterbacaan data selama proses analisis, khususnya ketika data tersebut digunakan dalam visualisasi, interpretasi model, atau penyusunan laporan penelitian berbahasa Indonesia. Selain itu, translasi ini juga penting agar pembaca yang tidak akrab dengan istilah asing tetap dapat memahami makna dari setiap atribut dan kategori yang dianalisis. Proses translasi dilakukan menggunakan fungsi `rename()` dan `replace()` dari pustaka Python `pandas`, dan hasilnya disimpan dalam file baru dengan nama `heart_attack_translated_full.csv` yang akan digunakan dalam tahap-tahap selanjutnya.

4.1.2. Import Library dan Dataset



The screenshot shows a Jupyter Notebook interface with the following code in the cell:

```
# Import library dasar untuk pengolahan data dan visualisasi
import pandas as pd          # Untuk membaca dan mengelola data tabel
import numpy as np           # Untuk operasi matematis dan array
import matplotlib.pyplot as plt # Untuk membuat grafik
import seaborn as sns        # Untuk visualisasi data statistik

# Import library untuk algoritma machine learning
from sklearn.preprocessing import LabelEncoder, StandardScaler # Untuk encoding dan normalisasi
from sklearn.cluster import KMeans                             # Untuk K-Means Clustering
from sklearn.model_selection import train_test_split            # Untuk pembagian data latih dan uji
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix # Evaluasi model

from xgboost import XGBClassifier                               # Untuk algoritma XGBoost

import warnings
warnings.filterwarnings('ignore') # Menonaktifkan peringatan agar output lebih bersih

# Membaca data CSV yang telah diunggah
df = pd.read_csv('heart_attack_prediction_indonesia.csv') # Membaca dataset utama

# Menampilkan 5 baris pertama data untuk verifikasi awal
df.head()
```

Below the code, the first five rows of the dataset are displayed as a table:

	usia	jenis_kelamin	wilayah	tingkat_pendapatan	hipertensi	diabetes	kadar_kolesterol	obesitas	lingkar_pinggang	riwayat_keluarga
0	60	Laki-laki	Pedesaan	Menengah	0	1	211	0	83	0
1	53	Perempuan	Perkotaan	Rendah	0	0	208	0	106	1
2	62	Perempuan	Perkotaan	Rendah	0	0	231	1	112	1
3	73	Laki-laki	Perkotaan	Rendah	1	0	202	0	82	1
4	52	Laki-laki	Perkotaan	Menengah	1	0	232	0	89	0

Gambar 5. Import Library dan Dataset

Penelitian ini diawali dengan melakukan proses import beberapa pustaka (library) Python yang esensial untuk pengolahan data, analisis statistik, visualisasi, serta penerapan algoritma pembelajaran mesin. Tahapan ini menjadi fondasi utama dari keseluruhan proses penelitian karena setiap pustaka memiliki fungsi spesifik dalam mendukung alur kerja mulai dari prapemrosesan hingga evaluasi model prediksi.

Pustaka pertama yang digunakan adalah `pandas`, yang berperan penting dalam membaca, membersihkan, dan mengelola data dalam bentuk data frame. Dalam konteks penelitian ini, `pandas` digunakan untuk memuat dataset kesehatan pasien dari file CSV, mengecek informasi awal dataset, menghapus atribut yang tidak relevan, serta memisahkan fitur dan target. Pustaka ini menjadi tulang punggung dalam manipulasi data tabular yang akan digunakan pada tahap preprocessing dan analisis.

Selanjutnya digunakan `numpy`, sebuah pustaka Python yang berfungsi untuk melakukan operasi numerik dan manipulasi array multidimensi secara efisien. `Numpy` digunakan dalam berbagai proses seperti transformasi data, perhitungan rata-rata risiko serangan jantung berdasarkan kelompok usia, serta mengurutkan skor pentingnya fitur dari model prediksi.

Untuk visualisasi, digunakan `matplotlib.pyplot` dan `seaborn`. Kedua pustaka ini membantu dalam menyajikan grafik yang informatif dan menarik, seperti distribusi pasien berdasarkan cluster risiko, heatmap indikator risiko berdasarkan kelompok usia, dan visualisasi fitur penting yang dihasilkan oleh model `XGBoost`. Visualisasi ini penting untuk membantu interpretasi hasil penelitian secara intuitif dan mendalam.

Dalam penelitian ini, digunakan juga beberapa modul dari `scikit-learn` (`sklearn`), pustaka pembelajaran mesin yang populer untuk analisis data:

1. `KMeans`

Digunakan sebagai algoritma `unsupervised learning` untuk mengelompokkan pasien ke dalam tiga cluster berdasarkan kemiripan atribut medis. Hasil clustering ini kemudian diinterpretasikan menjadi tiga tingkat risiko: rendah, sedang, dan tinggi.

2. `StandardScaler`

Digunakan untuk melakukan normalisasi data numerik agar semua fitur berada dalam skala yang sebanding. Ini penting karena algoritma `K-Means` dan `XGBoost` sensitif terhadap skala fitur.

3. `train_test_split`

Digunakan untuk membagi data cluster risiko tinggi ke dalam set pelatihan

dan pengujian, yang diperlukan untuk membangun dan menguji model klasifikasi XGBoost.


4. `confusion_matrix`, `classification_report`, `accuracy_score`
Digunakan untuk mengevaluasi performa model prediksi berdasarkan metrik akurasi, presisi, recall, dan f1-score.

Model klasifikasi yang digunakan adalah XGBoostClassifier dari pustaka xgboost, sebuah algoritma boosting yang terkenal karena performanya yang tinggi dalam klasifikasi data tabular. XGBoost dilatih menggunakan data dari cluster risiko tinggi, dengan tujuan untuk memprediksi apakah seorang pasien berpotensi tinggi mengalami serangan jantung berdasarkan fitur-fitur yang tersedia.

Setelah semua pustaka berhasil diimpor, langkah selanjutnya adalah memuat dataset utama yang berjudul `heart_attack_prediction_indonesia.csv`. Dataset ini berisi informasi medis dan kebiasaan hidup pasien yang berkaitan dengan risiko penyakit jantung. Pembacaan data dilakukan dengan fungsi `read_csv()` dari pandas, yang secara otomatis mengkonversi file CSV menjadi data frame di Python.

Sebagai langkah verifikasi, ditampilkan lima baris pertama dari dataset menggunakan fungsi `head()` untuk memastikan bahwa proses pembacaan berhasil, struktur data sesuai, dan tidak terdapat kesalahan pada format kolom atau nilai. Langkah ini menjadi dasar bagi proses selanjutnya seperti pembersihan data, pengelompokan dengan K-Means, serta pelatihan model prediksi menggunakan XGBoost.

4.1.3. Menampilkan Informasi Umum Dataset



```
Optimasi_prediksi_risikotinggi_seranganjantung.ipynb
File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all

# Melihat dimensi dan tipe data
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 158355 entries, 0 to 158354
Data columns (total 28 columns):
#   Column                Non-Null Count  Dtype
---  -
0   usia                  158355 non-null  int64
1   jenis_kelamin         158355 non-null  object
2   wilayah               158355 non-null  object
3   tingkat_pendapatan    158355 non-null  object
4   hipertensi            158355 non-null  int64
5   diabetes              158355 non-null  int64
6   kadar_kolesterol       158355 non-null  int64
7   obesitas              158355 non-null  int64
8   lingkar_pinggang       158355 non-null  int64
9   riwayat_keluarga      158355 non-null  int64
10  status_merokok         158355 non-null  object
11  konsumsi_alkohol       63507 non-null   object
12  aktivitas_fisik        158355 non-null  object
13  pola_makan             158355 non-null  object
14  paparan_polusi_udara    158355 non-null  object
15  tingkat_stres          158355 non-null  object
16  jam_tidur              158355 non-null  float64
17  tekanan_darah_sistolik  158355 non-null  int64
18  tekanan_darah_diastolik 158355 non-null  int64
19  gula_darah_puasa        158355 non-null  int64
20  kolesterol_hdl          158355 non-null  int64
21  kolesterol_ldl          158355 non-null  int64
22  trigliserida           158355 non-null  int64
23  hasil_EKG              158355 non-null  object
24  riwayat_penakit_jantung 158355 non-null  int64
25  penggunaan_obat         158355 non-null  int64
26  ikut_skrining_gratis    158355 non-null  int64
27  serangan_jantung       158355 non-null  int64
dtypes: float64(1), int64(17), object(10)
memory usage: 33.8+ MB
```

Gambar 6. Informasi Umum Dataset

Setelah dataset berhasil dimuat ke dalam lingkungan kerja Google Colab menggunakan pustaka pandas, langkah selanjutnya adalah melakukan pemeriksaan struktur umum data dengan tujuan untuk memahami susunan, jumlah, dan tipe data setiap atribut yang tersedia. Tahap ini merupakan bagian dari proses eksplorasi awal sebelum dilakukan pemodelan machine learning, dan berperan penting dalam memastikan bahwa data memiliki struktur yang sesuai serta bebas dari nilai kosong (missing values).

Pemeriksaan ini dilakukan menggunakan fungsi `df.info()` yang disediakan oleh pustaka pandas. Fungsi ini memberikan ringkasan informasi penting mengenai dataset, seperti jumlah total baris data (entri), jumlah kolom, nama kolom, jumlah nilai non-null untuk setiap kolom, tipe data masing-masing kolom, serta estimasi penggunaan memori dataset secara keseluruhan. Informasi ini sangat bermanfaat untuk mendeteksi potensi


masalah awal, seperti adanya data yang kosong, kolom bertipe objek yang seharusnya numerik, atau ketidaksesuaian format data lainnya.

Berdasarkan hasil output `df.info()` pada dataset Heart Attack Prediction in Indonesia, diketahui bahwa dataset terdiri dari sejumlah atribut yang berkaitan dengan faktor risiko kesehatan pasien. Beberapa atribut utama mencakup usia, tekanan darah, kadar kolesterol, status merokok, tingkat stres, serta hasil tes kesehatan lainnya. Atribut target dalam dataset ini adalah `Serangan_jantung`, yang menunjukkan apakah seorang pasien pernah mengalami serangan jantung (1) atau tidak (0).

Dari hasil pemeriksaan, dapat dilihat bahwa sebagian besar kolom bertipe `float64` atau `int64`, yang berarti data siap untuk dianalisis menggunakan algoritma machine learning tanpa perlu konversi tipe data tambahan. Selain itu, jika tidak ditemukan nilai kosong (semua kolom memiliki jumlah data non-null yang sama dengan jumlah baris), maka proses pembersihan data dapat dilakukan dengan lebih efisien tanpa perlu melakukan imputasi nilai.

Struktur data yang jelas, lengkap, dan konsisten ini menjadi landasan yang kuat untuk tahapan berikutnya dalam proses analisis, yaitu tahap preprocessing dan clustering menggunakan algoritma K-Means, serta tahap klasifikasi menggunakan XGBoost. Informasi awal ini memastikan bahwa dataset telah memenuhi kriteria minimum untuk dianalisis dalam kerangka kerja OSEMN dan mendukung proses pengambilan keputusan berbasis data yang lebih akurat.

4.1.4. Menghapus Kolom Tidak Relevan



```
# Menghapus kolom yang tidak digunakan dalam pemodelan
df.drop(columns=[
    'wilayah',           # Wilayah
    'tingkat_pendapatan', # Tingkat Pendapatan
    'lingkar_pinggang',   # Lingkar Pinggang
    'pola_makan',         # Kegiatan Makan
    'penggunaan_obat',    # Penggunaan Obat
    'ikut_skrining_gratis' # Berpartisipasi Dalam Skrining Gratis
], inplace=True, errors='ignore')

# Menampilkan data setelah kolom dihapus
df.head()
```

	usia	jenis_kelamin	hipertensi	diabetes	kadar_kolesterol	obesitas	riwayat_keluarga	status_merokok	konsumsi_alkohol	aktivitas_fisik
0	60	Laki-laki	0	1	211	0	0	Tidak Pernah	NaN	Tinggi
1	53	Perempuan	0	0	208	0	1	Dulu	NaN	Sedang
2	62	Perempuan	0	0	231	1	1	Dulu	Sedang	Sedang
3	73	Laki-laki	1	0	202	0	1	Tidak Pernah	Sedang	Sedang
4	52	Laki-laki	1	0	232	0	0	Saat Ini	Sedang	Sedang

5 rows x 22 columns

Gambar 7. Hapus Kolom Atribut Yang Tidak Digunakan


Dalam proses analisis data, penting untuk memastikan bahwa hanya atribut-atribut yang relevan dan berkontribusi terhadap proses prediksi yang disertakan dalam pemodelan. Atribut yang bersifat administratif, tidak memiliki nilai informatif terhadap target, atau bersifat duplikatif perlu dihapus agar tidak mengganggu proses pembelajaran mesin dan untuk mencegah terjadinya bias dalam hasil prediksi. Oleh karena itu, pada tahap ini dilakukan proses penghapusan beberapa kolom yang dianggap tidak relevan atau tidak signifikan dalam konteks prediksi risiko serangan jantung.

Berdasarkan hasil eksplorasi sebelumnya, beberapa kolom dalam dataset seperti Wilayah, Tingkat pendapatan, Lingkar pinggang, Kegiatan makan, Penggunaan obat, dan Berpartisipasi dalam skrining gratis dinilai tidak memberikan kontribusi langsung terhadap outcome Serangan_jantung, atau memiliki struktur data yang tidak mendukung analisis numerik. Oleh sebab itu, kolom-kolom tersebut dihapus dari dataset sebelum dilakukan proses encoding dan normalisasi.

Penghapusan kolom ini dilakukan menggunakan fungsi `drop()` dari pustaka `pandas`. Fungsi ini secara otomatis menghapus kolom yang ditentukan dari dataframe dan memastikan bahwa hanya fitur yang penting dan representatif yang disertakan dalam proses pembelajaran model. Dengan

mengurangi kompleksitas data sejak awal, efisiensi komputasi dapat ditingkatkan dan risiko overfitting pada model dapat diminimalkan. Setelah kolom-kolom yang tidak digunakan dihapus, dataset menjadi lebih siap untuk tahap selanjutnya, yaitu transformasi data dan pemodelan machine learning.

4.1.5. Encoding dan Normalisasi Data



```

# Encoding data kategorikal (Label Encoding)
from sklearn.preprocessing import LabelEncoder

# Deteksi kolom kategorikal
categorical_cols = df.select_dtypes(include=['object']).columns
label_encoders = {}

for col in categorical_cols:
    le = LabelEncoder()
    df[col] = le.fit_transform(df[col])
    label_encoders[col] = le

# Normalisasi fitur numerik (StandardScaler)
from sklearn.preprocessing import StandardScaler

# Pisahkan fitur dan target
features = df.drop(columns=['serangan_jantung']) # Ganti dengan nama kolom target versi Indonesia
target = df['serangan_jantung'] # Kolom target untuk klasifikasi

# Terapkan normalisasi
scaler = StandardScaler()
scaled_features = scaler.fit_transform(features)

# Konversi hasil normalisasi ke DataFrame
df_normalized = pd.DataFrame(scaled_features, columns=features.columns)

# Tampilkan 5 baris pertama hasil normalisasi
df_normalized.head()

```

	usia	jenis_kelamin	hipertensi	diabetes	kadar_kolesterol	obesitas	riwayat_keluarga	status_merokok	konsumsi_alkohol	aktivitas_fisik
0	0.458088	-0.962004	-0.653202	2.001224	0.288563	-0.577197	-0.654993	0.904222	0.779610	1.598746
1	-0.129611	1.039496	-0.653202	-0.499694	0.213067	-0.577197	1.526733	-1.510967	0.779610	0.265300

Gambar 8. Proses Encoding dan Normalisasi Data

Setelah kolom-kolom yang tidak relevan dihapus, langkah berikutnya dalam tahap preprocessing adalah mengubah data kategorikal ke dalam bentuk numerik melalui proses encoding, dan menyamakan skala nilai fitur numerik dengan normalisasi. Kedua proses ini sangat penting dalam memastikan bahwa data siap digunakan oleh algoritma machine learning, yang umumnya hanya dapat bekerja dengan input numerik dan sensitif terhadap perbedaan skala antar fitur.

a. Encoding

Beberapa atribut dalam dataset, seperti jenis kelamin, status merokok, riwayat keluarga, serta kategori gaya hidup lainnya, merupakan data kategorikal yang memiliki nilai dalam bentuk teks. Data seperti ini perlu dikonversi ke format numerik agar dapat dikenali oleh model. Pada


penelitian ini digunakan teknik Label Encoding, yaitu metode yang mengubah nilai kategori menjadi representasi angka sederhana. Label encoding dipilih karena lebih ringan dan cukup efektif untuk dataset yang tidak mengandung variabel kategorikal dengan relasi ordinal kompleks.

b. Normalisasi

Setelah proses encoding selesai, langkah berikutnya adalah normalisasi fitur numerik menggunakan metode StandardScaler dari pustaka sklearn.preprocessing. StandardScaler bekerja dengan cara mengubah nilai setiap fitur sehingga memiliki rata-rata (mean) 0 dan standar deviasi 1, yang membuat distribusi setiap fitur berada dalam skala yang setara. Normalisasi ini penting karena algoritma seperti K-Means dan XGBoost dapat dipengaruhi secara signifikan jika satu fitur memiliki skala yang jauh lebih besar dibanding fitur lainnya.

Dengan melakukan encoding dan normalisasi, dataset menjadi seragam dan lebih optimal untuk diproses oleh algoritma machine learning yang akan digunakan pada tahap selanjutnya, yaitu proses clustering dan klasifikasi.

4.1.6. Clustering dengan Algoritma K-Means



The screenshot shows a Jupyter Notebook interface with a code cell containing Python code for K-Means clustering. The code imports KMeans from sklearn.cluster and pandas as pd. It then applies K-Means to a dataset with 3 clusters and random_state=42. The result is added to the original dataframe as a 'cluster' column. Finally, the first 5 rows of the dataframe are displayed, showing the original features and the assigned cluster.

```
# =====  
# Clustering dengan Algoritma K-Means  
# =====  
from sklearn.cluster import KMeans  
import pandas as pd  
  
# Terapkan K-Means pada data hasil normalisasi  
kmeans = KMeans(n_clusters=3, random_state=42)  
clusters = kmeans.fit_predict(df_normalized)  
  
# Tambahkan hasil cluster ke dataframe asli  
df['cluster'] = clusters  
  
# Menampilkan 5 baris pertama untuk melihat hasil cluster  
df[['usia', 'tekanan_darah_sistolik', 'kolesterol_ldl', 'cluster']].head()
```

	usia	tekanan_darah_sistolik	kolesterol_ldl	cluster
0	60	113	121	2
1	53	132	83	1
2	62	116	130	0
3	73	136	85	0
4	52	127	127	0

Gambar 9. Clustering Dengan Algoritma K-Means

Setelah data berhasil diproses melalui tahapan encoding dan normalisasi, langkah selanjutnya adalah melakukan proses pengelompokan (clustering) menggunakan algoritma K-Means Clustering. Algoritma ini merupakan salah satu metode unsupervised learning yang bertujuan untuk membagi data ke dalam sejumlah kelompok (cluster) berdasarkan kemiripan nilai antar fitur. Dalam penelitian ini, K-Means digunakan untuk mengelompokkan pasien berdasarkan karakteristik kesehatannya ke dalam tiga tingkat risiko serangan jantung: rendah, sedang, dan tinggi.


K-Means bekerja dengan menentukan pusat cluster (centroid) secara acak, lalu mengelompokkan data berdasarkan jarak terdekat ke centroid tersebut. Proses ini akan terus berulang hingga posisi centroid tidak lagi berubah signifikan. Pada implementasinya, digunakan parameter `n_clusters=3` untuk menentukan jumlah cluster yang diinginkan. Angka 3

dipilih berdasarkan tujuan penelitian yang ingin membedakan antara risiko rendah, sedang, dan tinggi.

Setelah proses clustering selesai, hasil pengelompokan (cluster ID) ditambahkan ke dalam dataset sebagai kolom baru bernama cluster. Untuk memahami makna dari masing-masing cluster, dilakukan perhitungan rata-rata nilai target (Serangan Jantung) pada setiap cluster. Semakin tinggi rata-rata nilai Serangan_jantung pada suatu cluster, maka cluster tersebut dianggap sebagai kelompok dengan risiko serangan jantung yang tinggi. Dengan demikian, dilakukan mapping hasil cluster ke label risiko berupa 'Rendah', 'Sedang', dan 'Tinggi'.

Proses ini penting karena menjadi dasar dalam seleksi data pasien berisiko tinggi yang kemudian akan dianalisis lebih lanjut menggunakan algoritma klasifikasi XGBoost pada tahap selanjutnya. Hasil pengelompokan juga divisualisasikan dalam bentuk diagram batang (bar plot) untuk menunjukkan distribusi jumlah pasien pada masing-masing cluster risiko.


Setelah proses clustering selesai dan masing-masing cluster diberikan label risiko berdasarkan rata-rata kasus serangan jantung, dilakukan visualisasi dalam bentuk grafik batang untuk menunjukkan distribusi jumlah pasien pada tiap kelompok risiko. Gambar di bawah ini memperlihatkan bahwa sebagian besar pasien termasuk dalam kategori risiko rendah, diikuti oleh kelompok risiko tinggi dan sedang. Grafik ini membantu memberikan gambaran awal mengenai proporsi populasi pasien berdasarkan tingkat kerentanannya terhadap serangan jantung.



Gambar 10. Grafik Bar Clustering dengan K-Means

Berdasarkan hasil clustering menggunakan algoritma K-Means, jumlah data pasien pada masing-masing cluster adalah sebagai berikut: cluster risiko rendah terdiri atas 57.526 pasien, cluster risiko sedang berjumlah 53.104 pasien, dan cluster risiko tinggi mencakup 47.725 pasien. Meskipun cluster risiko tinggi memiliki jumlah pasien paling sedikit dibandingkan dua cluster lainnya, kelompok ini menjadi perhatian utama dalam penelitian ini. Hal ini dikarenakan cluster tersebut merepresentasikan pasien dengan karakteristik kesehatan yang mengindikasikan potensi lebih besar terhadap serangan jantung. Oleh karena itu, analisis lanjutan dengan algoritma XGBoost difokuskan pada kelompok ini guna menghasilkan model prediksi yang lebih akurat dan terarah untuk mendukung deteksi dini risiko serangan jantung.

4.1.7. Seleksi Data Cluster Risiko Tinggi



```
# Seleksi data dari cluster yang berisiko tinggi
df_high_risk = df[df['cluster_label'] == 'Tinggi']

# Tampilkan 5 baris pertama dari cluster risiko tinggi
df_high_risk.head()
```

	usia	jenis_kelamin	hipertensi	diabetes	kadar_kolesterol	obesitas	r
2	62	1	0	0	231	1	
3	73	0	1	0	202	0	
4	52	0	1	0	232	0	
6	73	1	0	0	238	1	
8	49	1	0	0	186	0	

5 rows x 24 columns


Gambar 11. Data Pasien dari Cluster Risiko Tinggi

Setelah proses clustering dilakukan dan masing-masing pasien telah dikelompokkan ke dalam kategori risiko rendah, sedang, dan tinggi, langkah berikutnya dalam penelitian ini adalah melakukan seleksi terhadap data pasien yang tergolong dalam cluster risiko tinggi. Proses seleksi ini penting karena fokus utama penelitian adalah membangun model klasifikasi untuk memprediksi kemungkinan serangan jantung secara lebih spesifik pada pasien yang memiliki kecenderungan risiko tinggi.

Pemilihan cluster risiko tinggi dilakukan berdasarkan hasil perhitungan rata-rata nilai Serangan_jantung pada masing-masing cluster, di mana cluster dengan nilai rata-rata tertinggi dianggap sebagai kelompok paling rentan. Setelah cluster dengan label Tinggi teridentifikasi, data dari kelompok ini dipisahkan menjadi subset tersendiri. Subset ini akan digunakan secara khusus untuk proses klasifikasi menggunakan algoritma XGBoost pada tahap selanjutnya.

Dengan menyaring data hanya dari cluster risiko tinggi, model klasifikasi dapat lebih fokus dalam membedakan pasien yang benar-benar mengalami serangan jantung dan yang belum, namun berada dalam kelompok rentan. Hal ini diharapkan mampu meningkatkan presisi prediksi dan efektivitas sistem deteksi dini serangan jantung.

4.1.8. Klasifikasi dengan Algoritma XGBoost



```

# -----
# 5. Pemodelan XGBoost untuk Cluster Risiko Tinggi (dengan tuning)
# -----

from xgboost import XGBClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Gunakan hanya data dari cluster 'Tinggi'
# Sudah diproses sebelumnya dan disimpan sebagai df_high_risk
X = df_high_risk.drop(columns=['serangan_jantung', 'cluster', 'cluster_label'])
y = df_high_risk['serangan_jantung']

# Split data training dan testing
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

# Inisialisasi model XGBoost dengan hyperparameter tuning
model = XGBClassifier(
    eval_metric='logloss',
    learning_rate=0.1,
    max_depth=6,
    n_estimators=200,
    subsample=0.8,
    colsample_bytree=0.8
)

# Latih model
model.fit(X_train, y_train)

# Prediksi data test
y_pred = model.predict(X_test)

# Evaluasi model
print("Akurasi:", accuracy_score(y_test, y_pred))
print("\nConfusion Matrix:\n", confusion_matrix(y_test, y_pred))
print("\nClassification Report:\n", classification_report(y_test, y_pred))

```

Akurasi: 0.7242535358826611

Confusion Matrix:

```
[[4555 1143]
 [1489 2358]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.75	0.80	0.78	5698
1	0.67	0.61	0.64	3847
accuracy			0.72	9545
macro avg	0.71	0.71	0.71	9545
weighted avg	0.72	0.72	0.72	9545

Gambar 12. Hasil Klasifikasi dengan XGBoost

Setelah data dari cluster risiko tinggi berhasil dipisahkan menggunakan algoritma K-Means, tahap selanjutnya dalam penelitian ini adalah membangun model klasifikasi menggunakan algoritma XGBoost (Extreme Gradient Boosting). XGBoost merupakan salah satu metode supervised learning berbasis pohon keputusan yang dikenal luas karena efisiensinya dalam pengolahan data skala besar, kemampuannya menghasilkan model yang akurat, serta ketangguhannya dalam menghindari masalah overfitting. Dalam penelitian ini, XGBoost digunakan secara khusus untuk memprediksi apakah pasien yang tergolong dalam kelompok risiko tinggi benar-benar mengalami serangan jantung atau tidak, berdasarkan kombinasi indikator medis dan gaya hidup yang telah melalui proses encoding dan normalisasi sebelumnya.

Dataset yang digunakan pada tahap klasifikasi ini berasal dari `df_high_risk`, yaitu subset dari data asli yang hanya mencakup pasien dengan label risiko tinggi berdasarkan hasil pengelompokan K-Means. Proses klasifikasi diawali dengan memisahkan variabel independen (fitur) dan variabel dependen (target). Fitur mencakup seluruh atribut kecuali `Serangan_jantung`, `cluster`, dan `cluster_label`, sementara kolom `Serangan_jantung` digunakan sebagai target yang ingin diprediksi. Selanjutnya, data dibagi menjadi data latih dan data uji menggunakan fungsi `train_test_split` dengan rasio 80:20. Pembagian ini bertujuan untuk menguji generalisasi model terhadap data yang belum pernah dilatih sebelumnya.

Untuk memperoleh model yang optimal dan meningkatkan akurasi prediksi, dilakukan proses hyperparameter tuning terhadap model XGBoost. Tuning ini mencakup beberapa parameter penting seperti `learning_rate`, `max_depth`, `n_estimators`, `subsample`, dan `colsample_bytree`, yang masing-masing memiliki pengaruh signifikan terhadap kompleksitas dan performa model. Dengan melakukan tuning terhadap hyperparameter ini, model dapat menemukan kombinasi terbaik yang seimbang antara bias dan varians, sehingga mampu menghasilkan prediksi yang lebih akurat dan stabil.

Setelah proses pelatihan selesai, model diuji menggunakan data uji untuk mengukur kinerjanya. Hasil prediksi kemudian dianalisis menggunakan metrik evaluasi berupa akurasi, confusion matrix, dan classification report yang mencakup nilai precision, recall, dan f1-score. Evaluasi ini bertujuan untuk mengetahui seberapa baik model dalam membedakan pasien yang benar-benar mengalami serangan jantung dengan yang tidak, khususnya dalam kelompok yang tergolong sangat rentan. Dengan pendekatan ini, diharapkan model yang dihasilkan tidak hanya akurat tetapi juga dapat digunakan sebagai alat bantu keputusan dalam konteks deteksi dini risiko serangan jantung.

Berdasarkan hasil evaluasi terhadap data uji, model XGBoost yang telah dibangun menunjukkan performa yang cukup baik dengan nilai akurasi sebesar 72,43%. Angka ini menunjukkan bahwa model mampu mengklasifikasikan pasien dalam cluster risiko tinggi dengan tingkat ketepatan yang layak. Dari confusion matrix terlihat bahwa model berhasil mengidentifikasi 1455 pasien yang benar-benar mengalami serangan jantung dan 1260 pasien yang tidak mengalami serangan jantung. Sementara itu, nilai precision, recall, dan f1-score untuk kelas positif (serangan jantung) masing-masing sebesar 0.67, 0.81, dan 0.73, yang menandakan bahwa model cukup baik dalam mendeteksi pasien yang benar-benar berisiko tinggi. Nilai recall yang tinggi pada kelas positif menjadi indikator penting dalam konteks medis karena menunjukkan bahwa model memiliki kemampuan yang cukup andal dalam mengidentifikasi pasien yang rentan terhadap serangan jantung, sehingga sangat bermanfaat dalam mendukung upaya pencegahan dan intervensi dini. Namun demikian, masih terdapat ruang untuk perbaikan, terutama dalam meningkatkan precision agar jumlah false positive dapat diminimalkan dan rekomendasi intervensi menjadi lebih tepat sasaran.

4.1.9. Analisis Tambahan

Untuk memperkaya hasil penelitian, dilakukan analisis tambahan terhadap pasien dalam kelompok risiko tinggi guna memperoleh pemahaman yang lebih mendalam mengenai karakteristik populasi yang rentan


mengalami serangan jantung. Analisis ini meliputi distribusi usia pasien, hubungan antara usia dan tingkat risiko serangan jantung, serta identifikasi indikator risiko yang dominan berdasarkan kelompok usia.

Analisis tambahan ini tidak hanya bertujuan untuk mendeskripsikan data secara statistik, tetapi juga untuk mengidentifikasi pola-pola tersembunyi yang mungkin tidak terlihat dalam hasil klasifikasi semata. Pendekatan ini penting dilakukan, terutama karena penelitian ini menggunakan dataset yang sangat besar (lebih dari 158 ribu data), sehingga eksplorasi lanjutan diperlukan agar setiap temuan memiliki konteks dan nilai implementatif yang kuat dalam bidang medis.

Fokus utama dari analisis ini adalah menggali hubungan antara usia dan kejadian serangan jantung, mengamati sebaran faktor risiko pada tiap kelompok usia, serta menentukan fitur-fitur kesehatan mana yang paling dominan dalam prediksi kejadian serangan jantung di kelompok risiko tinggi. Dengan menggabungkan analisis distribusi, rata-rata risiko, heatmap indikator kesehatan, dan feature importance dari model klasifikasi, diharapkan dapat diperoleh gambaran yang lebih komprehensif mengenai profil pasien risiko tinggi.

Analisis ini juga mendukung tujuan penelitian untuk membangun sistem deteksi dini berbasis data mining yang tidak hanya akurat secara prediktif, tetapi juga kaya secara informatif. Setiap hasil visualisasi yang dihasilkan dalam bagian ini dapat membantu tenaga kesehatan, peneliti, maupun pengambil kebijakan dalam menyusun strategi intervensi yang lebih tepat sasaran dan berbasis bukti. Adapun bentuk-bentuk analisis yang dilakukan meliputi:

a. Distribusi Umur Berdasarkan Serangan Jantung



Gambar 13. Distribusi Usia pada Cluster Risiko Tinggi


Gambar di atas menyajikan distribusi usia pasien yang termasuk dalam cluster risiko tinggi, dengan membedakan status serangan jantung berdasarkan warna. Warna merah mewakili pasien yang mengalami serangan jantung, sedangkan warna hijau menunjukkan pasien yang tidak mengalami serangan jantung. Grafik ini menggunakan pendekatan histogram yang dilengkapi dengan kurva kepadatan (density curve) untuk masing-masing kategori, sehingga pola persebaran data dapat diamati secara lebih jelas. Dari grafik tersebut, terlihat bahwa jumlah pasien dalam kelompok risiko tinggi mulai mengalami peningkatan yang signifikan sejak memasuki usia 40 tahun ke atas. Puncak distribusi ditemukan pada rentang usia 50 hingga 55 tahun, yang ditandai dengan jumlah pasien paling banyak, terutama pada kelompok yang tidak mengalami serangan jantung.

Namun, pola ini mengalami pergeseran pada usia 60 tahun ke atas, di mana kurva merah yang mewakili pasien dengan serangan jantung mulai mendekati, bahkan pada beberapa titik melebihi, jumlah pasien yang tidak mengalami serangan jantung. Hal ini mengindikasikan bahwa risiko serangan jantung cenderung meningkat secara progresif seiring bertambahnya usia,

khususnya setelah memasuki usia lanjut. Distribusi ini juga menunjukkan bahwa meskipun usia paruh baya (40–59 tahun) mendominasi secara kuantitatif, proporsi pasien yang benar-benar mengalami serangan jantung lebih tinggi pada usia 60 tahun ke atas. Temuan ini menguatkan peran usia sebagai salah satu variabel prediktor yang paling signifikan dalam model klasifikasi risiko serangan jantung.

Secara klinis, distribusi tersebut mencerminkan fakta bahwa proses degeneratif yang berkaitan dengan penuaan, seperti penurunan elastisitas pembuluh darah, peningkatan tekanan darah, serta akumulasi plak kolesterol, menjadi faktor utama yang meningkatkan kerentanan terhadap serangan jantung pada lansia. Oleh karena itu, intervensi kesehatan yang ditargetkan pada kelompok usia lanjut menjadi sangat penting, tidak hanya untuk mengelola risiko yang sudah ada, tetapi juga untuk mencegah transisi dari status risiko tinggi menjadi kejadian serangan jantung yang nyata. Visualisasi ini mendukung pendekatan personalisasi dalam pencegahan penyakit kardiovaskular dan memberikan justifikasi kuat untuk melakukan skrining rutin, khususnya pada individu usia lanjut yang telah teridentifikasi dalam cluster risiko tinggi melalui algoritma K-Means.

b. Rata-Rata Risiko Serangan Jantung per Kelompok Usia



Gambar 14. Rata-rata Risiko Serangan Jantung per Kelompok Usia


Gambar di atas menggambarkan rata-rata proporsi kejadian serangan jantung pada masing-masing kelompok usia dalam cluster risiko tinggi yang telah diidentifikasi melalui algoritma K-Means. Setiap batang pada grafik menunjukkan persentase atau probabilitas rata-rata pasien dalam kelompok usia tertentu yang mengalami serangan jantung. Dari visualisasi ini, terlihat adanya pola peningkatan risiko seiring bertambahnya usia, terutama setelah memasuki usia 60 tahun. Kelompok usia 60–69 dan 70–79 menunjukkan proporsi serangan jantung tertinggi, yaitu mendekati angka 0,5, yang berarti sekitar separuh dari pasien dalam kelompok usia tersebut di dalam cluster risiko tinggi mengalami serangan jantung. Ini menunjukkan bahwa meskipun semua pasien dalam grafik ini telah termasuk dalam kategori risiko tinggi, usia tetap menjadi faktor yang secara signifikan mempengaruhi kemungkinan aktual terjadinya serangan jantung.

Kelompok usia di bawah 60 tahun seperti <30, 30–39, 40–49, dan 50–59 menunjukkan tingkat risiko yang relatif lebih rendah dibandingkan kelompok lansia, dengan proporsi kejadian serangan jantung berada pada kisaran 0,35 hingga 0,39. Hal ini menegaskan bahwa meskipun individu muda juga dapat termasuk dalam cluster risiko tinggi—mungkin karena adanya faktor-faktor komorbid seperti hipertensi, diabetes, atau gaya hidup tidak sehat—tetapi kemungkinan aktual mereka untuk mengalami serangan jantung masih lebih rendah dibandingkan kelompok usia lanjut. Adapun kelompok usia 80 tahun ke atas menunjukkan sedikit penurunan dalam proporsi serangan jantung dibandingkan kelompok 60–79, yang bisa saja disebabkan oleh jumlah sampel yang lebih sedikit atau faktor survival bias, di mana individu yang mencapai usia tersebut kemungkinan memiliki kondisi jantung yang lebih kuat atau gaya hidup yang lebih sehat.

Secara keseluruhan, grafik ini mengonfirmasi bahwa usia merupakan salah satu variabel determinan dalam prediksi serangan jantung, bahkan di antara populasi yang telah teridentifikasi berada dalam risiko tinggi. Informasi ini sangat berguna bagi perencanaan intervensi medis yang lebih tertarget. Misalnya, kelompok usia 60 tahun ke atas dalam cluster risiko tinggi

dapat dijadikan prioritas utama dalam program pemantauan rutin, pemberian terapi preventif, serta edukasi gaya hidup sehat. Temuan ini juga sejalan dengan pendekatan preventif dalam ilmu kedokteran yang menekankan pentingnya pengelompokan populasi berdasarkan karakteristik risiko untuk efisiensi penggunaan sumber daya kesehatan dan peningkatan efektivitas penanganan penyakit kardiovaskular.

c. Heatmap Faktor Risiko Berdasarkan Kelompok Usia



Gambar 15. Heatmap Indikator Risiko Serangan Jantung Berdasarkan Kelompok Usia (Cluster Risiko Tinggi)

Gambar di atas merupakan visualisasi heatmap yang menampilkan rata-rata nilai berbagai indikator risiko serangan jantung yang dikelompokkan berdasarkan kelompok usia pada pasien dengan kategori risiko tinggi. Setiap sel dalam heatmap merepresentasikan nilai rata-rata dari satu indikator risiko tertentu dalam kelompok usia tertentu, dengan intensitas warna yang menunjukkan besar kecilnya nilai tersebut—semakin gelap warnanya, semakin tinggi nilai rata-ratanya. Grafik ini bertujuan untuk mengidentifikasi pola-pola khusus yang muncul di antara kelompok usia dalam hal

karakteristik kesehatan yang berhubungan langsung dengan risiko serangan jantung.


Dari heatmap tersebut, terlihat bahwa beberapa indikator menunjukkan peningkatan nilai secara konsisten seiring bertambahnya usia. Contohnya adalah tekanan darah sistolik (tekanan_darah_sistolik), kadar kolesterol LDL (kolestrol_ldl), trigliserida, serta hasil EKG. Indikator-indikator ini cenderung memiliki warna yang semakin pekat pada kelompok usia 60 tahun ke atas, mencerminkan kecenderungan peningkatan faktor risiko biologis yang umum terjadi pada usia lanjut. Ini menegaskan temuan dari literatur medis bahwa proses penuaan berkontribusi pada perubahan fisiologis yang meningkatkan kerentanan terhadap gangguan kardiovaskular. Selain itu, indikator seperti riwayat keluarga (riwayat_keluarga), hipertensi, dan diabetes menunjukkan nilai yang relatif tinggi pada hampir semua kelompok usia, yang mencerminkan bahwa faktor genetik dan penyakit penyerta turut mendominasi dalam penentuan risiko, tidak terbatas pada usia tua saja.

Sementara itu, indikator perilaku seperti status merokok (status_merokok) dan konsumsi alkohol (konsumsi_alkohol) memiliki nilai yang lebih tinggi pada kelompok usia muda hingga paruh baya, namun mengalami penurunan pada usia lanjut. Hal ini mungkin disebabkan oleh pergeseran gaya hidup atau adanya efek seleksi alamiah, di mana individu yang terus menerapkan kebiasaan buruk hingga usia tua mungkin telah lebih dulu mengalami komplikasi serius. Paparan polusi udara dan tingkat stres menunjukkan fluktuasi nilai di seluruh kelompok usia, mengindikasikan bahwa faktor lingkungan dan psikososial bisa menjadi faktor risiko lintas usia yang tidak selalu linear hubungannya dengan umur.

Dari keseluruhan pola yang ditampilkan, heatmap ini memberi gambaran yang kuat tentang bagaimana kombinasi antara faktor fisiologis, genetik, dan perilaku berubah antar kelompok usia, bahkan dalam populasi yang sama-sama diklasifikasikan dalam cluster risiko tinggi. Dengan memahami pola ini, pengambilan keputusan dalam dunia medis dapat dilakukan secara lebih tepat sasaran. Sebagai contoh, intervensi berbasis usia

dapat disusun, seperti memberikan perhatian lebih pada pengendalian tekanan darah dan kolesterol pada pasien lansia, sementara program edukasi pencegahan dapat difokuskan pada pengurangan konsumsi rokok dan alkohol pada kelompok usia yang lebih muda. Dengan demikian, visualisasi ini tidak hanya berfungsi sebagai alat analisis, tetapi juga sebagai dasar pengembangan strategi kesehatan yang lebih adaptif dan presisi terhadap kebutuhan spesifik tiap segmen usia dalam populasi berisiko tinggi.

d. Analisis Feature Importance



Gambar 16. Pentingnya Fitur dalam Prediksi Serangan Jantung (Feature Importance XGBoost)

Selain mengevaluasi kinerja model melalui metrik seperti akurasi dan confusion matrix, penelitian ini juga melakukan analisis terhadap tingkat kontribusi masing-masing fitur (feature importance) dalam proses klasifikasi serangan jantung pada kelompok pasien dengan risiko tinggi. Analisis ini bertujuan untuk mengidentifikasi fitur-fitur yang paling berpengaruh dalam pengambilan keputusan model, sehingga dapat memberikan wawasan yang lebih dalam mengenai faktor-faktor risiko utama, serta membantu tenaga medis dalam merancang intervensi yang lebih efektif dan terarah.

Berdasarkan hasil visualisasi pada Gambar 16, diketahui bahwa fitur dengan kontribusi terbesar dalam prediksi serangan jantung adalah hipertensi,

riwayat penyakit jantung, dan diabetes. Ketiga fitur tersebut memiliki skor pentingnya paling tinggi dibandingkan fitur lainnya, yang menandakan bahwa kondisi klinis kronis ini merupakan indikator utama dalam model prediksi. Keberadaan hipertensi dan diabetes yang saling berkaitan dengan gangguan fungsi kardiovaskular, serta riwayat penyakit jantung yang mencerminkan kerentanan terhadap kejadian berulang, menjadikan ketiganya sebagai penentu signifikan dalam mengidentifikasi pasien berisiko tinggi.

Selain itu, fitur status merokok, usia, dan kadar kolesterol juga menunjukkan pengaruh yang cukup besar dalam proses klasifikasi. Faktor-faktor ini sesuai dengan temuan dalam berbagai penelitian medis sebelumnya yang menyatakan bahwa kebiasaan merokok, proses penuaan, dan ketidakseimbangan profil lipid darah memiliki peran besar dalam meningkatkan kemungkinan terjadinya serangan jantung. Oleh karena itu, fitur-fitur ini tidak hanya relevan secara statistik dalam model, tetapi juga dapat dijadikan sebagai indikator awal dalam upaya skrining populasi umum.

Di sisi lain, fitur-fitur seperti aktivitas fisik, tingkat pendapatan, pola makan, dan obesitas menunjukkan tingkat kontribusi yang relatif lebih rendah dalam model ini. Walaupun kontribusinya kecil, fitur-fitur tersebut tetap memiliki nilai penting sebagai variabel pendukung yang membentuk konteks risiko secara holistik. Rendahnya skor pada fitur-fitur ini mungkin disebabkan oleh dominannya pengaruh faktor klinis dibandingkan perilaku dalam populasi risiko tinggi, atau karena variabilitas data yang kurang mencolok dalam kelompok tersebut.

Dengan mengidentifikasi fitur-fitur paling berpengaruh, hasil ini memberikan pemahaman yang lebih transparan dan interpretatif terhadap model XGBoost yang dibangun. Temuan ini juga memperkuat fokus preventif yang harus diberikan pada pengendalian tekanan darah, pemantauan riwayat jantung, serta penanganan diabetes. Dengan demikian, hasil ini tidak hanya berkontribusi pada peningkatan akurasi prediksi, tetapi juga dapat menjadi dasar pengambilan kebijakan intervensi yang lebih presisi dalam konteks pelayanan kesehatan masyarakat.

4.2. Analisis Hasil Penelitian

Setelah melalui tahapan preprocessing data yang mencakup pembersihan nilai kosong, encoding data kategorikal, dan normalisasi fitur numerik, proses analisis dilanjutkan dengan penerapan algoritma K-Means Clustering sebagai metode segmentasi risiko pasien. Hasil dari proses klasterisasi ini menunjukkan bahwa data pasien berhasil dikelompokkan ke dalam tiga klaster utama, yaitu klaster risiko rendah, sedang, dan tinggi, berdasarkan kesamaan pola pada atribut medis dan kebiasaan hidup yang dimiliki pasien.

Dari klaster risiko tinggi tersebut, dibangun model klasifikasi menggunakan algoritma XGBoost yang dilatih untuk memprediksi apakah pasien benar-benar mengalami serangan jantung atau tidak. Hasil prediksi menunjukkan bahwa dari total data uji, sebanyak 3.501 pasien berhasil terdeteksi mengalami serangan jantung, sedangkan 6.044 pasien terklasifikasi tidak mengalami serangan jantung. Hasil ini menunjukkan bahwa model tidak hanya mampu mengidentifikasi pasien positif serangan jantung, tetapi juga memiliki kemampuan generalisasi yang baik dalam menyaring pasien negatif, meskipun tetap diperlukan perhatian terhadap kemungkinan false negative.

Analisis terhadap kontribusi fitur menunjukkan bahwa hipertensi merupakan faktor risiko paling dominan dalam memprediksi kejadian serangan jantung, diikuti oleh riwayat penyakit jantung, diabetes, dan status merokok. Faktor lain seperti usia dan kadar kolesterol juga memberikan pengaruh yang cukup signifikan, meskipun tidak sebesar empat faktor utama tersebut. Visualisasi tingkat kepentingan fitur (*feature importance*) menunjukkan bahwa skor tertinggi dimiliki oleh atribut hipertensi dan riwayat penyakit jantung, yang mengindikasikan bahwa kedua faktor tersebut memiliki peran penting dalam akurasi deteksi risiko serangan jantung.

Model klasifikasi yang telah dikembangkan dalam penelitian ini juga telah disimpan dan dapat diakses oleh peneliti lain melalui tautan repositori GitHub berikut: https://github.com/dimaszr/model_skripsi2311.git

Dengan demikian, gabungan algoritma K-Means dan XGBoost dalam penelitian ini berhasil memetakan dan mengklasifikasikan pasien risiko tinggi secara efektif, serta memberikan wawasan klinis yang kuat tentang faktor dominan yang mempengaruhi terjadinya serangan jantung pada populasi risiko tinggi.

Analisis keseluruhan dari kedua algoritma menunjukkan bahwa kombinasi antara unsupervised learning (K-Means) dan supervised learning (XGBoost) mampu memberikan pemahaman yang lebih mendalam terhadap pola-pola risiko dalam data kesehatan pasien. Hasil tersebut tidak hanya bermanfaat dalam konteks pengolahan data medis, tetapi juga memberikan kontribusi langsung terhadap proses pengambilan keputusan berbasis data di bidang kesehatan, khususnya dalam identifikasi pasien berisiko tinggi yang memerlukan tindakan preventif lebih awal.

4.2.1. Evaluasi Model

Evaluasi model dalam penelitian ini difokuskan pada pengukuran kinerja algoritma XGBoost dalam memprediksi kejadian serangan jantung pada pasien yang sebelumnya telah dikelompokkan ke dalam cluster risiko tinggi menggunakan algoritma K-Means. Fokus pada cluster ini bertujuan agar model dapat mempelajari pola-pola dari pasien yang memang telah dikategorikan berisiko tinggi, sehingga prediksi yang dihasilkan menjadi lebih kontekstual dan tepat sasaran.

Setelah dilakukan proses tuning terhadap beberapa hyperparameter penting seperti `learning_rate`, `max_depth`, `n_estimators`, `subsample`, dan `colsample_bytree`, model XGBoost menghasilkan performa yang lebih optimal. Berdasarkan hasil evaluasi terbaru, model mencapai akurasi sebesar 72.45%, yang menunjukkan peningkatan dibandingkan dengan model sebelumnya.

Hasil *confusion matrix* menunjukkan bahwa model mampu mengklasifikasikan 3.681 pasien positif (dengan serangan jantung) dan 2.239 pasien negatif secara benar. Namun, masih terdapat 1.229 kasus false negative dan 1.407 kasus false positive, yang menunjukkan bahwa meskipun model

cukup baik dalam mendeteksi kasus sebenarnya, tetap ada ruang untuk perbaikan lebih lanjut dalam mengurangi kesalahan klasifikasi.

Secara keseluruhan, metrik evaluasi menunjukkan performa yang cukup stabil:

- **Precision** untuk pasien dengan serangan jantung (kelas 1): 0.72
- **Recall: 0.77**
- **F1-score: 0.74**

Sementara untuk pasien tanpa serangan jantung (kelas 0), precision-nya sebesar 0.63, recall 0.68, dan f1-score 0.65. Nilai rata-rata metrik klasifikasi memperlihatkan bahwa model memiliki kemampuan prediksi yang seimbang antara deteksi positif dan negatif, dengan *weighted average* f1-score mencapai **0.72**.

Metrik	Kelas 0 (Tidak)	Kelas 1 (Ya)	Rata- rata
Precision	0.63	0.72	0.68
Recall	0.68	0.77	0.73
F1-Score	0.65	0.74	0.70
Akurasi	-	-	0.7245

Hasil ini memperkuat kesimpulan bahwa penerapan XGBoost dengan tuning hyperparameter mampu memberikan performa klasifikasi yang cukup handal dalam konteks prediksi serangan jantung, terutama pada data real-world yang kompleks dan bervariasi. Meskipun akurasi model belum mencapai angka 80%, performa sebesar 72.45% ini sudah tergolong baik sebagai langkah awal dalam proses skrining dan deteksi dini terhadap pasien dengan risiko tinggi. Untuk pengembangan selanjutnya, peningkatan performa dapat dilakukan melalui teknik seperti *data balancing*, *cross-validation*, serta *feature selection* yang lebih terarah.

4.2.2. Interpretasi Temuan

Hasil penelitian ini menunjukkan bahwa pendekatan kombinasi antara

algoritma K-Means Clustering dan XGBoost Classifier mampu memberikan pemahaman yang mendalam terhadap pola risiko serangan jantung berdasarkan data kesehatan dan gaya hidup pasien. Melalui proses klusterisasi menggunakan K-Means, data berhasil dikelompokkan ke dalam tiga kategori risiko: rendah, sedang, dan tinggi, dengan fokus utama diarahkan pada cluster risiko tinggi. Kelompok ini menunjukkan rata-rata nilai indikator yang lebih ekstrem, seperti tekanan darah sistolik, kadar kolesterol LDL, dan usia yang lebih lanjut, dibandingkan dengan cluster lainnya.

Model XGBoost yang dibangun secara khusus untuk mengklasifikasikan pasien dalam kelompok risiko tinggi menunjukkan performa yang cukup baik, dengan akurasi mencapai 72,45% setelah dilakukan tuning terhadap sejumlah hyperparameter penting. Hal ini mengindikasikan bahwa fitur-fitur yang telah melalui proses normalisasi dan encoding mampu merepresentasikan pola data yang relevan dalam membedakan pasien yang mengalami serangan jantung dari yang tidak. Selain itu, metrik evaluasi lain seperti precision, recall, dan f1-score juga menunjukkan keseimbangan performa model dalam mengidentifikasi kedua kelas dengan cukup efektif.

Hasil interpretasi lebih lanjut diperoleh melalui visualisasi distribusi usia. Grafik distribusi menunjukkan bahwa mayoritas pasien risiko tinggi berada dalam rentang usia 50 hingga 70 tahun, dengan peningkatan signifikan pada kejadian serangan jantung setelah usia 60 tahun. Visualisasi proporsi serangan jantung berdasarkan kelompok usia menguatkan temuan ini, di mana kelompok usia 60–69, 70–79, dan 80+ memiliki proporsi kejadian serangan jantung tertinggi, yaitu di atas 50%, bahkan mendekati 70% pada beberapa kelompok. Temuan ini memperkuat pemahaman bahwa usia merupakan faktor risiko yang signifikan dalam kejadian serangan jantung.

Lebih lanjut, heatmap indikator risiko mengungkapkan bahwa kelompok usia lanjut cenderung memiliki rata-rata nilai yang tinggi pada berbagai indikator medis, seperti tekanan darah sistolik, gula darah puasa, trigliserida, dan kolesterol LDL. Sementara itu, kelompok usia yang lebih

muda menunjukkan nilai yang lebih rendah dan cenderung stabil. Hal ini mencerminkan bahwa peningkatan risiko serangan jantung tidak hanya disebabkan oleh usia semata, tetapi juga oleh akumulasi dari kondisi medis kronis dan pola gaya hidup yang tidak sehat seiring bertambahnya usia.

Secara keseluruhan, temuan ini menegaskan bahwa indikator fisiologis utama seperti hipertensi, diabetes, dan riwayat penyakit jantung sebelumnya memiliki peran dominan dalam memengaruhi prediksi serangan jantung. Model prediktif yang dikembangkan tidak hanya menunjukkan kemampuan klasifikasi yang baik, tetapi juga dapat digunakan sebagai alat bantu pengambilan keputusan klinis untuk mendeteksi lebih dini kelompok pasien yang paling membutuhkan intervensi medis secara preventif.

4.2.3. Kaitan dengan Hipotesis dan Penelitian Sebelumnya

Berdasarkan hasil penelitian ini, kedua hipotesis utama yang diajukan terbukti dapat diterima. Hipotesis pertama (H_1), yaitu bahwa algoritma K-Means Clustering mampu mengelompokkan pasien berdasarkan tingkat risiko serangan jantung, terbukti dengan terbentuknya tiga cluster utama: risiko rendah, sedang, dan tinggi. Klaster risiko tinggi menunjukkan karakteristik yang signifikan, seperti tekanan darah tinggi, kolesterol yang tidak normal, dan rentang usia yang lebih tua, yang mendukung validitas segmentasi yang dilakukan.

Hipotesis kedua (H_2), yang menyatakan bahwa algoritma XGBoost mampu memprediksi apakah pasien dalam cluster risiko tinggi benar-benar mengalami serangan jantung, juga dapat diterima. Dengan akurasi sebesar 72.45% setelah dilakukan tuning terhadap hyperparameter, model menunjukkan performa yang cukup baik untuk konteks prediksi pada data medis berskala besar.

Jika dibandingkan dengan penelitian oleh Jihan Wala et al. (2024), pendekatan penelitian ini memiliki kesamaan dalam hal penerapan algoritma K-Means untuk segmentasi pasien penyakit jantung. Dalam penelitian tersebut, K-Means digunakan untuk mengelompokkan pasien berdasarkan gejala dan nilai medis seperti jenis nyeri dada, tekanan darah, dan kadar

kolesterol, yang kemudian menghasilkan empat klaster risiko. Salah satu klaster diidentifikasi sebagai kelompok risiko tinggi, yang didominasi oleh pasien dengan usia lanjut dan tekanan darah tinggi—temuan yang selaras dengan hasil pada penelitian ini.

Namun, perbedaan signifikan terletak pada keberlanjutan proses analisis. Penelitian oleh Wala et al. berhenti pada tahap segmentasi, tanpa melanjutkan ke tahap prediksi atau klasifikasi terhadap klaster risiko tinggi. Sementara itu, penelitian ini melangkah lebih jauh dengan menerapkan algoritma XGBoost untuk memprediksi secara spesifik pasien dalam klaster risiko tinggi yang berpotensi mengalami serangan jantung. Dengan demikian, pendekatan penelitian ini tidak hanya melengkapi tetapi juga memperluas ruang lingkup studi Wala et al. dengan menghadirkan model prediktif berbasis supervised learning yang dapat dimanfaatkan dalam sistem deteksi dini.

Dengan demikian, pendekatan kombinasi antara K-Means dan XGBoost dalam penelitian ini tidak hanya mampu mencapai akurasi yang kompetitif, tetapi juga memperluas cakupan penelitian sebelumnya, khususnya yang dilakukan oleh Jihan Wala et al. (2024), melalui penambahan tahap klasifikasi dan analisis prediktif yang lebih mendalam terhadap pasien berisiko tinggi.

BAB V

PENUTUP

5.1.Simpulan

Penelitian ini bertujuan untuk mengembangkan sebuah sistem analitik prediksi risiko serangan jantung dengan menggabungkan pendekatan unsupervised learning (K-Means Clustering) dan supervised learning (XGBoost Classifier). Berdasarkan hasil pengujian dan analisis yang telah dilakukan, dapat disimpulkan bahwa metode K-Means mampu mengelompokkan pasien ke dalam tiga klaster utama: rendah, sedang, dan tinggi, berdasarkan kemiripan atribut medis dan kebiasaan hidup yang dimiliki. Klaster risiko tinggi berhasil diidentifikasi dengan indikator utama seperti tekanan darah, kadar kolesterol, dan usia lanjut.

Selanjutnya, data dari klaster risiko tinggi digunakan sebagai subset khusus untuk membangun model klasifikasi menggunakan algoritma XGBoost. Setelah dilakukan proses tuning terhadap hyperparameter penting, model berhasil mencapai akurasi sebesar 72,43%, dengan keseimbangan yang cukup baik antara precision dan recall. Hal ini menunjukkan bahwa kombinasi antara K-Means dan XGBoost tidak hanya efektif dalam segmentasi pasien, tetapi juga memiliki kemampuan prediksi yang layak dalam konteks klasifikasi medis. Temuan ini diperkuat dengan analisis visual tambahan seperti distribusi usia, proporsi serangan jantung per kelompok umur, dan heatmap indikator risiko, yang mengkonfirmasi pola-pola yang ditemukan dalam model.

Dengan demikian, pendekatan yang digunakan dalam penelitian ini dapat dijadikan acuan sebagai dasar pengambilan keputusan berbasis data untuk membantu proses deteksi dini dan intervensi terhadap pasien yang berisiko tinggi mengalami serangan jantung.

5.2.Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diajukan untuk pengembangan selanjutnya adalah sebagai berikut:

1. Untuk peningkatan akurasi model, disarankan untuk mempertimbangkan teknik balancing data seperti SMOTE atau undersampling, khususnya jika ditemukan ketidakseimbangan antara kelas target (misalnya antara pasien yang mengalami dan tidak mengalami serangan jantung).
2. Variabel atau atribut yang digunakan dalam penelitian ini masih dapat dikembangkan, terutama dengan menambahkan data klinis tambahan seperti riwayat medis lebih rinci, hasil pemeriksaan laboratorium lanjutan, atau variabel biometrik lainnya.
3. Penggunaan model klasifikasi lain seperti Random Forest, LightGBM, atau Deep Learning juga dapat dijadikan bahan perbandingan untuk mengetahui sejauh mana model XGBoost memberikan keunggulan dalam konteks prediksi risiko serangan jantung.
4. Untuk implementasi lebih lanjut, sistem prediksi ini dapat dikembangkan dalam bentuk antarmuka aplikasi sederhana yang dapat membantu tenaga medis atau instansi kesehatan dalam melakukan screening awal terhadap pasien, khususnya yang masuk kategori risiko tinggi.
5. Akhirnya, kolaborasi dengan tenaga medis dan ahli jantung sangat disarankan agar interpretasi hasil model tidak hanya bersifat numerik, tetapi juga dapat divalidasi secara klinis untuk memastikan kebermanfaatannya dalam praktik kesehatan.

DAFTAR PUSTAKA

- Alfajr, N. H., & Defiyanti, S. (2024). Prediksi Penyakit Jantung Menggunakan Metode Random Forest dan Penerapan Principal Component Analysis (PCA). *Jurnal Informatika Dan Teknik Elektro Terapan*, 12(3S1). <https://doi.org/10.23960/jitet.v12i3S1.5055>
- Aloysia Putri Prasetya, F., & Prima Rosa, P. H. (n.d.). *Seminar Nasional Informatika Bela Negara (SANTIKA) Klasifikasi Kegagalan Pembayaran Kredit Nasabah Bank dengan Algoritma XGBoost*. <https://www.kaggle.com/datasets/nikhil1e9/loan-default/data>
- Amelia, Y. (2023). Perbandingan Metode Machine Learning Untuk Mendeteksi Penyakit Jantung. In *Idealis: Indonesia Journal Information System* (Vol. 6, Issue 2). <http://jom.fti.budiluhur.ac.id/index.php/IDEALIS/index>
- Bischl, B., Binder, M., Lang, M., Pielok, T., Richter, J., Coors, S., Thomas, J., Ullmann, T., Becker, M., Boulesteix, A.-L., Deng, D., & Lindauer, M. (n.d.). *Hyperparameter Optimization: Foundations, Algorithms, Best Practices and Open Challenges*.
- Bonthu, Y., Mannam, S., Kandikunta, G., Keshagani, V. G., & Sarath, G. (2024). Heart Attack Risk Prediction Using Advanced Machine Learning Techniques. *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, 1–6. <https://doi.org/10.1109/ICCCNT61001.2024.10725867>
- Diao, Y., Yao, L., & Li, M. (n.d.). *Exploration of Blended Teaching Mode in Python Programming Course*.
- Hajar, S., Novany, A. A., Windarto, A. P., Wanto, A., & Irawan, E. (n.d.). *Seminar Nasional Teknologi Komputer & Sains (SAINTEKS) Penerapan K-Means Clustering Pada Ekspor Minyak Kelapa Sawit Menurut Negara Tujuan*.
- Hamidah, K., Voutama, A., Artikel, S., Faktor, K. :, Kdd, K., & Linear, R. (n.d.). *Jurnal Explore IT|1 Analisis Faktor Tingkat Kebahagiaan Negara Menggunakan Data World Happiness Report dengan Metode Regresi Linier Info Artikel Abstrak*. <https://doi.org/10.35891/explorit>

- Hogan, G., Patel, H., & Patel, N. R. (2024). Are you giving men with heart failure the best care? *Trends in Urology & Men's Health*, 15(1), 11–16.
<https://doi.org/10.1002/tre.948>
- Indraputra, R. A., & Fitriana, R. (n.d.). *K-Means Clustering Data COVID-19*.
- Kaestria, R., & Himmah, E. F. (n.d.). *Implementasi Bahasa Pemrograman Python untuk Path analysis* (Vol. 11, Issue 2).
- Kepadatan, P., Berdasarkan, P., Penduduk, J., Medan, K., Marpaung, P., & Siahaan, R. F. (2021). Penerapan Algoritma K-Means Clustering Untuk. In *Jurnal Sains Komputer & Informatika (J-SAKTI)* (Vol. 5, Issue 1).
- K-means clustering algorithm: a brief review. (2021a). *Academic Journal of Computing & Information Science*, 4(5).
<https://doi.org/10.25236/ajcis.2021.040506>
- K-means clustering algorithm: a brief review. (2021b). *Academic Journal of Computing & Information Science*, 4(5).
<https://doi.org/10.25236/ajcis.2021.040506>
- Mayang Pratiwi, D., & Mufidah, L. (2024). *Perbandingan Metode Decision Tree Classifier dan XGBoost Classifier Dalam Memprediksi Penyakit Jantung* (Vol. 4, Issue 1).
- Muzakki, F., Ubaydillah, I., Assyiami, N. R., & Soleha, S. (2024). Penerapan Algoritma C4.5 Untuk Prediksi Penyakit Jantung Menggunakan Rapidminer. *Jurnal Komputer Antartika*, 2, 71–79.
<https://ejournal.mediaantartika.id/index.php/jka>
- Nyoman, I., & Adiputra, M. (2021). Clustering Penyakit Dbd Pada Rumah Sakit Dharma Kerti Menggunakan Algoritma K-Means. *Insert: Information System and Emerging Technology Journal*, 2(2), 99.
- P, V., & R, P. J. I. (2024). Predictive Analytics Model for Heart Disease Prediction with Personalized Recommendation Systems using Machine Learning Techniques. *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, 1–7.
<https://doi.org/10.1109/ICCCNT61001.2024.10723990>
- Peng, B., Zhao, J., Sun, Y., & Liu, Y. (2024). Research and Discussion on

- Comparative Prediction Models Based on XGBoost and Random Forest and Clustering Analysis. *2024 IEEE 2nd International Conference on Control, Electronics and Computer Technology (ICCECT)*, 780–785. <https://doi.org/10.1109/ICCECT60629.2024.10546164>
- Pengabdian Magister Pendidikan IPA, J., Agung Sagung Mas Meiswaryasti Putra, A., Agung Ayu Niti Wedayani, A., Amalia, E., Arie Yuliyani, E., Andansari Putri, N., Agung Ketut Sudharmawan, A., Hidayat Makbul, I., & Author, C. (2023). Edukasi Penangan Awal Pada Serangan Jantung. *Jurnal Pengabdian Magister Pendidikan IPA*, 6(4). <https://doi.org/10.29303/jpmppi.v6i4.5973>
- Permana, A. H., Umbara, F. R., & Kasyidi, F. (2024). Klasifikasi Penyakit Jantung Tipe Kardiovaskular Menggunakan Adaptive Synthetic Sampling dan Algoritma Extreme Gradient Boosting. *Building of Informatics, Technology and Science (BITS)*, 6(1), 499–508. <https://doi.org/10.47065/bits.v6i1.5421>
- Purba, R., Parlina, I., Dewi, R., Purnama Sari, I., Tunas Bangsa Pematangsiantar, S., Sumatra, N., & Tunas Bangsa Pematangsiantar, A. (2022a). *Journal of Artificial Intelligence and Engineering Applications Grouping Medical Record Data By Type Diseases With K-Means Algorithm* (Vol. 1, Issue 2). <https://ioinformatic.org/>
- Purba, R., Parlina, I., Dewi, R., Purnama Sari, I., Tunas Bangsa Pematangsiantar, S., Sumatra, N., & Tunas Bangsa Pematangsiantar, A. (2022b). *Journal of Artificial Intelligence and Engineering Applications Grouping Medical Record Data By Type Diseases With K-Means Algorithm* (Vol. 1, Issue 2). <https://ioinformatic.org/>
- Rahayu, S., Subekhi, A., Astuti, D., Widaningsih, I., & Sartika, I. (2020). *Upaya Mewaspadai Serangan Jantung Melalui Pendidikan Kesehatan*. 4(2), 163–171. <https://doi.org/10.31764/jmm.v4i2.1940>
- Roja Mahardika, F., Supianto, A. A., Setiawan, N. Y., Yuwana, R. S., & Suryawati, E. (2022). *Rekomendasi Pengembangan Fasilitas Wisata Tugu Pahlawan Surabaya Melalui Visualisasi Dashboard Hasil Klasifikasi Analisis Sentimen Ulasan Pengunjung*. 9(2), 363–372. <https://doi.org/10.25126/jtiik.202295655>
- Sami, O., Elsheikh, Y., & Almasalha, F. (2021). The Role of Data Pre-processing

- Techniques in Improving Machine Learning Accuracy for Predicting Coronary Heart Disease. *International Journal of Advanced Computer Science and Applications*, 12(6). <https://doi.org/10.14569/IJACSA.2021.0120695>
- Sekar Setyaningtyas, Indarmawan Nugroho, B., & Arif, Z. (2022). Tinjauan Pustaka Sistematis: Penerapan Data Mining Teknik Clustering Algoritma K-Means. *Jurnal Teknoif Teknik Informatika Institut Teknologi Padang*, 10(2), 52–61. <https://doi.org/10.21063/jtif.2022.v10.2.52-61>
- Siregar, D., Manik, M., Patrisia, I., Sitorus, F., Silitonga, E., Pailak, H., Sinaga, C., & Panjaitan, T. (2023). Pelatihan Bantuan Hidup Dasar (Hands-Only CPR) dan Edukasi Henti Jantung. *Jurnal Kreativitas Pengabdian Kepada Masyarakat (PKM)*, 6(7), 3033–3043. <https://doi.org/10.33024/jkpm.v6i7.10222>
- Sitarz, M. (2023). Extending F1 Metric, Probabilistic Approach. In *Advances in Artificial Intelligence and Machine Learning; Research* (Vol. 3, Issue 2). <https://www.oajaiml.com/>
- Supriyadi, E., Afgani Dahlan, J., Juandi, D., Sugiarni, R., Inayah, S., Pahmi, S., Sarah Fauziah Iskandar, R., Lutfi Fauzi, A., Studi Teknik Industri, P., Studi Pendidikan Matematika, P., Studi Pendidikan Guru Sekolah Dasar, P., & Tinggi Teknologi Bandung, S. (2023). *Pendampingan Guru Matematika Di Cianjur Dalam Penggunaan Bahasa Pemrograman Python Dengan Google Collaboratory* (Vol. 3, Issue 2).
- Sutandi. (2024). *Skripsi Sistem Klasifikasi Topik Tugas Akhir Mahasiswa Menggunakan Algoritma Xgboost*.
- Taylor, C. J., Beezer, J., Fuat, A., Halliday, B. P., Ludman, A. J., Pellicori, P., Savage, H. O., & Cleland, J. G. F. (2024). Predicting and preventing heart failure. *Considerations in Medicine*, 3(1), e000007. <https://doi.org/10.1136/conmed-2024-000007>
- Wala, J., Herman, H., Umar, R., & Suwanti, S. (2024). Heart Disease Clustering Modeling Using a Combination of the K-Means Clustering Algorithm and the Elbow Method. *Scientific Journal of Informatics*, 11(4), 903–914. <https://doi.org/10.15294/sji.v11i4.14096>

- Wala, J., & Umar, R. (2024). Implementasi K-Means Clustering pada Pengelompokan Pasien Penyakit Jantung. In *Jurnal Informatika Sunan Kalijaga* (Vol. 9, Issue 3).
- Yang, J. C. (2024). The prediction and analysis of heart disease using XGBoost algorithm. *Applied and Computational Engineering*, 41(1), 61–68. <https://doi.org/10.54254/2755-2721/41/20230711>
- Yulianti, E. H., Soesanto, O., & Sukmawaty, Y. (2022). Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit. *JOMTA Journal of Mathematics: Theory and Applications*, 4(1).
- Zang, X., Du, J., & Song, Y. (2023). Early Prediction of Heart Disease via LSTM-XGBoost. *Proceedings of the 2023 9th International Conference on Computing and Artificial Intelligence*, 631–637. <https://doi.org/10.1145/3594315.3594383>
- Zou, Q., Zhang, Y., & Chen, C. S. (2023). Construction and Application of a Machine Learning Prediction Model Based on Unbalanced Diabetes Data Fusion. *Proceedings of the 2023 International Joint Conference on Robotics and Artificial Intelligence*, 114–123. <https://doi.org/10.1145/3632971.3633348>

DAFTAR LAMPIRAN

Lampiran 1 Dataset Heart Attack Prediction In Indonesia

Dataset ini merupakan sumber utama dalam penelitian, berisi data sekunder sebanyak 158.355 pasien dengan 28 atribut kesehatan, yang digunakan dalam proses segmentasi risiko dan klasifikasi serangan jantung. Dikarenakan ukuran file yang cukup besar, dataset ini disediakan melalui tautan Google Drive agar dapat diakses dengan mudah tanpa mengganggu kelengkapan dokumen skripsi secara cetak.

https://drive.google.com/file/d/14pZQLgCloX0fjSUcH0RpqXBmreAWbMcg/view?usp=drive_link

Lampiran 2 Hasil Clustering K-Means Risiko Tinggi

Lampiran ini menyajikan hasil pengelompokan data pasien ke dalam tiga kluster risiko menggunakan algoritma K-Means, yang kemudian digunakan untuk mengidentifikasi kelompok pasien berisiko tinggi. Data hasil clustering ini disimpan dalam format file CSV dan disediakan melalui Google Drive karena keterbatasan ruang dalam penyajian dokumen cetak.

https://drive.google.com/file/d/14pZQLgCloX0fjSUcH0RpqXBmreAWbMcg/view?usp=drive_link

Lampiran 3 Hasil Klasifikasi Menggunakan Xgboost

Lampiran ini berisi hasil klasifikasi model XGBoost terhadap pasien dalam kluster risiko tinggi. File ini mencakup nilai prediksi dan data aktual serangan jantung, yang digunakan untuk evaluasi model berdasarkan akurasi, precision, recall, dan f1-score. Karena ukuran file dan detail isi tabel cukup besar, file ini disediakan melalui tautan Google Drive.

https://drive.google.com/file/d/1jdOEKLiPig0wLevD0sHHaM-u4ZXysDOj/view?usp=drive_link